

GRI-TTS:离散情感控制下的语音合成情感表达优化^①

胡泊, 罗辉*

(东北林业大学计算机与控制工程学院, 黑龙江 哈尔滨 150040)

摘要: 近期的文本到语音(TTS)模型能够利用简短的语音提示克隆未见过的说话人, 它们借助强大的上下文学习能力模仿语音提示, 包括说话人风格、韵律和情感。然而, 由于TTS模型手动或随机选择语音提示, 现有语音合成模型在多样化风格和韵律变化上存在不足。针对以上问题提出了一种离散情感控制语音合成方法 GRI-TTS, 在基础模型上引入情感编码器以高效提取情感特征, 并设计条件流匹配解码器以精确控制合成语音的情感表达。该方法实现了对语音合成的离散情感控制, 有效提升了语音合成的情感多样性和自然度, 为语音合成技术在情感表达领域的应用提供了新的思路。

关键词: 文本到语音; 离散情感控制; 情感编码器

中图分类号: TN912.33

文献标识码: A

DOI:10.20232/j.cnki.jmsdxxb.2025.06.046

0 引言

在人工智能领域, 语音合成技术作为关键的交互手段, 其重要性不言而喻。不仅能够为视障人士提供便捷的信息获取方式, 还能在智能语音助手、电子书朗读、情感陪伴等场景中发挥重要作用, 满足人们对信息传递的情感化需求。随着技术的不断进步, 用户对语音合成的自然度、情感丰富度以及风格多样性提出了更高的要求。

文本到语音合成旨在从文本生成自然语音, 随着深度学习方法的发展, 取得了巨大进步。最近, 大型语言模型(LLMs)与TTS合成技术的结合成为新趋势, 受到广泛关注。LLMs通过上下文学习(ICL), 在从极少提示中学习方面取得了显著进展。这种突破加上将连续音频特征转换为离散标记的神经音频编解码器的使用, 极大地推动了最近的语音合成框架, 如 VALL-E, AudioLM, NaturalSpeech2 和 SPEAR-TTS。

VALL-E 采用基于 RVQ 的音频编解码器 Encoder, 并利用语言模型作为基于提示的语言建模任务。可以根据仅 3s 的语音录音生成声学标

记。AudioLM 采用分层序列到序列方法, 并分别使用 w2v-BERT 和 SoundStream 提取语义和声学标记。语音提示在两个阶段中使用, 并用不同的表示提取。与传统的 TTS 系统(如 FastSpeech2 和 Tacotron2)相比, 这些新模型通过仅提供 3s 语音提示, 展现出强大的语音克隆能力和与人类说话人相当自然的韵律。这种巨大成功可以归因于 GPT 风格架构提供的上下文学习, 以及音频编解码器的使用, 使 TTS 模型能够利用大量多样化和嘈杂的数据, 而不仅仅是录制的数据。GPT 风格的生成高度依赖于之前预测的标记。现有方法通常从目标说话人中随机选择语音提示, 导致选择的提示经常不足以有效引导零样本 TTS 系统模仿所需的情感风格和目标音色。在实时性和情感控制的灵活性上。情感特征的提取和控制上仍然存在改进的余地, 特别是在高效性和精准度方面。

针对以上两个问题, 研究做出了以下贡献:

(1) 提出了引入情感编码器的 TTS 框架的新模型 GRI-TTS, 通过简化的情感编码器高效提取情感特征。

① 收稿日期: 2025-05-07

基金项目: 黑龙江省自然科学基金联合引导项目(LH2023F002)。

作者简介: 胡泊(1996-), 男, 黑龙江佳木斯人, 硕士, 研究方向: 语音合成、语音识别。

通讯作者: 罗辉(1989-), 男, 湖北天门人, 副教授, 博士, 研究方向: 语音合成、语音识别。

(2)利用条件流匹配解码器灵活地调整语音合成参数,从而实现对合成语音情感的精准控制。

(3)进行了广泛的主观和客观实验,发现提出的方法优于基线方法,引入情感编码器比纯文本嵌入方法效果更好。这种创新性的方法不仅提升了情感特征提取的效率和精准度,还增强了情感

表达控制的灵活性和自然度,为语音合成技术在情感化表达领域的应用提供了新的思路和解决方案。

1 方 法

1.1 基础模型概述




图 1 总体框架

采用 GPT-SOVITS2 作为 TTS 模型之一,承认其在语音合成中的出色表现力,如图 1。模型使用 Hubert 和 RVQ 聚类将音频转化为包含音色的语义 token,然后使用类 GPT 模型将他补全,利用类 GPT 模型的自回归特性,推理时后面的 token 始终会继承一些参考音频的音色。由于 token 使用的特征比 condition 语义特征含有更多的音色信息,因此类 GPT 补全的 token 更多的是包含参考音频的目标音色。Hubert 分担了一部分音色压力,使得实现语音合成具备了可行性。在此基础上,将 condition 变更为文本,如果能找到一种可包含情感信息的提取 token 方法,就实现了情感控制。

1.2 离散情感标签与特征融合

在基础模型上,增加一个情感编码器,将离散的情感标签转换为固定维度的情感嵌入向量。解码器使用 RNN 堆栈和基于内容的 tanh 注意力机制。解码器在每个时间步预测 r 帧梅尔频谱,使用解码器预处理网络、单层注意力 RNN 以及两层残差连接解码器 RNN。对于每个小批量数据,解码器从一个全零的“GO”帧开始;然后,每个时间步的前一个时间帧作为解码器预处理网络的输入。将情感标签向量的投影注入到注意力

RNN 中,通过将其与预处理网络的输出连接并添加一层来将其投影到注意力 RNN 输入的大小。在解码器 RNN 的第一层也进行相同的情感特征注入,以将情感特征添加到生成的频谱图中。在实验中发现注意力对齐在中间部分表现出不规律性,预测是注意力对齐的锐度和生成语音质量之间具有相关性,用于预测注意力对齐的信息来源来自编码器的文本编码。基于这种来源,提出了以下改进对齐的方法。

修改文本编码器,将情感嵌入向量与文本嵌入向量拼接,作为模型的输入特征。文本编码由 CBHG 模块(卷积库 + 高速公路 + 双向 GRU)生成。CBHG 包含卷积滤波器库,每个滤波器显式提取局部和上下文信息。在 CBHG 的最后阶段,有一个双向 RNN 以捕捉文本输入中的长期依赖关系。长期依赖关系在 RNN 读取输入时累积在 RNN 的隐藏状态中。一个问题在于隐藏状态的大小是固定的。如果序列足够长,隐藏状态将无法包含整个序列的信息。CBHG 中的双向 RNN 必须包含当前时间步的文本信息以及长期依赖关系的信息。这给隐藏状态带来了更多的负担。添加一个残差连接,将输入和双向 RNN 的输出连接起来就改变了 CBHG 的输出,添加一个额外的项 x_t ,如下所示:

$$y_t = x_t + \text{BiRNN}(x_t, h_{t-1}) \quad (1)$$

式中 x_t, h_{t-1} 和 y_t 是双向 RNN 的输入、隐藏状态和输出。现在, 剩余连接传递当前时间步长的信息, 因此双向 RNN 的隐藏状态不需要包含当前时间步长的信息。这种连接使隐藏状态不那么拥挤, 并有助于编码文本信息。

1.3 简化的条件流匹配解码器

为了实现对合成语音情感的精准控制, 设计了一种简化的条件流匹配解码器。该解码器基于 Transformer 架构, 能够有效地处理和融合情感与文本特征。解码器首先接收来自情感编码器的情感嵌入向量和文本编码器的文本嵌入向量, 将两者进行拼接融合, 形成包含情感信息的联合特征表示。通过多头注意力机制和前馈网络, 解码器对这些联合特征进行变换和 refinement, 逐步生成语音特征。在生成过程中, 条件流匹配解码器通过引入条件流机制, 使得生成的语音特征能够更好地匹配输入的情感和文本特征, 从而实现了对合成语音情感的精准控制。为了提高解码器的效率和稳定性, 对 Transformer 架构进行了简化和优化, 减少了计算复杂度, 同时保持了模型的表达能力和灵活性。实验结果表明, 该简化的条件流匹配解码器能够在保证语音合成质量的同时, 有效地实现情感控制, 提升合成语音的情感表达能力和自然度。

2 实验结果与分析

2.1 数据集

为了全面验证所提情感语音合成方案的有效性, 所有实验均采用了两个具有代表性的数据集: AISHELL3^[1] 和 EDS^[2]。AISHELL3 数据集在语音领域具有较高的知名度, 尽管其包含的情感语音数量相对较少, 但涵盖了多样化的语音场景和说话风格, 为情感合成研究提供了宝贵的资源。而 EDS 数据集则更具针对性, 包含了 20 名发音人的语音样本, 并且涵盖了五种离散情感(开心、生气、伤心、难过、惊讶), 情感标注清晰且准确, 为情感合成的训练和评估提供了丰富的素材。通过在两个数据集上进行实验, 能够从不同角度评估所提方案在情感表达和语音合成质量方面的表现, 从而更全面地验证其情感合成能力。

2.2 评价标准

为了科学、客观地评估本文所提情感语音合成方案的性能, 从主观和客观两个方面进行了综合评价。主观评价方面, 精心设计并开展了三个平均意见得分(Mean Opinion Score, MOS)测试, 包括相似度平均意见得分(Similarity Mean Opinion Score, SMOS)测试和情感平均意见得分(Emotional Mean Opinion Score, EMOS)测试。SMOS 测试主要关注合成语音与真实语音在语音韵律、音色等方面的相似度, 通过邀请 10 名本地听众对合成语音与真实语音进行对比评分, 评分范围从 1 到 5, 间隔为 0.5 分, 以此来衡量合成语音在自然度和音频质量上与真实语音的接近程度。而 EMOS 测试则专注于评估合成语音所表达情感的准确性和感染力, 同样由 10 名本地听众对合成语音所传达的情感进行打分, 从而判断其情感表达是否自然、到位。客观评价方面, 采用字符错误率(Character Error Rate, CER)这一指标。CER 能够量化地反映合成语音与真实语音在文本内容上的差异, 为评估语音合成的准确性和稳定性提供了有力支持。通过主观和客观评价相结合的方式, 能够全面、准确地评估所提方案在情感合成方面的优势和不足, 为后续的研究改进提供有力依据。

2.3 对比实验

为了进一步凸显所提情感语音合成方案的创新性和优越性, 将该方案与当前领域内两种具有代表性的语音合成模型进行了对比实验。这两种对比模型如下。

VITS2+GST^[3]: 该模型在 VITS2 的基础上引入了全局风格标记(Global Style Token, GST)的方案, 通过提取参考音频中的情感特征, 实现了情感合成能力的提升。在情感表达的多样性和合成语音的自然度方面具有一定的优势, 但在处理复杂情感和保持说话人相似度方面仍存在一定的局限性。

LST-A^[4]: 这是一种基于 Transformer 结构的情感语音合成方案, 利用 Transformer 的强大建模能力和注意力机制, 能够较好地捕捉语音中的情感信息和韵律特征。由于其模型结构相对复杂, 在训练和推理过程中对计算资源的要求较

高,且在某些情感的细腻表达上仍有待改进。

通过在相同的实验条件下,对这三种模型进行对比测试,得到了如表 1 所示的实验结果。从表 1 中可以看出,所提方案在合成流畅度、说话人相似度、情感相似度等多个关键指标上均取得了显著优于对比模型的效果。GRI-TTS 在 MOS, SMOS 和 EMOS 三个主观评价指标上分别达到了 4.14,4.28 和 3.44 的高分,与 VITS2+GST 和 LST-A 相比,分别在 MOS 上高出 0.43 和 0.26,在 SMOS 上高出 0.61 和 0.37,在 EMOS 上高出 0.02 和 0.06。这表明 GRI-TTS 在合成语音的

自然度、韵律流畅度以及情感表达的准确性方面具有明显优势,能够更好地满足实际应用中高质量情感语音合成的需求。在客观指标 CER 上,GRI-TTS 也表现出了较低的错误率,仅为 7.12%,相较于 VITS2+GST 和 LST-A,分别低了 0.11%和 1.22%。这一结果进一步证实了 GRI-TTS 在保持合成语音与真实语音一致性方面的出色性能。通过与现有先进模型的对比实验,所提方案在情感语音合成领域展现出了显著的竞争力和应用潜力。

表 1 情感实验结果

方法	MOS	SMOS	EMOS	CER/%
GRI-TTS	4.14(±0.15)	4.28(±0.15)	3.44(±0.15)	7.12
VITS2+GST	3.71(±0.15)	3.67(±0.15)	3.42(±0.15)	7.23
LST-A	3.88(±0.15)	3.91(±0.15)	3.38(±0.15)	8.34

通过精心设计的实验方案和科学合理的评价标准,所提情感语音合成方案在多个方面均取得了优异的实验结果,充分证明了其在情感表达方面具有更好的性能。

3 结 语

提出了 GRI-TTS 框架,通过引入情感编码器和条件流匹配解码器,获得了更高的情感相似度。然而,研究方法在处理更复杂的情感数据集时可能仍面临挑战,未来的研究可以进一步优化情感编码器的结构,以及探索更高效的训练策略,以提高模型的泛化能力和合成质量。

参考文献:

[1] SHI Y,BU H,XU X,et al. AISHELL-3: A multi speaker mandarin TTS corpus and the baselines [C]// INTER-SPEECH 2021. 2021:2756-2760.

[2] LARSEN A B L,SØNDERBY S K,LAROCHELLE H,et al. Autoencoding beyond pixels using a learned similarity metric[C]//International Conference on Machine Learning. PMLR,2016:1558-1566.

[3] WANG Y,STANTON D,ZHANG Y,et al. Style tokens: Unsupervised style modeling, control and transfer in end-to-end speech synthesis[C]//International Conference on Machine Learning. PMLR, 2018: 5180-5189.

[4] CHEN L W,RUDNICKY A. Fine-grained style control in transformer-based text-to-speech synthesis[C]//ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2022: 7907-7911.

GRI-TTS: Discrete Emotion Control Speech Synthesis Method
Based on Emotion Encoder in Speech Synthesis

HU Po, LUO Hui*

(School of Computer and Control Engineering, Northeast Forestry University, Harbin 150040, China)

Abstract: Recent prompt-based Text-to-Speech (TTS) models can clone unseen speakers using short speech prompts, imitating their style, prosody, and emotion via powerful context learning. However, existing TTS models have shortcomings in diverse styles and prosody changes due to manual or random prompt selection. This paper proposes a Discrete Emotion Control Speech Synthesis method, GRI-TTS, which introduces an emotion encoder to efficiently extract emotion features and a Conditional Flow Matching Decoder to precisely control emotion expression in synthesized speech. This method achieves discrete emotion control in speech synthesis, enhancing emotion diversity and naturalness, and offers new ideas for emotional expression in speech synthesis technology.

Key words: text-to-speech; discrete emotion control; emotion encoder