

中文图书分类号：TN912.33

密 级：公开

UDC：621.3

学 校 代 码：10016



北京建筑大学

BEIJING UNIVERSITY OF CIVIL ENGINEERING AND ARCHITECTURE

硕士专业学位论文

Dissertation for Professional Master's Degree

论 文 题 目：基于深度学习的零样本情感语音合成技术

研究

论 文 作 者：梁世雄

专业类别（领域）：机械

指 导 教 师：周若华、袁庆升

论文提交日期： 2025 年 6 月



北京建筑大学

BEIJING UNIVERSITY OF CIVIL
ENGINEERING AND ARCHITECTURE

学 位 论 文

基于深度学习的零样本情感语音合成技术研究

Zero-Shot Emotional Speech Synthesis Technology Based on Deep Learning

梁世雄

指导教师姓名 周若华 教授 北京建筑大学

袁庆升 高级工程师 国家计算机网络应急处理协调中心

申请学位级别 硕士 学位类别 机械硕士学位

所 属 学 科 机械

年 级 2022 学 号 2108550022025

论文答辩时间 2025 年 6 月

答辩委员会主席 周士弘 研究员

摘要

情感语音合成作为语音合成领域的重要研究方向，旨在赋予合成语音更加丰富与细腻的情感表达能力，从而提升人机交互的自然度与沉浸感。尽管近年来该技术在深度学习的推动下取得了显著进展，但在模型生成能力、情感建模精度以及数据资源支撑等方面仍面临诸多挑战：多数系统仍构建于 FastSpeech、VITS 等相对早期的语音生成架构之上，难以满足高质量语音合成需求；传统基于离散标签的情感建模方式难以充分刻画情感的风格多样性与强度连续性；高质量、大规模情感语音数据集的缺乏亦严重制约了模型性能的进一步提升。针对上述挑战，本文提出了一种基于 F5-TTS 框架的情感可控文本到语音合成模型（Easy-Control Emotion TTS, ECE-TTS），并在此基础上引入情感自适应球面向量（Emotion-Adaptive Spherical Vector, EASV）与情感算术向量（Emotion Arithmetic Vector, EAV）两种机制，分别实现对情感风格与情感强度的连续、可解释调控。此外，构建了一个时长达 200 小时的大规模中文情感语音数据集，为模型训练提供高质量数据支撑。具体研究成果如下：

（1）为解决传统语音合成模型在生成质量与表达能力方面的局限性，本文选用近年来提出的高性能语音合成模型 F5-TTS 作为基础框架，以其在自然度与结构简洁性方面的优势为依托，构建更具表现力的情感语音合成系统。在此基础上，引入情感自适应球面向量机制，实现了从普通语音合成向情感语音合成的有效扩展。EASV 方法通过将 VAD 情感维度映射至球面坐标系，并设计类别中心点以增强风格区分度，从而提升了模型对情感风格的建模精度与控制灵活性。主客观实验表明，ECE-TTS 在 SMOS、NMOS 和 EMOS 三项指标上均取得最高评分（分别为 3.93、3.98 和 3.94），同时在语音识别误差率（WER=13.91）和情感识别相似度（AVD-SIM=0.679）等客观指标上也优于现有方法，全面验证了模型在语音自然度、情感表达准确性与风格控制能力方面的优势。

（2）为简化情感强度控制流程并提升调节效果，本文在模型中引入情感算术向量方法，通过在权重空间内进行向量插值，实现对情感强度的连续、平滑控制。该方法避免了传统排序学习或嵌入空间操作中依赖标签、训练复杂等问题，具备实现便捷、无参考、控制精度高的特点。为验证其有效性，本文以快乐、悲伤和愤怒三类情绪为例，从主观感知评分和声学指标两个角度进行了评估。结果表明，随着强度因子 α 的增大，主观评分呈现显著上升趋势，表现出良好的强度可感知性；VAD 预测得分随 α 增大呈规律变化，说明模型在不同情绪下具备稳定的强度控制能力。此外，频谱分析进一步揭示了音高变化、能量分布等声学特征在不同强度等级下的系统性差异，验证了 EAV 方法在简化建模流程的同时具备良好的调节表现力。

（3）此外，为缓解当前情感语音合成中高质量标注数据稀缺的困境，本文构建了一个时长达 200 小时的大规模中文情感语音数据集。该数据集通过自动标注流程构建，涵

盖多个说话人、多种情感类别与表达风格，显著降低了数据构建成本，同时提升了数据多样性与情感覆盖范围，为模型训练与性能提升提供了坚实支撑。

综上所述，本文提出的 ECE-TTS 模型有效应对了当前情感语音合成面临的关键技术难点，在合成质量、情感表达的精细度与控制灵活性方面均取得了突出成果，为推动情感语音合成技术向更高质量、更强实用性的方向发展提供了可行路径与实践经验。

关键词：情感语音合成；零样本语音合成；情感自适应球面向量；情感算术向量。

Abstract

Emotional speech synthesis is a major research area in text-to-speech (TTS). It aims to add richer and more nuanced emotional expressiveness to synthesised speech, thereby enhancing the naturalness and immersion of human-computer interaction. Although recent advances in deep learning have significantly promoted this field, several key challenges remain unresolved. Most current systems are built on earlier architectures such as FastSpeech and VITS, which limit their ability to generate high-quality speech. In addition, emotion modeling based on discrete labels struggles to represent the diversity and continuity of emotional styles and intensities. The lack of large-scale, high-quality emotional speech datasets also restricts further performance improvement.

To address these challenges, this thesis proposes an emotion-controllable text-to-speech model named Easy-Control Emotion TTS (ECE-TTS), built upon the F5-TTS framework. The model integrates two novel control mechanisms: the Emotion-Adaptive Spherical Vector (EASV) for emotional style and the Emotion Arithmetic Vector (EAV) for emotional intensity, enabling continuous and interpretable emotion modulation. Additionally, a large-scale Chinese emotional speech dataset comprising 200 hours of audio was constructed to provide strong data support for model training. The main contributions of this research are as follows:

(1) In order to address the limitations of conventional TTS models regarding generation quality and expressive capability, this study adopts F5-TTS as the backbone framework. By leveraging its advantages in naturalness and architectural simplicity, this study constructs an expressive emotional speech synthesis system. Built upon this foundation, the EASV mechanism is introduced to enable a smooth transition from neutral to emotionally rich speech synthesis. EASV projects traditional VAD (Valence–Arousal–Dominance) emotional dimensions into a spherical coordinate system and defines class-specific centroids to improve the separability of emotional styles, thereby enhancing the accuracy and controllability of emotional expression. Both subjective and objective evaluations demonstrate that ECE-TTS achieves the highest scores across three perceptual metrics—SMOS (3.93), NMOS (3.98), and EMOS (3.94). Furthermore, it outperforms existing models such as GenerSpeech and EmoSphere++ in terms of Word Error Rate (WER=13.91) and emotional similarity (AVD-SIM=0.679). These results showcase its superiority in naturalness, emotional fidelity, and fine-grained control.

(2) For emotional intensity control, this work proposes the Emotion Arithmetic Vector (EAV) method, which performs vector interpolation within the model’s weight space to achieve smooth and continuous intensity modulation. This approach eliminates the need for ranking-based learning or complex embedding operations, offering a reference-free, easy-to-implement, and highly precise control mechanism. Using “happy,” “sad,” and “angry” as representative categories, the method is evaluated from both perceptual and acoustic perspectives. Results reveal a significant upward trend in subjective scores with increasing intensity factor α ,

demonstrating clear perceptibility of emotional strength. In addition, VAD prediction scores vary consistently across different α values, confirming robust intensity controllability across emotional categories. Spectrogram analysis further supports the method's effectiveness, showing systematic differences in acoustic attributes such as pitch and energy across intensity levels, thereby validating EAV's strength in expressive and fine-grained emotional regulation.

(3) To alleviate the current scarcity of high-quality annotated emotional speech data, this thesis constructs a 200-hour large-scale Chinese emotional speech dataset via an automated annotation pipeline. The dataset covers a wide range of speakers, emotion types, and expressive styles, significantly reducing data collection costs while enriching emotional diversity and coverage. This provides a strong foundation for model training and performance enhancement.

In summary, the proposed ECE-TTS model effectively addresses several core challenges in emotional speech synthesis. It achieves notable improvements in generation quality, emotional expressiveness, and controllability, offering a practical and scalable solution for advancing emotional TTS technologies toward higher quality and broader applicability.

Keywords: Emotional Speech Synthesis, Zero-Shot Speech Synthesis, Emotion-Adaptive Spherical Vector, Emotion Arithmetic Vector.

目 录

第 1 章 绪论.....	1
1.1 课题背景及研究意义.....	1
1.2 国内外研究现状.....	2
1.2.1 语音合成技术研究及发展现状.....	2
1.2.2 情感语音合成技术研究及发展现状.....	4
1.3 论文主要工作.....	7
1.4 论文结构安排.....	8
第 2 章 语音合成的相关理论	11
2.1 语音相关基础.....	11
2.1.1 语音概念	11
2.1.2 分帧与加窗	13
2.1.3 傅里叶变换.....	13
2.1.4 线性谱与梅尔谱	14
2.2 深度学习概述.....	15
2.2.1 卷积神经网络.....	15
2.2.2 循环神经网络.....	16
2.2.3 长短期记忆网络	17
2.2.4 Transformer 模型	18
2.2.5 Diffusion Transformer 模型	20
2.3 基于深度学习的语音合成模型	21
2.3.1 文本分析模块.....	22
2.3.2 声学建模.....	23
2.3.3 声码器.....	24
2.3.4 完全端到端语音合成.....	25
2.4 本章小结.....	25
第 3 章 基于情感自适应球面向量的情感语音合成	27
3.1 基于条件流匹配的语音合成模型	27
3.2 分类器引导与无分类器引导	28
3.3 情感自适应坐标转换.....	29
3.4 模型训练.....	32
3.5 模型推理.....	35
3.6 实验与结果分析.....	38
3.6.1 数据集.....	38
3.6.2 实验环境与模型设置.....	39

3.6.3 评价指标.....	41
3.6.4 结果与分析.....	42
3.7 本章小结.....	45
第4章 基于情感向量的情感强度控制	46
4.1 引言.....	46
4.2 使用情感算数向量控制情感强度	46
4.3 实验与结果分析.....	47
4.3.1 实验设置.....	47
4.3.2 结果与分析.....	48
4.4 情感语音合成系统的设计与实现	51
4.4.1 系统设计.....	52
4.4.2 系统展示.....	54
4.5 本章小结.....	56
结论.....	57
参考文献.....	59

第1章 绪论

1.1 课题背景及研究意义

在数字化与智能化的浪潮中，语音合成（Text to Speech, TTS）技术作为人机交互领域的关键技术之一，正日益展现出其重要性。该技术通过人工合成人类语音，使计算机能够将文本转化为自然的语音输出，从而为人机交互提供了更加直观和便捷的方式。随着深度学习和人工智能技术的飞速发展，TTS 技术取得了显著进步，并广泛应用于智能语音助手、语音导航、虚拟主播、教育辅助等多个领域。近年来，基于深度学习的语音合成模型（如 Tacotron^[1]、FastSpeech^[2]、VITS^[3]、NaturalSpeech^[4]等）的涌现，极大地提升了合成语音的自然度和流畅性，使得机器合成的语音越来越接近人类语音的真实感，为人机交互的进一步发展奠定了技术基础。

传统文本到语音系统长期致力于提升语音输出的清晰度和连贯性，然而这一技术路径仍难以全面反映人类语言的复杂性。作为人际交流的核心载体，语音除传递语义信息外，更承载着丰富的情感内涵——通过韵律特征（包括基频变化、语速调节和能量动态）等超音段特征，说话者能够准确传达情绪状态，实现具有情感温度的人际互动。这种认知推动着情感语音合成（Emotional Speech Synthesis, ESS）发展成为 TTS 领域的前沿课题。正如文献^[5]指出，情感语音合成的技术突破在于结合深度学习结构与神经网络算法，实现对语音中情感特征及其表达模式的有效建模与再现。该研究方向旨在构建多维度的情感表征体系，使模型能够合成具备典型情绪特征（如高兴、悲伤、愤怒、惊讶等）的语音信号。借助这种方法，ESS 有望突破传统 TTS 系统在情感传递方面的局限，构建具备情感认知能力的智能交互系统，推动人机语音沟通向更自然、更具情感表达力的方向发展。

情感语音合成技术在多个领域展现出广泛的应用前景。在智能语音助手中，情感语音合成可以使机器提供更自然和个性化的用户体验，通过调整语调和情感色彩回应不同的情境，从而提升用户的满意度和交互体验。在教育领域，情感语音合成能够通过富有情感的语音提高学习的参与感和记忆效果，尤其适用于语言学习和早期教育，为学生提供更加生动和高效的学习方式。在虚拟主播领域，情感语音合成技术可显著增强语音的表现力与拟人化水平，使虚拟主播在播报、互动等场景中具备更自然、生动的表达效果，从而提升观众的沉浸感与互动体验^[6]。

情感语音合成的研究不仅推动了语音技术本身的革新，也为构建更智能、更人性化的交互系统提供了可行路径。通过赋予机器真实且可控的情感表达能力，该技术正逐步缩小人机之间的交互鸿沟，促进信息传递从“准确”走向“有温度”。随着技术不断成熟与应用场景持续拓展，情感语音合成正迈向表达更复杂状态与更长时间情感行为的目标，不仅能够合成单一情绪片段，还将实现上下文感知与多轮对话中一致、恰当的表达策略，成为智能交互系统中的核心模块^[7]。因此，深入探索情感语音合成不仅具有重要

的学术研究价值，也将在教育、医疗、虚拟人等众多场景中发挥越来越重要的作用，助力人工智能与人类社会的深度融合。

1.2 国内外研究现状

1.2.1 语音合成技术研究及发展现状

语音合成技术的核心目标在于将文本信息转化为可感知的语音信号，是现代人机交互系统中的关键组成部分。自诞生以来，该领域经历了从早期的机械模拟到当代深度学习模型的多阶段演进，不断推动人机语音交互能力的飞跃发展。

早在 18 世纪，科学家便尝试利用机械装置模拟人类的发声机制。进入 20 世纪初，贝尔实验室研制出一款可通过手动控制生成语音的语音操作演示器，虽然具备基本的语音输出功能，但由于设备笨重、发音生硬，实用性有限。20 世纪 70 年代，基于共振峰理论的语音合成方法开始兴起，其通过调节共振峰的频率、带宽等参数，来还原语音音素的声学特性，在音质方面有所突破。然而，该类方法结构复杂、参数依赖性强，难以灵活调整和大规模部署^[8]。随后在 20 世纪 80 年代，波形拼接语音合成技术^[9]开始应用于实际系统。该方法通过从语音数据库中直接选取并拼接已录制的语音波形，以生成连续的语音流。其核心思想是依据文本输入所解析出的上下文信息，从标注良好的语料库中检索匹配的语音单元，并将其依序拼接，构建最终的语音输出。借助上下文信息的引导，该方法在合成语音自然度方面表现较好。拼接语音合成主要有两种实现方式：一种基于线性预测系数 (Linear Predictive Coding, LPC)^[10]，另一种为基于基音同步叠加 (Pitch Synchronous Overlap and Add, PSOLA) 的方法。LPC 方法通过对语音信号进行编码压缩，有效减少存储空间，其解码与拼接过程较为简单。该方法保留了语音的大部分细节信息，因此在生成短语或单词级语音时表现自然。然而，在实际应用中，人类语言的连续性和流畅性难以通过单个语音单元的拼接完全复现，拼接点处常导致听感不连贯的问题。为缓解拼接带来的不连贯问题，PSOLA 方法应运而生。该方法通过调整拼接单元的韵律参数以适应目标上下文，在保持原始语音质量的同时提高了拼接的自然性。然而，PSOLA 依然存在一些局限性。其合成质量对基音周期或起始点极为敏感，容易引入伪影或造成不自然的听感；同时，拼接单元之间的过渡也难以实现完全平滑，仍可能引发语音流畅性的断裂感。这些问题在一定程度上限制了该方法在多样化应用场景中的推广与普及^[11]。

随着拼接合成方法在自然度方面面临瓶颈，自 20 世纪 90 年代起，研究重心逐渐转向统计建模路径，统计参数语音合成 (Statistical Parametric Speech Synthesis, SPSS) 由此成为主流方向。其中最具代表性的是基于隐马尔可夫模型 (Hidden Markov Model, HMM) 的语音建模方法^[12]。统计参数语音合成系统通常由三个模块构成：文本分析模块、参数预测模块以及语音合成模块。其中，文本分析模块负责对输入文本进行预处理，并将其转换为语音合成系统可用的语言特征，如文本规范化^[13]、自动分词^[14]及字素到音素的映射^[15]。这些语言特征通常包括音素、音节、词语和句子级别的结构信息。参数预测模块则根据文本分析模块输出的语言特征，预测出目标语音对应的声学参数；语音合成模块

再以这些声学参数为输入，通过特定的算法生成最终语音波形。

如图 1-1 所示，SPSS 系统整体可划分为训练阶段和合成阶段。在训练阶段，首先从语音数据库中提取基频、声道谱等声学特征，并结合文本分析得到的语言特征，用以训练统计建模模块；在合成阶段，则使用训练好的模型，根据输入文本的语言特征预测目标语音的声学参数，最终由声码器合成出可听语音。尽管 SPSS 具备建模灵活和参数可控的优势，但其存在帧间独立假设和参数平均化等问题，易导致语音连贯性差与过度平滑。系统还依赖复杂的上下文建模与规则性声码器，限制了其在高自然度语音合成中的应用效果。




图 1-1 统计参数语音合成系统结构图

Fig.1-1 Architecture of statistical parametric speech synthesis

进入 21 世纪，随着神经网络的发展，语音合成技术迎来了质的飞跃。2016 年，DeepMind 提出的 WaveNet 模型^[16]首次通过深度自回归卷积网络对音频波形进行建模，在语音自然度和真实感方面取得了革命性成果。然而，WaveNet 的逐点生成特性导致推理速度缓慢，难以应用于实时语音合成场景。为提升合成效率，Google 随后提出了 Tacotron 系列模型，构建了从文本到梅尔频谱的端到端序列建模框架，并结合 WaveNet 作为声码器显著提升了语音质量。Tacotron 结构简洁、可扩展性强，但仍存在推理效率低、韵律建模能力不足以及合成稳定性较差等问题。为进一步提升合成速度与可控性，2019 年出现的 FastSpeech 模型采用非自回归机制，并引入持续时间预测模块，实现高并行、高效率的语音生成。尽管如此，FastSpeech 仍需依赖外部教师模型进行对齐指导，训练流程复杂，且在情感表达与说话人个性建模方面存在不足。2021 年，Kim 等人提出的 VITS 模型首次将变分推理^[17]（Variational Autoencoder, VAE）与生成对抗训练^[18]（Generative Adversarial Network, GAN）机制相结合，打破了传统 TTS 系统依赖梅尔谱作为中间表示的限制，实现了端到端的语音生成。该模型引入了正则化的潜变量建模和随机时长预测器，有效建模了文本到语音之间的一对多映射关系，在语音自然度、韵律表达及多样性方面取得了显著提升。随后，Tan 等人于 2022 年提出的 NaturalSpeech 模型进一步优化了 VAE 结构，通过引入双向先验-后验对齐机制、大规模音素预训练及记忆增强模块，进一步提升了语音的保真度与自然度。然而，尽管上述模型在语音自然度和对齐策略方面取得了显著进展，标志着神经语音合成的阶段性突破，但其合成语音在真实感与表现力上仍与人类语音存在差距，整体质量尚未达到足够细腻的水平。此外，这些方法在情感表达的可控性和丰富性方面依然不足，难以实现对多样化情感风格的精准建模与灵活调节，限制了其在高质量、情感驱动的语音生成任务中的应用潜力。

随着模型架构与训练策略的持续优化，2024 年涌现出一批高性能的端到端语音合

成模型,进一步推动了技术前沿的发展。例如,Wang 等人^[19]提出的 MaskGCT 模型,结合掩码生成机制与语音特征解耦建模策略,在说话人相似度、语音质量和生成稳定性方面均实现了显著提升;而 Chen 等人^[20]提出的 F5-TTS 模型则引入非自回归流匹配机制^[21](Conditional Flow Matching, CFM)与 Diffusion Transformer^[22],消除了对持续时间预测器、外部文本编码器以及音素对齐模块的依赖,在语音表现力和零样本泛化能力方面表现出强大优势,为通用、可控且高质量的语音合成提供了新的实现路径。

1.2.2 情感语音合成技术研究及发展现状

随着文本到语音(Text-to-Speech, TTS)技术的不断演进,现代语音合成系统已具备生成自然流畅、语义准确语音的能力。然而,传统 TTS 系统往往仅关注语音的清晰度与可懂度,难以表达情感色彩,无法有效传达语气、态度等更高层次的语用信息,这使得其在情感交互、虚拟人、个性语音助手等应用场景中表现出明显局限。进一步地,在实际应用中,语音合成系统常常需要应对“零样本”场景,即在没有目标说话人或目标情感语料参与训练的情况下,仍能够生成具有特定风格的语音。这类任务对模型的泛化能力提出了更高要求,也是当前语音生成领域的重要研究方向。具备零样本能力的情感语音合成系统,能够在无需额外微调的前提下实现跨说话人、跨情感的语音生成,从而提升系统在多样化、开放式交互环境中的实用性与扩展性。图 1-2 直观展示了传统 TTS 系统与情感 TTS 系统在合成流程上的关键差异。传统 TTS 系统仅以文本为输入,依赖内部语音建模机制生成中性语音;而情感 TTS 系统则在原有流程基础上引入了“目标情感”作为额外输入条件,在文本分析模块后叠加情感建模路径,使系统能够针对指定情绪进行情感驱动的语音合成,从而合成出带有预期情感表达的语音输出。




图 1-2 普通语音合成与情感语音合成流程对比图

Fig.1-2 Comparison between standard and emotional speech synthesis pipelines

在此背景下,情感控制逐渐成为情感语音合成研究的核心任务之一。具体而言,情感控制主要包括两个维度:其一是情感类别控制,即指导系统合成具备如高兴、悲伤、愤怒等具体情绪类型的语音;其二是情感强度控制,用于调节同一情绪类型下的表达程度,例如轻微悲伤与深度悲痛之间的差异。情感本身具有主观性、模糊性和动态变化等复杂属性,因此如何对其进行精细、连续且稳定的建模与调控,已成为高质量情感语音合成系统实现过程中有待解决的核心技术挑战。

(1) 情感风格控制

早期的情感语音合成技术依赖于一种简单的控制机制:通过为所有可能的情感对独立训练转换系统,推理时只需选择适当的情感对即可。这种方法基本上被使用独热编码表示情感的方法所取代,例如 StarGAN^[23],其中每种情感由一个独热向量表示。对于情感风格的控制,Younggun Lee^[24]等人提出了一种改进的 Tacotron,作为端到端情感语音合成器,它将字符序列和所需的情感作为输入,成功地训练和生成了给定情感标签的语音。这种方法是使用显式的情感标签,如情感类别标签,作为语音合成系统的条件,来指导生成相应情感的语音^[25]。但由于手动标注成本高、数据集规模有限,这种方法合成的语音情感较为单调。这些方法通过联合学习多个情感对,能够更好地处理多对多的映射关系。然而,依赖固定编码的方式远低于成功人机交互应用所需的控制水平。因此,后来的方法转向基于参考的“风格迁移”方法^[26],这些方法受到表达性 TTS 最新进展的启发。

风格迁移的核心思想是通过参考编码器从匹配特定情感风格的短参考音频中提取情感特征编码,并将其迁移至待生成语音中,从而实现对目标语音情感风格的灵活建模与控制。这种方法以数据驱动的方式学习表达风格的潜在表示,能够有效提升合成语音的情感一致性与自然度^[27,28]。Skerry-Ryan 等人^[29]首次提出了利用参考编码器对参考音频的梅尔频谱特征进行编码,并将提取到的嵌入向量作为风格提示传入解码器,从而将参考语音中的韵律风格迁移到目标语音中。然而,该方法中所学习到的嵌入往往包含高度耦合的信息,在风格迁移过程中容易引发控制失效。例如,从女性语音迁移到男性语音时,系统可能产生非预期的音高变化,使得输出听起来像是女性在模仿男性的声音,这种现象显著限制了模型的可解释性与控制精度。为提升风格表示的可控性与解耦性,Wang 等人^[30]提出了全局风格标记(Global Style Tokens, GSTs)机制。他们在参考编码器后引入注意力模块,令编码器输出作为查询,与一组预定义、可学习的风格标记进行注意力聚合操作,最终得到的加权结果再传入解码器作为情感提示。这种结构既增强了模型在风格建模上的灵活性,也使用户能够通过显式调节风格标记的注意力权重来实现连续可控的情感风格调节。在进一步推动风格解耦建模方面,香港中文大学近期提出的 FACodec 框架^[31]提供了新的解决思路。该方法通过将语音特征分解为内容、韵律和声学细节三类子空间,从而实现对语音中不同属性的独立建模。尽管这一框架在提高表达多样性与解耦建模能力方面展现出潜力,但由于韵律编码器仍可能捕捉到部分语音细节,

其输出容易包含与参考音频内容相关的信息，导致最终生成语音更倾向于反映提示语音的原始内容，而非目标文本^[32]。此外，这类基于参考音频的风格迁移方法虽然无需显式的情感标签，具备良好的表达多样性，但面临的主要挑战在于：如何从参考音频中准确提取情感特征，并有效迁移至目标语音，同时避免将非情感因素（如说话人身份、年龄等）一同迁移而导致干扰。当前，如何实现情感与非情感信息的有效解耦，并确保风格迁移过程的稳定性与可控性，仍是该方向的关键难点之一。

针对基于参考音频的风格迁移方法在控制精度与信息解耦方面所面临的挑战，研究者开始尝试摆脱对离散标签或显式参考的依赖，转而探索基于连续空间的情感建模机制，以提升风格控制的精细度与灵活性。其中，Russell^[33]提出的情感环状模型为该方向提供了理论基础。该模型将情感状态映射到由效价（Valence）、唤醒度（Arousal）和支配度（Dominance）三个连续维度构成的三维空间中，从而使复杂情绪状态可被数值化表达。具体而言，唤醒度衡量情绪的激活水平，从平静到兴奋逐级递增；效价反映情绪的正负极性，从积极（如愉快）到消极（如悲伤）连续分布；而支配度则描述说话人对交流情境的控制感，例如自豪对应高支配度，恐惧则体现低支配度。相比传统的离散标签方式，使用 VAD 三维情感空间不仅具有更强的表达能力，还可通过情感识别模型^[34]自动提取，从而减少对人工标注的依赖。在此基础上，近期有研究进一步提出了情感自适应坐标变换方法，将 VAD 表示映射为球面向量形式，即情感自适应球面向量^[35]（Emotion-Adaptive Spherical Vector, EASV）。该方法通过构建球面坐标系以捕捉不同情绪类别在空间中的分布差异，使模型能够基于向量方向实现对语音情感风格的连续、可解释控制。此外，该研究还引入基于分位数的长度归一化机制，以增强模型对不同情感类型在分布结构上的适应能力。实验结果表明，EASV 表示不仅提升了语音情感表达的自然性与多样性，也显著增强了系统在情感变化调节过程中的可控性。

（2）情感强度控制

情感强度控制是情感语音合成中的另一个关键方面。相较于情绪类别的选择，情感强度关注的是情绪表达的程度，即如何在“同一种”情绪下实现从微弱到强烈的自然过渡。近年来的研究指出，情感并非以孤立的离散状态存在，而是分布于连续的维度空间中，具有可调节、可过渡的性质^[36]。因此，在连续尺度上实现情感强度的建模与控制，已成为情感语音合成研究中的重要课题之一。然而，与离散情感标签的建模相比，情感强度建模起步相对较晚，当前仍处于探索阶段，尚存诸多挑战。

在早期工作中，研究者主要依赖人工标注的方式对情感强度进行建模。例如，Lorenzo-Trueba^[37]等人率先在深度学习框架下引入相对强度标签，通过比较表演者应表达的预期情感与评估者实际感知情感之间的偏差，生成可连续调节的情感权重向量。随后，Choi 和 Hahn^[38]也提出了类似策略，允许用户在推理阶段手动设置连续情感向量，以调节合成语音的情感表达强度。尽管这些方法实现原理相对简单、结构清晰，但高度依赖高质量标注数据，并且在实际应用中，由于手动调节缺乏一致性和自动化支持，使

用效率与可重复性存在明显不足。为了提升强度估计的自动化水平,有研究开始尝试引入情感识别系统(Speech Emotion Recognition, SER)作为辅助模块。例如, Schnell 和 Garner^[39]提出利用 SER 系统生成的显著性图来引导帧级情感强度调节; Zhang 等人^[40]则直接将 SER 输出的后验概率用作句子层面的情感强度控制因子。尽管此类方法一定程度上减轻了对人工标签的依赖,但其核心性能极大地受限于 SER 模型本身的泛化能力,尤其在面对跨说话人或跨场景迁移时,稳定性和准确性仍难以保障。此外,由于 SER 输出并不一定与真实感知的强度水平完全一致,使用这类模型作为强度估计依据还存在潜在的错误引导风险。

为进一步提升情感强度建模的鲁棒性,部分研究尝试从排序学习的角度出发,捕捉情感强度的序数性特征。Zhou 等人^[41]和 Lei 等人^[42]分别提出通过构造情感与中性之间、或不同强度等级情感之间的配对关系,引入排序监督信号,并近似求解最大边际优化问题,从而学习情感强度排序函数,并在 $[0,1]$ 区间内构建连续的强度权重分布。这种方法有效缓解了对精确强度标签的依赖,但由于其推理阶段仍需依赖排序函数或特征对齐机制,整体部署复杂度仍有待优化。最近, Kalyan 等人^[43]提出的情感算术向量方法,为情感强度建模提供了全新的思路。该方法在共享的 TTS 模型架构下,针对不同目标情感分别进行微调,以获得相对于中性情感的“增量向量”,并将其作为该情绪类别的强度方向向量。在推理阶段,通过对该向量的幅度进行缩放,即可实现对同一情感类别下不同强度水平的连续调节。该方法具备直观的参数控制机制和良好的可解释性,同时具有较强的可迁移性,无需依赖复杂的排序函数或外部感知模块。

综上所述,情感强度控制作为 ESS 研究的重要方向,近年来已取得初步进展,相关方法各具优势。然而,现有技术仍面临调节机制复杂或鲁棒性不足等问题。情感算术向量方法以其直观的建模思路、灵活的控制手段和较低的部署成本,成为该领域的一项具有代表性的最新成果,为后续实现更自然、稳定且可控的情感强度调节提供了有力支持。

1.3 论文主要工作

本文的研究内容是基于深度学习的情感语音合成的研究与应用,首先回顾了语音合成与情感语音合成的背景与国内外的发展历程和现状,尽管情感语音合成技术近年来取得了显著进展,但在情感控制方面仍面临诸多挑战,主要由于现有模型的局限性、人类情感本身的复杂性(包括情感风格和强度),以及缺乏足够的情感数据集。针对以上问题,本文将展开以下核心工作:

(1) 系统梳理并分析了当前主流的语音合成模型,包括端到端的 NaturalSpeech 系列、结合变分推理与对抗训练机制的 VITS,以及近年来提出的 MaskGCT 和 F5-TTS。综合比较其在合成质量、情感控制能力与模型复杂度等方面的表现,最终选取结构简洁、性能优异的 F5-TTS 作为技术基础,构建情感可控文本到语音合成模型(Easy-Control Emotion TTS, ECE-TTS)。该模型保留了 F5-TTS 中条件流匹配与扩散变换器的核心优势,去除音素级时长预测与显式对齐模块,显著降低了对精确标注数据的依赖,并实现

了用户可灵活设定情绪目标的零样本语音合成,有效提升了语音的自然度与情感表达准确性。

(2)为解决情感风格控制粒度粗、表达不自然等问题,本文引入情感自适应球面向量作为风格建模手段,实现了连续、细粒度且可解释的风格控制机制。相较于传统离散标签驱动和风格迁移方法,EASV在表达的多样性、稳定性及控制精度方面均展现出明显优势。

(3)在情感强度控制方面,本文进一步采用情感算术向量方法。该方法通过权重空间插值技术,在共享的语音合成模型基础上实现对情感强度的连续、平滑调节,避免了传统基于排序或情感嵌入空间操作方法的复杂性与不稳定性,实现了灵活、可解释且高效的情感强度控制。

(4)为解决现有情感数据集规模小、标注成本高等问题,本文构建了一个高质量的200小时情感语音数据集。数据集的构建采用自动情感标注流程,有效降低了人工成本,显著提高了数据规模和情感多样性,为模型训练提供了坚实的数据基础。

综上所述,本文在全面分析当前情感语音合成技术的基础上,提出了一种以F5-TTS为核心架构的改进型情感语音合成模型ECE-TTS。该模型结合条件流匹配、DiT、情感自适应坐标风格控制与情感算术向量调节机制,显著提升了情感表达的自然性与可控性。通过系统性实验验证,本文所提出的方法在语音合成质量与情感控制精度方面表现出显著优势,为构建高质量、实用化的情感语音合成系统提供了有效支撑。

1.4 论文结构安排

本文共有5个章节,对情感语音合成技术进行了研究,主要研究内容与组织结构如图1-3所示,各章节主要内容如下:

第1章为绪论,介绍了情感语音合成技术的研究背景与意义。从数字化与智能化时代背景出发,分析了语音合成技术在人机交互中的重要性,并进一步指出情感语音合成技术对于提升人机交互自然性与情感体验的关键作用。在综述国内外语音合成与情感语音合成领域的发展历程与研究现状基础上,明确当前存在的主要问题和技術挑战,进而提出了本文的研究目标、研究内容与创新点。

第2章为语音合成相关理论基础。本章从语音信号处理的基本理论入手,系统介绍了语音信号的时频域特性及相关处理方法。回顾并总结近年来基于深度学习的主流语音合成模型(如卷积神经网络、循环神经网络、Transformer和Diffusion Transformer模型等)的结构特征、适用场景和技术发展趋势,为后续的模型设计提供坚实的理论支撑。

第3章情感易控语音合成模型的设计与实现。以先进的F5-TTS为基础框架,提出一种基于情感自适应球面向量的情感风格控制方法,实现从普通语音合成向情感语音合成的转变。详细阐述了模型的整体结构与技术路线,包括条件流匹配语音合成机制、情感自适应坐标向量的转换设计,以及模型的训练与推理流程。进一步描述了数据集的构建方法、实验环境的配置及评估指标的选取,通过主客观评测结果验证了所提出方法在

情感风格建模和控制上的有效性与优势。

第4章基于情感算术向量的情感强度控制。针对情感强度调控步骤繁琐且难以精准控制的问题，引入情感算术向量方法，通过在权重空间中进行向量插值实现了对情感强度的连续、平滑、高精度调节。阐明该方法的基本原理与具体实现过程，并通过主观评分和客观声学特征分析，验证了该方法在快乐、悲伤和愤怒等典型情绪上的控制有效性。此外，本章还搭建了基于 Gradio 的情感语音合成交互系统，展示了所提出模型在实际应用中的可行性。

第5章为结论。归纳和总结全文的主要研究成果，指出研究中存在的不足之处，并提出了未来进一步的研究方向和可优化的技术路线。




图 1-3 论文内容与组织结构
Fig.1-3 Thesis content and organization

第 2 章 语音合成的相关理论

语音合成作为语音生成领域的重要研究方向，融合了语音信号处理、语言学以及深度学习等多学科知识。为支撑后续情感语音合成系统的建模与实现，本章围绕语音合成的基础理论与关键技术模块进行系统梳理，构建起从信号层面到建模机制的理论体系。章节内容包括语音的基本特性、发音原理及其时频域分析方法，为后续模型理解语音结构与感知特性提供信号层基础。在此基础上，重点介绍典型深度学习模型的结构特点与建模优势，如卷积神经网络、循环神经网络、Transformer 以及 Diffusion Transformer，并结合文本处理、声学建模与声码器等核心模块，梳理当前主流深度学习语音合成系统的整体架构及技术演进方向。本章内容不仅有助于理解语音合成模型的构建逻辑，也为后文提出的情感可控语音合成模型的设计提供理论支撑与方法基础。

2.1 语音相关基础

2.1.1 语音概念

人类通过发音器官产生语音，以承载和传递语言信息，实现有目的的交流行为。如图 2-1 所示，肺部、气管、喉部、声门、口腔和鼻腔等共同构成了声音生成与传播的路径。气流由肺部推动，经声带振动形成周期性脉冲气流，之后在上声道的共鸣作用下被调制为不同的语音信号。由于个体声带形态存在差异，每个人的声音在音色上呈现出独特的个性特征^[44]。




图 2-1 发音器官示意图

Fig.2-1 Diagram of human speech organs

在汉语语音中，音素主要包括元音和辅音。元音具有显著的共振峰，频率通常集中在 1000Hz 以下，利用 2 至 3 个共振峰便可实现区分^[45]。男性说话时的共振峰频率普遍

低于女性和儿童约 20%，但其频谱包络在频率轴平移后仍具有高度相似性。辅音则可分为清辅音和浊辅音。清辅音中摩擦噪声成分占比较大，频谱特性相对平滑，能量分布较弱，因而易受背景噪声干扰；而浊辅音通常呈现出能量集中的线谱结构^[46]。

从时域角度来看，语音信号表现出明显的不连续性与稀疏性，其能量在不同时间点的分布高度不均衡。在频域中，语音能量主要集中于基频、倍频以及共振峰等特定频率位置，其余频点的能量则趋近于零，呈现出整体性的非均匀分布特性^[47]。尤其在浊音段，频谱能量更加集中，主要聚焦于说话人的基频及其倍频分量，反映出个体音色的显著差异^[48]。理论上，除了这些关键频带外，其他频点的能量几乎可以忽略不计，大多数频率成分在频谱中接近零值^[49]。

在描述语音时，通常涉及四个主观感知维度：响度（loudness）、音调（pitch）、音色（timbre）和主观持续时间。

（1）响度

响度表示声音的强弱，主要由声波的振幅决定，同时也受频率影响。响度以“宋”（sone）为单位，参考标准为 1000Hz、40dB 的纯音。个体感知上，响度会因性别、年龄等差异而有所变化，中频的纯音往往被感知为比低频或高频更响。

（2）音调

音调受频率主导，同时也与声压相关。频率越高，对应的音调越高。人耳可分辨极小频率差异，2Hz 的频率变化即可被察觉。对于复音而言，其音调主要由基频决定，基频的变化直接影响音调感知。

（3）音色

音色反映声音的主观质量，与发音系统结构密切相关。不同个体的口腔、鼻腔、喉部等结构差异决定了其谐波与共振特性的不同，从而赋予每个人独特的声音风格。音色无法通过单一物理量度量，需在多维特征空间中进行建模，例如频谱构型、谐波分布和时域结构等综合要素。

（4）主观持续时间

主观持续时间即听觉系统对声音时长的感知，受到语种、语境和频率的影响较大。在短音节中尤为明显。研究表明，高频声音需较长的实际持续时间以获得与低频相似的主观时长，类似“等响曲线”概念中所提出的“等时长曲线”。其中，响度和音调可视为一维属性，音色则需借助多维空间表达。

尽管语音信号在整体上呈非平稳性，其统计特性不断随时间变化，但在 10 至 30ms 的时间范围内，通常可视为近近平稳过程。该时间尺度为短时傅里叶分析提供了理论基础，使得语音信号可通过分帧后提取频谱特征，广泛应用于语音识别、合成及增强等任务中。尽管变换系数理论上服从近似高斯分布，在实际操作中依然展现出良好的建模能力，是当前语音信号处理的核心工具之一^[50]。

2.1.2 分帧与加窗

语音信号在短时内可被视为平稳信号，因此常将其划分为若干帧段，每段称为一帧，帧长一般设定在 10~30 毫秒之间。为避免边界信息损失，常采用帧间重叠处理，使相邻帧之间平滑过渡，降低不连续性带来的频谱泄露问题^[51]。

在实际处理中，分帧后需对每帧语音加窗，利用窗函数完成信号的平滑截断，抑制频谱旁瓣泄露。常用窗函数包括汉宁窗、汉明窗和矩形窗，其定义如下。

$$W(n) = 0.5 \left[1 - \cos \left(\frac{2\pi n}{N-1} \right) \right], 0 \leq n \leq N-1 \quad (2-1)$$

$$W(n) = 0.54 - 0.46 \cos \left(\frac{2\pi n}{N-1} \right), 0 \leq n \leq N-1 \quad (2-2)$$

$$W(n) = 1 \quad (2-3)$$

其中， $W(n)$ 表示窗口系数， N 为窗口长度。选择合适窗型有助于在时域截断的同时保留更多有效频谱特征，提高后续特征提取与建模效果。

2.1.3 傅里叶变换




图 2-2 语音信号的短时傅里叶变换声谱图

Fig.2-2 Spectrogram of a speech signal obtained by Short-Time Fourier Transform

傅里叶变换是一种将时域信号转换为频域表示的重要数学工具，能够将信号分解为若干具有不同频率的正弦和余弦波。该方法广泛应用于音频处理、图像分析与通信等领域，特别适用于分析语音中包含的频率信息。通过傅里叶变换，可以揭示语音信号中各频率成分的能量分布，有助于理解其频谱特征。

对于任意连续时间信号 $f(t)$ ，其傅立叶变换 $F(\omega)$ 可以表示为：

$$F(\omega) = \int_{-\infty}^{\infty} f(t) e^{-i\omega t} dt \quad (2-4)$$

其中， $X(t, f)$ 是信号在时间 t 和频率 f 上的二维函数， $x(\tau)$ 是输入信号， $\omega(\tau-t)$ 是窗口函数， $e^{-j2\pi f\tau}$ 是复指数项。

在语音处理中，由于语音信号具有非平稳特性，需采用短时傅里叶变换（Short-Time Fourier Transform, STFT）对其进行时频联合分析。STFT 能够展现语音信号的频率随时

间的动态变化，常通过声谱图可视化，如图 2-2 所示。该图横轴为时间，纵轴为频率，颜色或亮度则表示每个时频点的能量强度。除了频谱分析，傅里叶变换也在滤波、特征提取等语音信号处理环节中发挥着关键作用。

2.1.4 线性谱与梅尔谱

在两阶段语音建模方案中，声学特征常作为中间表示，用于桥接声学模型与声码器。线性谱是最常见的声学特征之一，广泛应用于语音处理、音频分析、通信系统及雷达信号处理等领域。通过线性谱，可以揭示信号中各个频率分量的能量分布，有助于分析语音在不同频率区间的构成特性。语音信号经预处理（如分帧、加窗）并通过短时傅里叶变换后，可得到其线性谱表示。然而，考虑到人耳听觉系统对不同频率敏感程度的不平衡性，通常会将线性频率转换为更符合感知特性的梅尔刻度。其频率映射关系如下所示：

$$F_{\text{mel}} = 2595 \times \log_{10} \left(1 + \frac{f}{700} \right) \quad (2-5)$$

其中， f 为线性频率， F_{mel} 为对应的梅尔频率值。

梅尔刻度依据人类听觉对低频更敏感、高频相对不敏感的感知规律进行设计。其频率间隔为非线性分布——低频段间隔较宽，高频段则相对密集，更能贴近听觉感知机制。因此，梅尔频率尺度在语音识别与合成领域得到了广泛应用。图 2-3 展示了一段语音信号对应的梅尔频谱图。




图 2-3 语音信号的梅尔频谱图

Fig.2-3 Mel spectrogram of a speech signal

如图 2-4 所示，语音信号的梅尔频率特征提取流程通常包括以下步骤：首先进行预加重，以提升高频成分并增强信噪比；随后，信号被分帧加窗以满足短时平稳性假设；再通过短时傅里叶变换将帧级信号转换到频域，获得其功率谱。接着，使用在梅尔尺度上等间距分布的梅尔滤波器组对功率谱进行加权累积，生成梅尔频谱。这一过程有效压缩了原始频谱的高维信息，同时突出了语音中与人类听觉相关的重要频率分量。该频谱随后经过对数压缩与离散余弦变换（Discrete Cosine Transform, DCT）处理，最终得到维度更紧凑、具有良好判别性的梅尔频率倒谱系数（Mel-Frequency

Cepstral Coefficients, MFCC)。值得注意的是,若省略 DCT 步骤,则对数梅尔谱即可作为 Fbank 特征直接输入神经网络进行建模,该表示形式已成为近年来深度学习 TTS 模型中的主流输入特征之一。此外,功率谱本身也常用于生成语谱图,用于展示语音在时间与频率两个维度上的结构演变过程,为语音分析与可视化提供直观支持。




图 2-4 梅尔频率倒谱系数与对数梅尔谱的特征提取流程图

Fig.2-4 Feature extraction process of Mel-frequency cepstral coefficients and log-Mel spectrogram

2.2 深度学习概述

2.2.1 卷积神经网络

卷积神经网络 (Convolutional Neural Network, CNN) 由 Yann LeCun^[52]于 20 世纪 90 年代提出。然而受限于早期的数据和计算资源,该结构未能广泛应用。随着深度学习的发展和硬件能力提升, CNN 架构不断演进并趋于成熟,成为当前最常用、性能优越的神经网络之一,广泛应用于计算机视觉、自然语言处理、语音识别及语音合成等多个领域。作为一种典型的深层前馈神经网络, CNN 通常由输入层、多个隐藏层以及输出层组成,其基本结构如图 2-5 所示。

在卷积神经网络中,除输入与输出层外,其余层统称为隐藏层,卷积和池化操作是隐藏层的核心组成。卷积层作为 CNN 的关键模块,由多个可学习的滤波器(卷积核)构成,这些滤波器在输入特征图上滑动,并通过点乘计算提取局部特征。该过程使得网络能自动从原始数据中捕捉空间结构信息,实现有效的特征建模。

池化层则用于对卷积层提取的特征图进行下采样,从而减少特征维度和模型计算量,缓解过拟合风险并提升运行效率。常见的池化方式包括最大池化与平均池化:前者取窗口内最大值以保留显著特征,后者则取均值,反映局部整体趋势。这些策略增强了模型对微小扰动的鲁棒性及其对位置变化的不变性。

激活函数通常嵌于卷积层或全连接层之后，用于引入非线性，使模型具备拟合复杂数据分布的能力。常见的激活函数有修正线性单元(Rectified Linear Unit, ReLU)、Sigmoid和双曲正切(Tanh)，其表达式分别为：

$$\text{ReLU}(x) = \max(0, x) \quad (2-6)$$

$$\text{Sigmoid}(x) = \frac{1}{1+e^{-x}} \quad (2-7)$$

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-8)$$

全连接层通常位于神经网络的末端，其主要作用是将卷积或池化层提取的高维特征展平为一维向量，并通过线性变换生成最终输出结果。该层通过密集连接整合局部与全局特征，完成从特征空间到任务空间（如分类或回归）的映射。在全连接过程中，神经元间的全连接结构使模型能够捕捉特征之间的复杂关系，提升整体判别能力。尽管计算量较大，但配合激活函数与正则化策略，全连接层在增强非线性表达和控制过拟合方面表现出良好效果，是完成最终预测的关键组件。




图 2-5 卷积神经网络结构示意图

Fig.2-5 Convolutional neural network architecture

整体来看，CNN 通过局部感受野与参数共享机制，在有效提取空间局部模式的同时大幅减少参数数量，广泛应用于图像处理、语音识别与语音合成等任务。在语音任务中，卷积层用于提取时频特征，池化层提供降维能力，激活函数提升表达能力，全连接层输出预测结果。然而，CNN 对长程依赖建模能力有限，因此常与循环网络、注意力机制等结构结合，以提升对变长序列的处理能力。

2.2.2 循环神经网络

循环神经网络^[53] (Recurrent Neural Networks, RNN) 是一类专为处理序列数据而设计的神经网络架构。与传统的前馈神经网络不同，RNN 在时间维度上具备“状态记忆的能力”，能够捕捉输入数据之间的时序依赖关系，因此在自然语言处理、语音识别和时间序列分析等领域得到了广泛应用。

RNN 的核心机制在于其递归的结构设计：每一个时间步的网络状态不仅受当前输

入的影响，还会受到上一时刻隐藏状态的作用。具体来说，当前时间步的隐藏状态由前一状态与当前输入共同决定，并用于生成当前输出。这种递归连接使得 RNN 能够处理变长序列，并在时间维度上传递上下文信息。模型训练时通常将所有时间步的误差进行累计，通过反向传播算法统一优化网络参数。图 2-6 展示了典型 RNN 的结构，左侧图为其基本单元，其中 x 表示当前输入， s 为隐藏状态， o 为输出。 U 、 V 、 W 分别为输入到隐藏层、隐藏到输出层、前一状态到当前状态的权重矩阵。右侧图展示了将网络在时间轴上展开后的结构。其前向传播的基本计算过程如下：

$$S_t = f(UX_t + WS_{t-1} + b) \quad (2-9)$$

$$O_t = g(VS_t + c) \quad (2-10)$$

其中， f 和 g 都是激活函数， X_t 为第 t 个时间步的输入， S_t 表示第 t 个时间步的隐藏状态， O_t 为对应的输出， b 和 c 分别是隐藏层和输出层的偏置项。




图 2-6 循环神经网络结构示意图

Fig.2-6 Recurrent neural network architecture

尽管 RNN 在处理短期依赖序列方面表现良好，但在面对较长输入序列时，往往面临梯度消失或爆炸的问题，严重影响模型对长程依赖的学习能力。为应对这一挑战，研究者先后提出了长短期记忆网络^[54]（Long Short-Term Memory, LSTM）和门控循环单元^[55]（Gated Recurrent Unit, GRU）等改进结构。它们通过引入门控机制，有效调控信息的存储与更新，从而显著提升了模型在捕捉长期依赖信息方面的表现，同时缓解了原始 RNN 架构在训练过程中出现的不稳定性问题。

2.2.3 长短期记忆网络

长短期记忆网络最初由 Hochreiter 等人提出，旨在解决传统循环神经网络在处理长序列数据时容易出现的梯度消失与梯度爆炸等问题。作为 RNN 的一种变体，LSTM 通过引入门控机制，实现对信息流的精细控制，从而具备更强的建模长期依赖能力，广泛应用于语音识别、自然语言处理等序列学习任务中。

如图 2-7 所示，LSTM 网络由多个基本单元（LSTM Unit）构成，每个单元包括三个核心门控结构：遗忘门、输入门和输出门，以及一个用于存储和传递历史信息的细胞状

态。在每个时间步中，遗忘门通过 Sigmoid 激活函数计算出一个控制系数，用于调节前一时刻细胞状态中应保留的信息比例；输入门则决定当前输入信息的写入程度，并与通过 Tanh 激活函数生成的候选状态共同参与细胞状态的更新。细胞状态在遗忘门与输入门的协同作用下完成当前时刻的状态更新，而输出门则基于更新后的细胞状态控制当前的输出幅度，并结合 Tanh 激活函数生成新的隐藏状态，从而实现对长时序依赖信息的有效建模。




图 2-7 长短期记忆网络结构图

Fig.2-7 Structure of a LSTM unit

与传统 RNN 相比，LSTM 更善于保留长距离的上下文信息，能够显著缓解训练过程中梯度衰减问题，在长序列任务中具有更稳定的建模性能。然而，LSTM 结构中引入多个门控机制，导致参数量大幅增加，相应地提升了训练与推理的计算复杂度。因此，在对计算资源或响应速度要求较高的应用场景，如实时语音处理和大规模文本生成中，LSTM 的效率问题仍是实际部署时的重要考量因素。

2.2.4 Transformer 模型

Transformer^[56]是由 Vaswani 等人于 2017 年提出的一种基于自注意力机制（Self-Attention Mechanism）的神经网络架构，最初被广泛应用于自然语言处理任务，如机器翻译、文本分类和语音识别等。与传统依赖序列结构建模的 RNN 或 CNN 不同，Transformer 完全摒弃了循环与卷积结构，核心依赖自注意力机制以实现输入与输出表示的建模。相较于早期基于注意力机制的 Seq2Seq 模型，Transformer 采用的多头自注意力机制在捕捉序列中的长距离依赖与信息丰富度方面更具优势，因此在序列建模任务中展现出更为卓越的性能^[57]。

如图 2-8 所示，Transformer 采用经典的编码器-解码器（Encoder-Decoder）结构。其

编码器部分由若干结构相同的层堆叠而成，每层主要包含两个子模块：多头注意力机制（Multi-Head Attention）和前馈神经网络（Feed-Forward Network）。每个子模块均配备残差连接（Residual Connection）与层归一化^[58]（Layer Normalization）操作，以提升训练稳定性与收敛速度。编码器的主要任务是将输入序列映射至高维的上下文向量表示，以提取丰富的语义信息。解码器结构在此基础上进行了扩展，同样由多个解码层构成，每层包含三个子模块：掩码多头注意力模块、编码器-解码器注意力模块和前馈神经网络模块。其中，掩码多头注意力机制用于确保解码器在每一时间步仅访问当前及其之前的位置信息，防止信息泄漏，从而实现自回归的序列生成过程。解码器通过迭代方式逐步生成目标序列，并在每一步中基于已生成的内容及编码器输出进行预测。


图 2-8 Transformer 模型结构图^[56]

Fig.2-8 Architecture of the transformer model

Transformer 架构的核心优势在于其自注意力机制。该机制通过构造查询（Query）、键（Key）和值（Value）三组向量，并计算查询与各键之间的相似度，以获得注意力权重，进而对值进行加权求和生成输出表示。该操作使模型在生成每个位置的表示时能够参考整个输入序列的信息，从而捕捉到全局依赖关系。为增强模型表达能力，Transformer 并行设置多个注意力头，每个头学习不同的子空间特征，最终拼接融合为综合表示。由

于自注意力机制不具备自然的位置信息感知能力，Transformer 通过位置编码（Positional Encoding）策略引入顺序信息。该编码形式通常为可学习或基于正余弦函数的固定向量，直接加至输入嵌入中，以显式提供序列顺序信息。

凭借其优越的建模能力、结构的高度并行性及良好的可扩展性，Transformer 架构已成为自然语言处理领域的主流模型，并逐步拓展至语音合成等任务。例如，在语音合成方向，Transformer TTS^[59]作为代表性模型，在音频序列建模任务中展现出优异性能，进一步验证了 Transformer 架构在语音生成方面的广泛适用性与发展潜力。

2.2.5 Diffusion Transformer 模型

Diffusion Transformer(DiT)是一种结合了扩散模型和 Transformer 架构的生成模型，其核心思想是用 Transformer 替代传统扩散模型中的 U-Net^[60]架构，利用 Transformer 的全局建模能力提升生成质量与扩展性。DiT 在潜空间中操作，通过变分自编码器（VAE）将高维图像压缩为低维特征，从而降低计算复杂度。




图 2-9 DiT 模型的输入规范图^[22]

Fig.2-9 Input specifications of the DiT model

Diffusion Transformer 的设计初衷是将 Transformer 架构引入扩散模型，以替代传统的 U-Net 作为生成任务的主干网络，从而提高模型的扩展性和计算效率。扩散模型的基本思想是通过逐步向数据添加噪声，并学习反向去噪过程，以实现高质量的生成任务。DiT 在这一框架下，用 Transformer 处理扩散过程的潜在表征，而非传统的 CNN 结构，使其具备更强的可扩展性和计算效率。

DiT 的核心原理在于将 Transformer 的自注意力机制引入扩散模型的反向去噪过程中，以增强模型的全局建模能力和上下文感知能力。如图 2-9 所示，其输入数据首先通过“Patchify”操作被分解为多个小块（patch），每个 patch 被视作一个 token，依次输入至 Transformer 模型中进行序列建模。DiT 借鉴了 Vision Transformer^[61]（ViT）的基础架

构,并针对扩散生成任务进行了多项结构优化,主要包括自适应层归一化(Adaptive Layer Normalization, AdaLN)、交叉注意力机制(Cross-Attention)以及 in-context 条件控制策略。其中,adaLN-Zero 机制通过将调节分支参数初始化为零,有效缓解了条件扰动对模型初期训练带来的不稳定性,进而加速了模型收敛过程。图 2-10 进一步展示了上述结构优化在 DiT 模块中的具体实现方式,分别对应基础的 adaLN-Zero 模块、集成交叉注意力的扩展结构,以及融合 in-context 条件注入机制的建模框架。




图 2-10 DiT 模型整体架构与模块变体示意图^[22]

Fig.2-10 Overview of the DiT architecture and variants of DiT blocks

Transformer 由于其自注意力机制,虽然在自然语言处理任务中表现出色,但在图像生成等任务中的应用受限于计算复杂度和序列长度扩展问题。传统扩散模型依赖于 U-Net 作为主干网络,而 U-Net 采用卷积神经网络架构,使其在图像任务上具有先验优势,但却在扩展性和计算效率方面存在局限。DiT 通过采用 Transformer 取代 U-Net,弥补了 U-Net 在大规模训练下的局限性,使扩散模型能够继承 Transformer 在可扩展性上的优势,同时保持较低的计算开销。实验表明,DiT 在计算复杂度和生成质量之间呈现出良好的线性关系,即随着计算资源的增加,生成效果显著提升。

在语音合成任务中,DiT 具有潜在的应用前景。扩散模型已被证明能够用于高质量的语音生成,而 Transformer 在建模长序列数据方面具有天然的优势。因此,DiT 可以用于语音合成模型,以增强音质、控制发音风格,并提高生成效率。相较于传统的基于 CNN 或 RNN 的扩散模型,DiT 可能在长时间依赖关系建模和多模态(如文本-语音对齐)任务中表现更优。

2.3 基于深度学习的语音合成模型

图 2-11 展示了基于深度学习的语音合成模型的演化路径,从最早的传统三阶段系统(文本分析、声学模型、声码器)出发,逐步发展出弱前端系统、直接声码器建模系统,以及采用梅尔频谱图作为中间表示的两阶段系统,最终演进为完全端到端的神经语音合成架构。随着对语音自然度与可控性要求的提升,研究重心不断由规则工程向数据驱动

过渡。梅尔频谱建模方案在语音质量与训练稳定性之间取得了良好平衡，而端到端模型则通过统一建模框架简化了系统结构，显著增强了泛化能力。不同结构在输入形式、特征建模方式及语音输出机制上各有侧重，体现了语音合成系统在准确性、简化性与效率之间不断权衡与优化的过程，也反映了对语音建模本质理解的逐步深化。




图 2-11 基于深度学习的语音合成模型发展演化示意图

Fig.2-11 Evolution of Deep Learning-based Speech Synthesis Models

2.3.1 文本分析模块

在传统的文本到语音系统中，文本处理模块通常被称为“前端”，主要负责将原始文本转化为适合声学建模的语言特征。一个典型的文本处理模块通常包括以下几个步骤：

（1）文本规范化。文本规范化旨在将原始文本中的非标准词（如数字、缩写等）转换为其对应的口语表达形式。例如，“1989”应被转换为“nineteen eighty-nine”，“Mr.”则转换为“Mister”。当一个符号词可能存在多种发音方式时，规范化的上下文判断尤为重要。例如，“3 lb”可读作“three lb”或“three pounds”^[62]，“345 Tilak Marg”既可读作“Three hundred and forty-five Tilak Marg”，也可按地址场景表达为“Three forty-five Tilak Marg”。这类书写形式与发音形式不一致的词统称为符号词，包括日期、时间、数字和金额等。

（2）词性标注。该步骤为文本中的每个单词分配对应的词性标签，有助于更准确地进行字素到音素（Grapheme-to-Phoneme, G2P）转换。因为一个词的发音可能因其语法角色不同而变化。尽管在统计参数语音合成系统中，词性标注对发音精度影响较大，但在现代神经网络架构中，该步骤往往被省略。

（3）韵律预测。韵律特征（如节奏、重音和语调）在语音自然度中起着关键作用。TTS 系统可通过建模音素的持续时间、基频和响度来还原韵律信息。神经网络模型通常会通过独立的子模块自动学习和建模这些韵律属性，从而增强生成语音的自然感。

（4）字素到音素转换。G2P 是文本处理模块中最关键的部分，负责将输入的字素

序列转换为对应的音素序列。通常，这一过程可通过预先构建的语言词典完成，对于词典外的词，则可借助语言规则或数据驱动模型进行音素生成。

需要指出的是，当前主流的基于神经网络的文本到语音系统通常直接以字符或音素作为模型输入。因此，相较于传统 TTS 系统，这类神经网络架构无需额外构建用于提取语言特征的独立前端模块，从而有效简化了整体流程并提升了建模效率。

2.3.2 声学建模

声学模型的任务是将语言特征映射为声学特征，用以驱动声码器生成语音信号。常见的声学特征包括梅尔倒谱系数、线谱对、梅尔广义系数、音高、基频以及梅尔频谱图等。其中，梅尔频谱图因其能更好地捕捉语音的听觉感知特性，成为当前神经 TTS 系统中最常用的目标输出表示。随着深度学习技术的发展，不同结构的神经网络被广泛应用于声学建模任务。目前主流的模型结构可以大致分为三类：基于 RNN 的模型、基于 CNN 的模型以及基于 Transformer 的模型，其代表模型和主要特征如表 2-1 所示。

表 2-1 常见的声学建模架构及其代表模型

Table2-1 Common acoustic modeling architectures and representative models		
模型类型	代表模型	描述说明
基于 RNN 的模型	Tacotron 系列	使用编码器-注意力-解码器架构，将字符转为线性频谱图；Tacotron 2 在自然度和鲁棒性方面表现更好。
		通过卷积神经网络提取语言特征；DeepVoice 3 增强了网络结构并支持多说话人建模。
基于 CNN 的模型	DeepVoice 系列	引入时长预测器，实现非自回归的快速推理；FastSpeech 2 提供更多韵律信息，提升合成质量。
基于 Transformer 的模型	FastSpeech 系列	

在基于 RNN 的方法中，最具代表性的是 Tacotron 系列，它采用典型的编码器-注意力-解码器架构，以字符序列作为输入，输出对应的梅尔频谱图。Tacotron 2^[63]相较初版在语音自然度与合成鲁棒性方面均有显著提升，是当前神经合成框架的重要里程碑。

在 CNN 结构中，DeepVoice 系列是较早将卷积神经网络引入语音合成的尝试。DeepVoice^[64]利用卷积网络提取语言特征，再通过神经声码器生成语音；DeepVoice2^[65]引入更复杂的网络结构并支持多说话人建模，进一步提升系统表达能力；DeepVoice3^[66]则完全采用卷积结构对字符进行建模，从而提升了模型并行计算能力。随后的一些衍生模型如 ClariNet^[67]和 ParaNet^[68]，实现了从文本到波形的端到端建模，并在推理速度与语音质量之间取得了良好平衡。此外，DCTTS^[69]系统也基于全卷积结构，具备较好的生成效率。

Transformer 架构的引入进一步推动了声学建模的发展。Tacotron 2 原本基于 RNN 构

建, 但存在难以并行计算、建模长距离依赖能力不足等问题。为此, 研究者提出了基于 Transformer 的 Transformer TTS 模型, 以改进上述缺陷。该模型在结构上继承了 Tacotron, 但使用了自注意力机制以实现更长距离的建模能力和并行化训练。然而, Transformer 模型仍存在一定的不稳定性, 特别是在注意力对齐方面容易出现跳字或重复问题。为解决这一问题, FastSpeech 系列提出了非自回归的建模方式。FastSpeech 使用前馈 Transformer 网络替代自回归解码器, 并引入时长预测器和长度调节器, 实现并行生成梅尔频谱图, 在推理效率和合成稳定性上均取得突破。FastSpeech 2 进一步增强了模型对韵律特征(如音高、持续时间和能量)的建模能力, 提升了语音自然度和表达力。

2.3.3 声码器

声码器的核心任务是将声学模型输出的特征(如梅尔频谱图)还原为可听的语音波形。其具体输入形式因声学建模方式不同, 可能包括梅尔频谱图、线性谱图或其他声学参数。由于传统自回归方式从梅尔频谱图生成波形速度较慢, 近年来研究者提出了多种高效替代方案, 包括基于流、生成对抗网络以及扩散模型的方法, 以在保障语音自然度的同时显著加快推理效率。

最早的神神经声码器代表是 WaveNet, 它利用扩张卷积进行自回归建模, 可逐点生成高质量语音波形, 在自然度方面表现优异。然而, 由于其串行推理的特性, 推理速度较慢, 难以满足实时应用需求。为此, LPCNet^[70]在 WaveNet 的基础上引入了线性预测机制与轻量级 RNN 架构, 通过残差建模有效降低了计算开销, 实现了在嵌入式环境中的语音合成。

基于流的声码器利用可逆变换将复杂分布映射至高斯分布, 具有良好的建模能力和采样可控性。WaveNet、WaveGlow^[71]和 WaveFlow^[72]均属于此类方法。它们在建模质量与推理效率之间寻求平衡, WaveFlow 更是融合了自回归和非自回归的优势。

在生成对抗网络框架下, 声码器借助判别器引导生成器学习更加真实的波形特征。代表性工作如 WaveGAN^[73]、MelGAN^[74]与 HiFi-GAN^[75], 它们通过设计多尺度判别器、多周期判别器或分层判别器来增强判别能力, 进而提升音频保真度。此外, 为优化训练稳定性与音质表现, 这类模型通常引入 STFT 损失和特征匹配损失等辅助目标。

近年来兴起的基于扩散概率模型的声码器代表了高保真语音合成的前沿趋势。典型模型如 DiffWave^[76]、WaveGrad^[77]以及 PriorGrad^[78]等, 均采用去噪扩散过程建模语音波形。在这一框架下, 语音信号通过前向扩散过程逐步添加噪声, 并通过学习的反向过程逐步还原为真实波形。这种方法虽然生成音质优异, 但由于迭代步骤繁多, 推理速度较慢。因此, 研究热点逐渐转向如何在保持音质的同时, 减少扩散步骤以加速推理。

综上所述, 从早期的 WaveNet 到后续的 HiFi-GAN 和 DiffWave, 神经声码器架构持续演进, 不断提升语音合成系统在质量、效率与实用性之间的综合表现, 为构建高质量的端到端 TTS 系统奠定了坚实基础。

2.3.4 完全端到端语音合成

一个完全端到端的文本到语音系统以字符为输入，直接生成相应的语音波形。此类方法的显著优势在于省去了繁琐的特征工程与对齐操作，减少了人工标注与错误传播的风险。然而，其主要挑战在于如何有效桥接输入的字符或音素序列与输出波形序列之间的巨大长度差异，以及不同模态之间的表达映射。

为了解决上述问题，研究者提出了多种架构设计。VITS 是一种融合了变分自编码器、归一化流与对抗训练的端到端模型。它通过引入音素级对齐机制与持续时间预测器，在音素和梅尔频谱图之间建立了隐式对应关系。该模型在自然度和音质方面表现良好，但仍存在对齐稳定性差、情感表达不足、泛化能力有限等问题。FastSpeech2 则采用非自回归架构，通过持续时间预测器与长度调节器显式对齐音素与梅尔频谱长度，显著提高了生成效率，并具备更强的韵律建模能力。然而，该模型高度依赖于持续时间预测的准确性，一旦预测误差出现，语音的自然性和表达能力会明显下降。在情感表达与多语者建模方面也面临一定限制。

针对这些问题，F5-TTS 提出了一种全新的建模范式。F5-TTS 是一种完全非自回归的 TTS 框架，基于条件流匹配和 DiT 架构。该模型取消了传统 TTS 系统中常见的音素对齐机制、持续时间预测器与文本编码器，仅通过将字符序列简单填充至与梅尔频谱图长度一致，并结合语音参考信息作为条件输入进行训练，从而极大简化了建模流程并消除了对对齐精度的依赖。为提升文本建模与上下文理解能力，F5-TTS 在输入端引入了 ConvNeXt V2^[79] 模块，有效增强了字符表示的语义感知能力，并在多语者、多情感的情境中表现出更强的对齐与泛化能力。推理阶段，该模型采用 Sway Sampling 策略，有效降低扩散过程中的采样步数，在保证音质的前提下显著提升了合成速度，克服了传统扩散类模型推理效率低下的缺陷。综合来看，相较于 VITS 和 FastSpeech 2，F5-TTS 在结构上更加简洁高效，在自然度、情感表现力及跨说话人适应性方面均具有显著优势，代表了端到端语音合成模型向高质量、强泛化方向发展的重要趋势。

2.4 本章小结

本章系统梳理了语音合成的核心理论体系，为后续情感语音合成模型的构建提供了坚实的理论支撑与方法基础。内容涵盖语音信号处理原理、深度学习建模结构以及 TTS 系统架构，逐步构建起完整的知识框架。

语音信号处理部分围绕语音的产生机制与物理属性展开，详细介绍了语音信号的短时平稳性假设、分帧加窗、傅里叶变换、线性谱与梅尔谱等基础处理流程。这些技术为声学建模阶段的特征提取和表示提供了关键理论支持。

在深度神经网络建模部分，本章介绍了卷积神经网络(CNN)、循环神经网络(RNN)及其变体 LSTM，进一步拓展至 Transformer 与 Diffusion Transformer 等当前主流结构，分析其在特征建模、序列处理能力、训练效率等方面的特点与适用场景。

结合现代 TTS 系统架构，梳理了文本处理、声学建模与声码器三大模块之间的关系

与技术演进趋势，重点探讨了非自回归建模在提高生成效率、减少对齐依赖方面的优势，以及 GAN、流模型、扩散模型等声码器在合成质量与计算复杂度之间的平衡策略。

本章构建的理论框架不仅为后续情感建模机制的引入提供了坚实支撑，也为高自然度、强可控性与良好泛化能力的语音合成系统设计奠定了基础，在明确模型设计方向的同时，为情感语音合成工作的深入推进提供了有力保障。

第3章 基于情感自适应球面向量的情感语音合成

由于现有模型的局限性、人类情感本身的复杂性（尤其是在情感风格维度上的多样性）以及情感数据集的稀缺，情感语音合成在实现自然、可控的情绪表达方面仍面临诸多挑战。为应对这些问题，本文提出了一种简洁高效的情感可控语音合成模型——ECE-TTS。该模型以 F5-TTS 为基础，采用文本引导的语音补全任务进行训练，避免了对音素级持续时间对齐器的依赖，从而显著简化了模型结构。在文本与语音对齐方面，模型引入增强型文本编码器与无分类器引导机制，以提升语音生成的一致性与自然度。针对情感风格控制需求，ECE-TTS 融合情感自适应球面向量建模机制，能够在推理过程中实现更为细腻和可控的情绪风格调节。此外，为缓解高质量情感语音数据的获取难题，本文构建了一个覆盖七种基本情绪类别的高质量英文语音数据集，并设计了多阶段的筛选与处理流程，确保训练语料的情感标签准确、语音质量可靠，从而为模型学习提供坚实的数据支撑。

3.1 基于条件流匹配的语音合成模型

本研究采用流匹配目标进行训练，该目标使模型能够将简单的概率分布（如标准正态分布）转换为近似目标数据分布的复杂分布。该技术利用整个流变换路径中的时间依赖性，确保模型在条件引导选择和数据约束下进行训练。因此，它能够准确建模从初始分布到目标分布的过渡，从而促进高质量语音数据的生成。

流匹配损失函数定义在公式（3-1）中，其目标是预测给定输入 x_0 时流变换的预期行为。其中， $u_t(x)$ 表示预期的流方向向量：

$$L_{FM}(\theta) = E_{t,p_t(x)} \|v_t(x) - u_t(x)\|^2 \quad (3-1)$$

在该公式中， θ 表示神经网络参数， $t \sim \mathcal{U}[0,1]$ ，并且 $x \sim p_t(x)$ 。由于无法通过先验知识近似 $p_t(x)$ 的显式形式，训练过程遵循条件概率路径：

$$p_t(x | x_1) = N(x | \mu_t(x_1), \sigma_t(x_1)^2 I) \quad (3-2)$$

其中， x_1 是与训练数据对应的随机变量， μ 和 σ 分别表示高斯分布的时间依赖均值和标量标准差。文献^[80]已证明，条件流匹配的损失函数与原始流匹配损失函数等价，这为后续的建模方法提供了理论基础。

条件流匹配的目标是建模两个分布之间的过渡，例如将随机正态噪声分布 $p(x_0)$ 转换为目标数据分布 $p(x_1)$ 。这种转换依赖于流路径 $\psi_t(x_0) = x_t$ 和时间依赖的向量场 $v_t(x_t)$ ，后者决定了每个时间步数据点的移动方向和速度。流路径 $\psi_t(x_0) = x_t$ 描述了从初始分布 $p(x_0)$ 到目标分布 $p(x_1)$ 的完整动态过程，可以表示为两个概率密度函数之间的映射：

$$\frac{d}{dt} \psi_t(x) = v_t(\psi_t(x)), \psi_0(x) = x \quad (3-3)$$

模型训练的目标是从简单分布（如高斯噪声）开始，生成符合目标分布的数据样本。在此过程中，流匹配提供了一个向量场：

$$\frac{d}{dt}\psi_t(x_0) = u_t(\psi_t(x_0) | x_1) \quad (3-4)$$

通过应用重参数化，推导得出条件流匹配损失函数：

$$L_{CFM}(\theta) = E_{t, q(x_1), p(x_0)} \left\| v_t(\psi_t(x_0)) - \frac{d}{dt}\psi_t(x_0) \right\|^2 \quad (3-5)$$

利用最优传输（Optimal Transport, OT）公式 $\psi_t(x) = (1-t)x + tx_1$ ，可以进一步表达 OT-CFM 损失函数为：

$$L_{CFM}(\theta) = E_{t, q(x_1), p(x_0)} \left\| v_t((1-t)x_0 + tx_1) - (x_1 - x_0) \right\|^2 \quad (3-6)$$

在推理阶段，给定初始分布中的样本点 x_0 ，使用常微分方程（ODE）求解器^[81]求解流的时间步 t 和生成约束。然后，将 $\psi_t(x_0)$ 的积分结果作为时间的函数进行评估，初始条件设置为 $\psi_0(x_0) = x_0$ 。这种方法确保了生成过程的数学严谨性，并保持了对数据分布的动态可控性。

3.2 分类器引导与无分类器引导

分类器引导(Classifier Guidance, CG)^[82]是一种在扩散模型中引入的条件生成技术，旨在通过结合分类器的梯度信息，显式增强生成样本与目标条件之间的对齐，从而显著提高合成样本的质量。与无条件生成相比，CG 能够有效地将生成样本引导至目标分布，确保结果更贴近用户指定的条件。然而，这种显式的条件生成方法也存在一些显著的局限性。

首先，CG 需要训练一个额外的分类器，该分类器必须能够高效处理噪声输入数据，这增加了整体实现的复杂性。此外，生成样本的质量直接依赖于分类器的准确性；如果分类器不可靠或容易受到外部噪声的影响，生成样本与预期条件之间的对齐可能会恶化。另外，由于 CG 依赖于分类器的梯度进行引导，它本质上容易受到对抗攻击的影响，可能导致生成误导性样本。例如，这些对抗样本可能包含一些微妙的、难以察觉的细节，表面上符合给定条件，但实际上偏离了真实的目标分布。因此，尽管 CG 提供了一种显式的条件控制机制，但其对分类器的依赖以及相关的安全问题限制了其实际应用。

为了解决这些挑战，无分类器引导（Classifier-Free Guidance, CFG）^[83]被提出作为一种替代的引导方法，消除了对显式分类器的依赖。CFG 的核心思想是在生成过程中同时利用条件和无条件的分数估计，从而在提高样本质量的同时，避免了基于分类器引导的复杂性和风险。该方法在训练过程中以一定概率随机丢弃条件信息，使模型能够同时学习条件和无条件的分数估计，最终提高生成的灵活性。具体而言，CFG 使用单一模型同时生成条件分数 ϵ_{cond} 和无条件分数 ϵ_{uncond} 。最终的引导分数通过以下线性组合公式计算：

$$\tilde{\epsilon}_\theta = \epsilon_{uncond} + s \cdot (\epsilon_{cond} - \epsilon_{uncond}) \quad (3-7)$$

其中， s 是一个缩放参数，用于控制生成引导的强度。通过调整 s 的值，CFG 可以在生成过程中动态平衡样本的保真度和多样性。

与 CG 相比，CFG 具有几个显著优势。首先，CFG 不需要额外的分类器，大大简化

了实现过程，并降低了扩散模型的训练复杂性。其次，CFG 避免了因分类器引导而可能产生的对抗攻击漏洞，从而增强了生成样本的安全性和可靠性。最后，通过在训练过程中随机丢弃条件信息，CFG 能够无缝切换条件生成和无条件生成模式，提供了更灵活和自适应的生成过程。通过采用这种技术，CFG 不仅简化了条件生成，还增强了模型的控制能力。实验结果表明，CFG 在样本质量和多样性之间实现了有效平衡，如公式 (3-8) 所示，其中 α 表示 CFG 引导的强度：

$$v_{t,\text{CFG}} = v_t(\psi_t(x_0), c) + \alpha \left(v_t(\psi_t(x_0), c) - v_t(\psi_t(x_0)) \right) \quad (3-8)$$

除了改进一般的条件生成外，文本-语音对齐是确保合成语音语义准确性和情感一致性的关键因素。CFG 通过在训练过程中随机丢弃文本条件，增强了文本-语音对齐，使模型能够同时学习文本条件和无条件分数分布。这加强了文本内容与生成语音之间的关联，确保了更准确的韵律和情感表达。因此，本文采用了 CFG，利用其优势简化模型架构，同时显著提高了合成语音的语义连贯性和情感保真度。

3.3 情感自适应坐标转换




图 3-1 3D VAD 情感模型

Fig.3-1 3D VAD emotional model

在情感语音合成任务中，如何实现细粒度、连续性且可解释的情感控制一直是一个核心挑战。传统方法通常依赖离散情感标签（如“开心”“愤怒”等）进行分类建模，但这种离散化处理难以充分覆盖人类真实情绪中所蕴含的丰富表达风格与强度变化。此外，基于参考音频的风格迁移方法虽然能够提升合成语音的自然度与多样性，但由于缺乏明

确的物理语义映射，也难以支持灵活可调的情感控制能力。如图 3-1 所示，为实现更细腻、连续的情感建模，已有研究引入愉悦度、唤醒度与支配度构成的三维情感空间，替代传统离散标签，增强情感表达的连续性与解释性。然而，VAD 向量在生成建模中仍面临挑战，如不同情感类别在三维空间中分布重叠导致风格边界模糊，维度间耦合亦限制了调控的独立性。

为解决上述问题，本文引入情感自适应球面向量方法^[35]，进一步提升情感建模的结构性与表达力。EASV 基于三维 VAD 情感空间构建，通过笛卡尔-球面坐标变换将原始 VAD 向量映射为球面上的单位向量。在该球面空间中，情感风格主要由向量的方向表示，不同方向对应不同的表达类型。为了增强风格分布的清晰性，EASV 在建模过程中引入了每类情感的特征性中心点 M_k ，并通过最大化其与中性情感之间的角度间隔来构建更具判别力的风格坐标系统。该机制有效拉开了不同类别之间的球面角度距离，从而提升了风格区分度，并支持在不同情感风格之间进行平滑插值，实现连续化的风格调控。




图 3-2 语音情感识别器模型结构图

Fig.3-2 Architecture of the speech emotion recognition model

本文采用基于预训练模型的语音情感识别器^[34]对原始语音进行 VAD 三维情感维度提取，其网络结构如图 3-2 所示。该情感识别模型基于 Wav2vec 2.0 构建，输入为原始波形信号，首先通过一组冻结的 CNN 层提取局部时域特征，随后通过可微调的 Transformer 编码器建模全局上下文信息，并利用平均池化操作获得语音整体的嵌入表示，最终通过全连接层输出对应的 VAD 预测值。该方法具备无需手工标注即可获得情感标签的优势，不仅提高了系统的训练效率，也消除了对高成本人工注释的依赖，为后续 EASV 表征构建提供了高质量输入。基于上述提取的 VAD 向量，本文进一步应用情感自适应坐标变换方法，将其转换为结构化的球面情感向量，其具体转换流程如图 3-3 所示，包括以下几个步骤：




图 3-3 情感自适应坐标转换流程图

Fig.3-3 The Process of emotion-adaptive coordinate transformation

(1) 情感维度提取。使用训练好的情感识别模型 ψ 对语音数据集 X 中每个参考语音样本 x_i 预测 VAD 值，得到：

$$e_i^k = \psi(x_i) \quad (3-9)$$

其中， e_i^k 是一个三维向量 (d_v, d_a, d_d) ，分别表示愉悦度 V、唤醒度 A 和支配度 D。

(2) 中立情感中心计算。对于中性情感数据，计算其在 VAD 空间中的平均值，作为后续坐标变换的基准中心：

$$M = \frac{1}{N_n} \sum_{i=1}^{N_n} e_i^n \quad (3-10)$$

其中， N_n 为中性情感样本的总数， e_i^n 表示第 i 个中性情感样本的 VAD 值。

(3) 情感坐标平移。为构建具有类别可区分性的球面坐标系，需首先为每一类情感构造特异性的参考中心点 M_k 。通过最大化该类别与中性类别之间的距离比，计算得到类别中心：

$$M_k = \arg \max_M \frac{E_{e_i^k \in E_k} [\|M - e_i^k\|_2]}{E_{e_i^n \in E_n} [\|M - e_i^n\|_2]} \quad (3-11)$$

这里， e_i^k 和 e_i^n 分别表示情感集 E_k 和中性集 E_n 中第 i 个样本的坐标。

随后，将该类别下所有样本的坐标进行平移，得到修正后的向量：

$$\hat{e}_i^k = e_i^k - M_k \quad (3-12)$$

(4) 球面坐标转换。将平移后的笛卡尔坐标 $\hat{e}_i^k = (\hat{d}_v, \hat{d}_a, \hat{d}_d)$ 转换为球面坐标 $s_i^k = (r, \theta, \varphi)$ ，计算方式如下：

$$r = \sqrt{\hat{d}_v^2 + \hat{d}_a^2 + \hat{d}_d^2}, \theta = \arccos\left(\frac{\hat{d}_a}{r}\right), \varphi = \arctan\left(\frac{\hat{d}_v}{\hat{d}_a}\right) \quad (3-13)$$

(5) 异常值处理。为了减少异常值对模型训练的影响，本文采用四分位距（Interquartile Range, IQR）方法^[84]对球面半径 r 进行限制处理：

$$r_{clamp} = \min(\max(r, r_{min}), r_{max}), r_{IQR} = \frac{r_{clamp} - r_{min}}{r_{max} - r_{min}} \quad (3-14)$$

其中， r_{min} 和 r_{max} 根据 IQR 方法计算，具体来说， r_{min} 设定为第一四分位数（Q1）减去 1.5 倍 IQR， r_{max} 设定为第三四分位数（Q3）加上 1.5 倍 IQR。

通过上述步骤，情感维度值最终转换为情感自适应球面向量，记作 $s_i^k = (r_{clamp}, \theta, \varphi)$ ，该向量作为模型的情感特征表示。EASV 充分融合了心理学情绪建模理论与向量空间表达能力，能够实现对情感风格与强度的显式分离与联合建模。配合 SER 模型生成的 VAD 特征，该方法在表达可解释性、风格可控性以及连续插值生成等方面表现出显著优势，为构建高质量、灵活可控的情感语音合成系统提供了有效支撑。

3.4 模型训练

本研究采用了上下文学习框架，以语音填充任务为核心优化目标。该任务的基本思路是：在提供完整文本信息与部分缺失音频内容的前提下，引导模型预测并还原缺失的语音片段。模型接收一个上下文提示，提示中包含完整的文本序列与不连续的语音片段，借助语言语义、风格和韵律等信息，学习如何补全被遮蔽的音频区域。通过引入上下文作为条件，模型能够更好地理解语言结构和表达规律，在保留上下文一致性的同时提升生成结果的自然性与连贯性。




图 3-4 面向语音补全任务的上下文学习框架图

Fig.3-4 In-context learning framework for speech infilling tasks

如图 3-4 所示，本研究构建的上下文学习框架由原始音频数据、上下文提示构建机制以及 TTS 模型组成，模型在上下文条件引导下对缺失的语音片段进行补全生成。为提升生成效率与表达灵活性，训练过程中采用了非自回归建模策略。与传统依赖自回归机制、逐帧从左至右生成语音的结构不同，非自回归架构支持模型在序列中任意位置插入或还原语音片段，从而增强了其在语音编辑、音频修复与情感迁移等任务中的适应能力。该方法不仅具备较强的语音生成保真度，同时能够在保持上下文一致性的前提下，实现更加灵活和个性化的情感语音表达控制。




图 3-5 ECE-TTS 模型训练流程图

Fig.3-5 An overview of the training process of the ECE-TTS model

模型训练过程如图 3-5 所示。模型输入数据格式为 (x, y, E) ，其中 x 表示音频样本， y 表示对应的文本转录， E 表示情感特征序列。在预处理阶段，输入音频数据 x 被转换为 Mel 频谱特征矩阵，记作： $x_1 \in \mathbb{R}^{F \times N}$ ，其中， F 表示 Mel 频率维度， N 表示序列长度。与传统依赖于音素级对齐的模型不同，ECE-TTS 只需要字符级的文本序列，无需音素级的文本对齐。输入音频数据对应的转录文本 y 会被编码为字符向量，并通过填充操作扩展至与梅尔频谱特征矩阵相同的时间维度 N 。扩展后的字符序列 Z 形式如下：

$$z = (c_1, c_2, \dots, c_M, \langle F \rangle, \dots, \langle F \rangle) \quad (3-15)$$

其中， c_i 表示第 i 个字符， F 代表填充字符，以确保序列长度与 N 匹配， M 为原始文本长度。

由于本研究直接使用字符序列 Z 作为文本输入，而非音素级表示，这在一定程度上可能削弱模型的对齐能力。为缓解该问题，在特征拼接之前引入 ConvNeXt V2 模块对文本序列进行预处理，以增强语音与文本表征之间的对齐效果。ConvNeXt V2 结构如图 3-6 所示，其设计借鉴了现代卷积网络的构建理念，并融合了 Transformer 架构中的关键特性。该模块包含深度卷积层、层归一化、逐点线性变换、GELU 激活函数、全局响应归一化等组件，能够实现类似 Transformer 的表征能力，同时保留卷积结构在局部感知与位置建模方面的优势。相较于传统卷积网络，ConvNeXt V2 在对齐建模上展现出更强的

局部特征提取能力与上下文捕捉能力，使模型即便在缺乏显式对齐机制的条件下，也能实现更加精准的跨模态映射，从而有效提升语音合成的表达质量。实验结果表明，该结构为文本提供了更具表达力的建模空间，显著增强了模型的上下文理解与生成能力。类似地，情感特征序列 E 同样通过 ConvNeXt V2 模块进行建模，从而进一步提升其与文本表示之间的对齐效果。




图 3-6 ConvNeXt V2 模型结构图

Fig.3-6 Architecture of the ConvNeXt V2 model

此外，本研究采用了 DiT 作为模型的主干架构，用以执行反向去噪任务。与传统基于 U-Net 的扩散模型不同，DiT 利用 Transformer 的全局建模能力，能够更有效地捕捉长时依赖信息，从而提升语音合成的上下文一致性与对齐能力。具体实现中，系统采用的是 DiT 的 AdaLN-Zero 架构。该机制中，所有用于调节的缩放与偏移分支初始权重均设为零，使模型初始阶段的行为接近恒等映射，有效抑制条件扰动对训练稳定性造成的不利影响。图 3-7 示了该架构的具体模块结构。整个 DiT 模块由多个堆叠的子结构组成，每个子结构包含两个子层，分别用于执行多头注意力机制与多层感知机（MLP）建模操作。每个子层内部均采用残差连接结构，并引入了层归一化与可学习调节机制。输入特征首先经过归一化处理，随后分别送入多头注意力或 MLP 模块进行特征变换；与此同时，网络并行生成一组缩放与偏移参数（ γ 、 β ），用于调节归一化后的表示。该调节过程通过一个独立的分支完成，输出结果与主分支通过残差连接相加，构成子层输出。为

进一步增强模型的表达能力与稳定性,在两个子层的残差路径中分别引入独立的缩放系数(α_1 、 α_2),以实现针对不同建模阶段的动态控制。这种设计使得模型能够在保持整体信息流通畅的同时,灵活调节各模块对最终表示的影响程度。AdaLN-Zero 在图像生成与文本建模等扩散任务中的良好收敛性与可控性亦在本研究中得以体现,通过增强条件特征的注入稳定性,有效提升了语音输出的表达一致性与语义准确性。




图 3-7 DiT 模型结构图

Figure 3-7 Architecture of the DiT model

在条件流匹配的训练过程中,系统引入噪声音频和掩码音频。具体而言,高斯噪声扰动的形式为 $(1-t)x_0 + tx_1$,其中, x_0 为采样的高斯噪声, t 为流步骤长。为构建遮蔽学习任务,系统使用了掩码音频表示为 $(1-m) \odot x_1$,其中, $m \in [0,1]^{F \times N}$ 是一个二值时间掩码矩阵, F 为频率维度, N 为时间帧数。模型的训练目标是基于未被掩码的语音片段 $(1-m) \odot x_1$ 、字符序列 Z 和情感特征序列 E 来重建被掩码的语音片段 $m \odot x_1$,这一过程等价于学习目标分布 p_1 ,其形式为: $P(m \odot x_1 | (1-m) \odot x_1, Z, E)$,该分布的目标是逼近真实的语音数据分布 q 。

3.5 模型推理

在推理阶段,为实现对语音内容与情感风格的精准控制,模型整合了多个关键输入:参考音频频谱图 x_{ref} 、对应的文本转录 y_{ref} 、目标文本转录 y_{gen} 以及情感提示 E 。其中,参

考音频提供目标说话人的音色和韵律信息，文本提示用于指导生成语音的内容，而情感提示则用于控制情感表达。




图 3-8 ECE-TTS 模型推理流程图

Fig.3-8 An overview of the inference process of the ECE-TTS model

在 TTS 模型中，序列长度 N （即语音持续时间）直接影响语音合成的长度控制。与其他需要单独训练时长预测器的模型不同，本方法直接基于 y_{gen} 与 y_{ref} 的字符比率预测时长。这种简洁策略不仅减少了模型复杂性，还引入了一定的随机性，从而提升了语音的自然度。假设总字符长度不超过 Mel 频谱图长度，将 y_{gen} 与 y_{ref} 进行拼接，并填充字符序列以匹配 Mel 频谱图的长度，作为内容条件输入。此外，使用情感自适应坐标变换的方法，从情感参考音频 e_{ref} 中提取情感自适应球面坐标，并将其作为模型的情感特征输入 E 。在从学习到的分布中进行采样时，使用转换后的 Mel 特征 x_{ref} 、拼接扩展的字符序列 $z_{ref.gen}$ 以及情感维度序列 E 作为公式（3-8）中的条件输入，得到：

$$v_t(\psi_t(x_0), c) = v_t\left((1-t)x_0 + tx_1 \mid x_{ref} z_{ref.gen}, E\right) \quad (3-16)$$

如图 3-8 所示，推理过程从推理过程以随机高斯噪声 x_0 开始，通过扩散模型中定义的可逆流函数 $\psi_t(x_0)$ 逐步还原为清晰的语音表示 x_1 。模型采用常微分方程（ODE）求解

器，通过求解微分方程 $d\psi_t(x_0)/dt = v_t(\psi_t(x_0), x_{ref}, z_{ref}, gen, E)$ ，实现从 $\psi_0(x_0) = x_0$ 到 $\psi_1(x_0) = x_1$ 的映射，即从纯噪声到语音表示的连续生成过程。

为了保证生成质量的前提下降低计算负担，本方法在推理过程中引入了函数评估次数（NFE, Number of Function Evaluations）作为控制变量。NFE 决定了 ODE 解算器在 0 到 1 的流变时间段中采样的步数，每一步都需要调用模型 v_t 进行前向推理。较高的 NFE 有助于提升生成语音的细腻程度与上下文一致性，但也会带来显著的计算成本。因此，本模型在设计中通过实证研究选择设定 NFE 步数为 32，以在生成质量与推理效率之间取得最佳平衡。




图 3-9 非均匀时间步采样策略在 $s = -0.8$ 下的时间步采样密度分布图

Fig.3-9 Probability density of sway sampling timestep with coefficient $s = -0.8$

此外，为优化时间步的分布结构，采用非均匀时间步采样策略来替代传统的线性均匀采样方式。该策略通过对采样时刻进行非线性偏移，使时间采样更加聚焦于生成过程的早期阶段。由于扩散生成任务中，大量关键语音结构（如音素边界、节奏框架等）往往在去噪初期已基本成型，Sway Sample 能够加强模型对初期信息的建模能力，从而显著提升对齐精度与韵律自然度。

具体而言，非均匀时间步采样并非直接从 $t \sim \mathcal{U}[0,1]$ 进行均匀采样，而是首先从均匀分布采样初始时间步 $u \sim \mathcal{U}[0,1]$ ，随后引入一个基于参数 s 的可调函数对其进行变换：

$$f_{\text{sway}}(u; s) = u + s \cdot \left(\cos\left(\frac{\pi}{2}u\right) - 1 + u \right) \quad (3-17)$$

其中，参数 $s \in \left[-1, \frac{2}{\pi-2}\right]$ 控制采样分布的偏移方向和强度。

当 $s < 0$ 时，采样将偏向时间轴前部，从而形成如图 3-9 所示向左偏的采样密度 $\pi(t)$ ，使生成过程更加关注初始阶段。与之相对，当 $s > 0$ 时，采样向后偏移；而当 $s = 0$ 时则

退化为标准均匀采样。当设定 $s = -0.8$ 时, 所得到的采样密度函数 $\pi(t)$ 在 $t \approx 0$ 附近显著集中, 从而加强了模型对去噪初期信息的学习能力。得益于该策略, 模型在训练与推理阶段能够更频繁地接触早期时间步, 有助于更好地学习关键的低层次语音表示, 特别在语音对齐与自然度方面展现出更优表现。该方法结构简单、实现高效, 适用于多种扩散语音合成框架中, 对提升生成质量与稳定性具有重要意义。

在模型完成 Mel 频谱图的生成后, 推理流程的最后一步是将其输入声码器以恢复最终的语音波形。在该过程中, 系统会丢弃参考音频所对应的频谱部分, 仅保留由模型生成的 Mel 区段, 并将其作为输入传递给声码器进行重建。为进一步提升语音还原的质量与效率, 本文选用 Vocos^[85] 作为声码器模块。

Vocos 是一种基于频域建模的神经声码器, 其核心思想是直接对 STFT (短时傅里叶变换) 频谱中的复数系数进行建模, 并通过高效的逆 STFT 操作恢复时域波形。相较于 HiFi-GAN、BigVGAN^[86] 等传统基于时域的 GAN 声码器, Vocos 摒弃了冗长的反卷积上采样结构, 显著减少了模型复杂度, 有效规避了混叠伪影等问题, 在提升重建质量的同时也大幅提高了推理效率。在架构设计上, Vocos 采用 ConvNeXt^[87] 模块构建生成器, 并保持全流程的时间分辨率一致, 避免了频繁上采样带来的不稳定性。此外, 其引入显式的幅度与相位建模机制, 结合单位圆映射实现平滑连续的相位恢复, 使得合成语音在韵律与自然度方面更为接近真实人声。Vocos 的引入不仅为系统提供了稳定可靠的波形重建能力, 也在自然度、清晰度与实时性等方面显著提升了情感语音合成系统的整体性能, 进一步增强了其在实际应用中的部署可行性与拓展能力。

3.6 实验与结果分析

3.6.1 数据集

1. 训练数据

高质量 TTS 模型的训练受益于充足且精心整理的数据。然而, 情感语音的录制和人工标注成本高昂, 使得构建规模足够大、质量足够高的情感数据集成为一项挑战。相比于离散情感标签或情感迁移技术, 本文的方法利用情感识别模型提取情感维度, 并应用情感自适应坐标变换以生成 EASV 作为情感风格表示。

本研究借鉴文献^[32]的数据集构建思路, 从一个包含丰富情感表达的 600 小时语料库中筛选整理, 构建了一个时长为 200 小时的高质量英文情感语音数据集。具体流程如下: 首先, 使用 Emo2vec 模型^[88]对语音样本进行情感分类, 并为每条样本分配情感置信度评分, 仅保留属于七种目标情感类别 (中性、快乐、愤怒、悲伤、厌恶、兴奋、恐惧) 且置信度达到 1.0 的样本。随后, 采用 DNSMOS 方法对音频质量进行评估, 筛除 OVLR 评分低于 3.0 的样本, 再提取 EASV。为了实现更精细的情感风格控制, 采用滑动窗口技术, 窗口大小设为 0.5s, 步长设为 0.25s, 以提取分段 EASVs。最后, 借助 Whisper-Large 模型^[89]对语音样本进行文本转录, 形成完整的音频-文本对齐对。至此, 构建完成的情感数据集不仅在语音质量和标注准确性方面达到了较高标准, 也满足了后续情感可

控语音合成的建模需求。数据集的整体信息见表 3-1，具体数据格式示例见表 3-2。

表 3-1 情感语音数据集基本信息表

Table 3-1 Basic information of the emotional speech dataset

语音属性	说明
数据规模	200 小时
语种	英语
情感类别	中性、高兴、生气、悲伤、厌恶、兴奋、恐惧

表 3-2 情感语音数据格式示例

Table 3-2 Basic information of the emotional speech dataset

音频文件名	文本内容	情感标签
emo_000001.wav	Since you asked, I'll be frank.	[[0.3492949359921522, 2.1684864564220616, -2.17631351295192], ..., [0.7360244814971794, 2.0928414593867393, -2.290382479038461]]
emo_000002.wav	But it's also important to stay alive.	[[0.37721440888438057, 2.205607956642605, -2.156518575334899], ..., [0.4484440781776289, 1.9398159871845186, -2.283537373445272]]

2. 评估数据

为了评估模型的性能，本研究在情感语音数据库 ESD^[90]上开展了实验。该数据集由 10 名以英语为母语的说话者与 10 名以汉语为母语的说话者共同录制，涵盖 350 条平行句子，不同说话人朗读相同文本内容，从而构建了在文本一致的前提下具备音色、韵律及语言风格差异的语音样本。ESD 包含五种情感类别：中性、快乐、愤怒、悲伤与惊讶，所有录音均在受控声学环境下完成，总时长约为 30 小时。在评估过程中，从测试集随机选取了 30 条语音样本作为实验数据。为提取情感特征输入，采用滑动窗口策略处理语音信号，并利用预训练的情感特征提取器计算对应的情感维度值，包括效价、唤醒度与支配度。最终，这些连续情感维度被进一步转换为情感自适应球面坐标，作为模型的情感控制向量输入，以指导情感语音的生成。值得说明的是，为实现“零样本”情感语音合成，本研究在训练阶段未使用上述参与测试的说话人语音数据，而是在推理阶段仅通过输入文本与预训练的情感特征提取器得到的情感维度值进行合成。

3.6.2 实验环境与模型设置

1. 实验环境

本文实验中涉及到的环境配置详细信息如表 3-3 所示，在 AMD EPYC 7F72 24 核处理器与 NVIDIA A100 80GB 显卡的高性能计算平台上进行。操作系统采用 Ubuntu 20.04 LTS（64 位），深度学习框架为 PyTorch 2.5.1（cu124），CUDA 驱动版本为 12.2，开发语言为 Python 3.10。整体环境配置稳定可靠，能够满足语音合成模型在训练与推理阶段的性能需求。

表 3-3 实验软硬件环境配置表
Table 3-3 Experimental hardware and software configuration

软/硬件	配置环境
处理器	AMD EPYC 7F72 24-Core Processor
显卡	NVIDIA A100 80GB
操作系统	Ubuntu 20.04 LST 64 位
CUDA 驱动版本	12.2
Pytorch 版本	2.5.1+cu124
开发语言	Python3.10

2.模型设置

表 3-4 ECE-TTS 模型部分参数
Table 3-4 ECE-TTS model partial parameters

模块名称	参数名称	数值
Diffusion Transformer	Transformer 层数	22
	注意力头数	16
	嵌入层	1024
	前馈网络	2048
	卷积层数	4
ConvNeXt V2	嵌入层	512
	前馈网络	1024
	文本特征维度	512
文本嵌入	字符嵌入词汇表	212
	情感特征维度	256

基于 F5-TTS 模型的参数设置，本文所提出的模型整体采用 22 层架构，包含 16 个注意力头，嵌入层维度与前馈网络（FFN）维度分别为 1024 和 2048，遵循 DiT 架构设计。在情感与文本建模模块中，使用了 4 层 ConvNeXt V2 结构，嵌入维度和 FFN 维度分别设置为 512 和 1024。文本特征维度与情感特征维度分别为 512 和 256，以增强模型在语义理解与情感控制方面的建模能力。在文本处理方面，模型输入采用字符级编码，包括英文字母与常用标点，构建的字符嵌入词表大小为 212。在音频处理部分，提取的特征为维度为 100 的对数梅尔滤波器组，采样率为 24 kHz，帧移设置为 256。在语音填充任务的训练阶段，梅尔频谱帧以 70%至 100%的比例进行随机掩码操作。针对条件引导训练（CFG）策略，模型采用两阶段掩码机制：首先以 0.3 的概率丢弃掩码语音输入，然后以 0.2 的概率同时丢弃掩码语音与对应文本输入。优化方面，使用 AdamW 优化器

[91], 峰值学习率设为 $7.5e-5$, 并在前 20k 次参数更新中采用线性预热策略, 之后进行线性衰减。梯度范数裁剪上限设为 1。模型在 4 张 NVIDIA A100 80GB GPU 上进行训练, 训练总时长约为五天, 批量大小设为 307,200 个音频帧(约合每批 0.91 小时音频时长), 共完成 66,000 次参数更新。

3.6.3 评价指标

1. 客观指标

为了全面评估模型性能, 本文从语音的可懂度和情感表达一致性两个维度出发, 采用两类客观指标对生成语音进行量化分析, 衡量其在内容与情感属性上的匹配程度。

(1) 词错误率 (Word Error Rate, WER): 为评估合成语音的可懂度, 使用 Whisper-Large 模型对生成语音进行自动转录, 并计算词错误率。WER 通过比较识别结果与参考文本之间的差异来衡量识别准确性, 以百分比形式表示, 数值越低代表语音清晰度越高、可懂度越好。

(2) Aro-Val-Domin 相似度 (Aro-Val-Domin SIM): 为评估合成语音与参考语音在情感维度上的一致性, 采用基于 VAD 三维情感特征的序列相似度计算方法。具体做法是使用滑动窗口技术(窗口大小为 0.5 秒, 步长为 0.25 秒)提取合成语音和参考语音的情感特征序列, 并逐帧计算余弦相似度, 最终取平均值得到 AVD SIM 分数。该指标越高, 表明合成语音的情感表达与目标情感越接近。

2. 主观标签

为进一步评估语音的感知质量, 设计了主观听感实验, 并采用均值主观评分 (Mean Opinion Score, MOS) 作为核心评价指标。MOS 的评分标准如表 3-5 所示。

表 3-5 MOS 语音质量主观评价标准表

Table 3-5 MOS subjective evaluation criteria for speech quality

得分	音频质量	评价标准
5	优秀	语音非常清晰自然, 无任何失真或噪声, 听感与真人语音无异。
4	良好	语音清晰自然, 存在轻微可忽略的失真或噪声, 不影响理解。
3	一般	语音质量一般, 有一定程度的失真或背景噪声, 但基本可理解。
2	较差	语音失真严重或噪声较大, 理解困难, 需要重复聆听。
1	很差	语音几乎无法理解, 严重失真或噪声干扰, 无法用于有效交流。

本次主观实验共邀请 5 名大学生参与, 所有受试者均佩戴专业耳机进行听辨。每条语音样本播放 2-3 次, 以确保听者充分感知音频细节并给出准确评价。实验采用对比评分的方式, 受试者需要分别对不同模型生成的语音与参考语音进行打分。最终 MOS 得分为所有评分者打分的平均值。为获得全面的主观评价结果, 实验引入以下评估指标:

(1) SMOS (Speaker Similarity Mean Opinion Score): 评估合成语音与参考音频的相似度, 评分范围为 1 (完全不同) 至 5 (高度相似)。

(2) NMOS (Naturalness Mean Opinion Score): 评估合成语音的自然度, 评分范围为 1 (极差) 至 5 (优秀)。

(3) EMOS (Emotion Mean Opinion Score): 评估合成语音与参考音频的情感相似度, 评分范围为 1 (完全不同) 至 5 (高度相似)。

3.6.4 结果与分析

为评估不同零样本情感语音合成模型的性能, 本文将所提出的 ECE-TTS 与两种具有代表性的现有方法进行对比, 具体包括:

(1) GenerSpeech^[92]: 一种高保真零样本风格迁移模型, 能够在无需目标风格数据的情况下实现跨领域语音合成。该模型通过整合多级风格适配器、通用内容适配器以及基于流的后处理网络, 实现高效的风格迁移并保证卓越的语音质量。GenerSpeech 支持不同说话人和情感风格的自适应, 展现出强大的泛化能力, 使其适用于未见数据的语音合成任务。

(2) EmoSphere++^[35]: 一种专为精确情感风格控制和强度调节设计的零样本情感可控 TTS 模型。该模型结合情感自适应球面向量与多级风格编码器, 有效解决了跨说话人和情感风格的泛化问题。此外, 其条件流匹配解码器能够生成高质量语音, 并提升情感表达能力。

表 3-6 不同模型合成语音的主观 MOS 评价结果

Table 3-6 Subjective MOS evaluation results of speech generated by different models

方法	SMOS	NMOS	EMOS
真实值	4.02±0.06	4.07±0.06	4.10±0.06
Generspeech ^[92]	3.84±0.07	3.86±0.07	3.85±0.08
EmoSphere++ ^[35]	3.91±0.08	3.98±0.07	3.86±0.07
ECE-TTS	3.93±0.07	3.98±0.07	3.94±0.06

表 3-6 展示了不同模型在主观均值主观评分 (MOS) 评估中的表现。第一行“真实值”代表选自 ESD 数据集的原始语音样本, 作为评估合成语音质量的参考标准。在自然度评分 (NMOS) 方面, ECE-TTS 与 EmoSphere++ 得分相同, 均为 3.98, 优于 GenerSpeech (3.86), 说明 ECE-TTS 所生成语音在听感自然性上具有良好表现。在说话人相似性评分 (SMOS) 上, ECE-TTS 得分为 3.93, 超过 EmoSphere++ (3.91) 和 GenerSpeech (3.84), 表明其在保留说话人身份特征方面具备更强建模能力。特别是在情感表达评分 (EMOS) 上, ECE-TTS 取得了最高得分 3.94, 进一步验证了情感自适应球面向量在实现精细化情感控制的同时, 依然能够保持语音的韵律自然性与情感真实感。

除了主观评价指标外, ECE-TTS 在客观评估方面同样展现出优异性能。如表 3-7 所示, 模型在语音识别误差率 (WER) 和情感相似度 (AVD SIM) 两个维度上均优于对比系统。具体而言, ECE-TTS 的 WER 值为 13.91, 显著低于 GenerSpeech (16.34) 和 EmoSphere++ (15.08), 说明其合成语音在可理解性和语义准确性方面表现更佳。此外, 在 AVD SIM 评价指标上, ECE-TTS 取得了最高得分 0.679, 而 GenerSpeech 为 0.627, EmoSphere++ 为 0.656。这一结果表明, ECE-TTS 在愉悦度、唤醒度和支配度序列方面与真实语音的匹配度更高, 进一步验证了其在情感风格控制上的精准性。

表 3-7 不同模型在客观指标上的评估结果

Table 3-7 Objective Evaluation Results of Different Models

方法	WER	Aro-Val-Domin SIM
真实值	12.25	1
Generspeech ^[92]	16.34	0.627
EmoSphere++ ^[35]	15.08	0.656
ECE-TTS	13.91	0.679

此外，为进一步验证所提出模型 ECE-TTS 在情感表达方面的有效性，本文引入情感语音识别中常用的三类声学特征——音高、能量与频谱变化，从基频、响度及频率变化角度对合成语音的情感动态进行评估。音高反映唤醒度水平，高唤醒情绪（如开心、惊讶）对应更高且波动明显的基频；能量衡量语音强度，通常在愤怒、兴奋等情绪中更高，在伤心、中立等情绪中较低；频谱变化则刻画频率结构的动态程度，数值越大说明语音变化越剧烈，情绪表达更活跃。通过对上述指标的分析，可全面评估合成语音的情感表达效果，验证模型的控制能力。





图 3-10 不同情感类别下合成语音的声学特征分布图

Fig.3-10 Acoustic feature distributions of synthesized speech under different emotion categories


图 3-10 展示了模型在五类典型情感（愤怒、开心、中立、伤心、惊讶）下合成语音的声学特征箱线图。在音高维度，开心与惊讶的语音具有更高的基频中位数及更宽的分布区间，表现出典型的高唤醒特征；中立与伤心则表现出基频较低且变化范围较小的特点，语调更为平缓；愤怒情绪的音高位于中间水平，略高于中立，但波动不如开心显著。在能量维度，愤怒与开心的语音具有更高响度，说明模型在合成高激动情绪时能够生成更具语气张力的语音；中立与伤心的能量值较低，分布集中，符合其情绪特征的低张力属性。频谱变化方面，开心的频率波动最为剧烈，其次是惊讶，体现了语音动态性强与语速较快的特征；而中立与伤心的频谱变化最小，结构相对稳定。上述实验结果表明，ECE-TTS 在不同情感类别下生成的语音在音高、能量与频谱变化等声学特征维度上均展现出符合情绪语义预期的分布特征，表明所提出模型能够有效

建模并区分不同情感风格，为情感可控语音合成提供了坚实的声学支持。




a) 愤怒语音的梅尔谱图

a) Mel-spectrogram of angry speech



b) 中立语音的梅尔谱图

b) Mel-spectrogram of neutral speech



c) 悲伤语音的梅尔谱图

c) Mel-spectrogram of sad speech

图 3-11 不同情感语音对应的梅尔频谱图

Fig.3-11 Mel-spectrograms of speech with different emotions

为进一步增强上述统计指标的直观表现，本文引入梅尔频谱图对合成语音的频谱结构进行可视化展示，图 3-11 展示了模型在愤怒、中立与伤心三种情绪条件下生成的梅尔谱图，用以分析不同情感风格下语音的声学差异。具体而言，愤怒情绪对应的谱图整体亮度较高，频带中分布着大量强能量区域，说明模型在该情绪下生成的语音具有更强的发声强度与情感张力。同时，频带的排列呈现出明显的跳跃性，谱线形态弯曲明显，表征了激烈情绪下语音在频率维度上的快速波动与动态变化。而在中立情绪下，谱图亮度

适中, 频谱结构趋于规则, 频带线条分布均匀, 说明语音能量平稳、节奏自然, 体现了中性语气的基本属性。相比之下, 伤心情绪下的谱图亮度最低, 频谱线条变化缓慢, 整体趋于平直, 呈现出低能量、低动态的语音形态, 符合悲伤情绪表达所具有的内敛与收敛特征。

综上所述, ECE-TTS 在主观与客观维度均展现出卓越的性能优势, 尤其在情感风格建模与情感一致性表达方面表现突出。结合定量指标与频谱可视化结果, 进一步印证了该模型具备精准捕捉语音情感特征并进行有效控制的能力, 为高质量、可控的情感语音合成提供了坚实基础。

3.7 本章小结

本章围绕情感可控语音合成任务, 详细介绍了所提出模型 ECE-TTS 的整体架构设计、训练方法与评估策略。该模型旨在针对当前情感语音合成中面临的三大关键挑战提出有效解决方案: 其一, 传统语音模型生成能力有限且高度依赖音素级持续时间对齐器, 导致系统结构复杂, 泛化性受限; 其二, 人类情感表达高度复杂, 涉及多维度的风格因素与韵律特征, 难以通过离散标签实现有效建模; 其三, 情感语音数据稀缺, 尤其缺乏覆盖多情感、多说话人的高质量标注语料, 难以支撑深层模型训练。

针对上述问题, ECE-TTS 首先采用基于条件流匹配的非自回归建模策略, 以语音补全任务为训练目标, 摆脱对音素级对齐器的依赖, 有效提升生成灵活性和对上下文的建模能力; 在架构上引入 DiT 作为主干模型, 并结合 Classifier-Free Guidance 机制, 在提升生成质量的同时实现语义内容与声学特征之间的高效对齐。其次, 模型通过情感自适应球面向量引入连续化的情感风格表示方式, 突破传统离散情感标签的表达限制, 使模型能够更精细地调节情感风格, 实现更具表现力的情感控制。最后, 为缓解训练数据匮乏的问题, 研究构建了一个覆盖七类情感、时长达 200 小时的高质量英文情感语音数据集, 配合声学质量评估与情感置信度筛选流程, 为模型提供了稳定可靠的数据支持。

综合主客观实验结果, ECE-TTS 在语音自然度、说话人一致性和情感风格表达等方面均优于现有主流方法 GenerSpeech 与 EmoSphere++, 并在多个声学维度上展现出良好的情感区分能力。频谱可视化进一步从感知层面验证了模型合成语音在音高、能量与频谱动态上的情感一致性。本章的研究不仅验证了 ECE-TTS 在情感语音合成中的建模能力, 也为后续开展更细粒度的情感控制, 特别是在情感强度调节与表达精度提升等方面的研究奠定了基础。

第4章 基于情感向量的情感强度控制

4.1 引言

情感强度作为情感表达的重要维度，直接影响语音中情绪的感知层次与感染力。例如，快乐情绪可由轻微愉悦延展至强烈的狂喜，而悲伤则可能从低落的哀伤发展为深切的悲痛^[93]。然而，在当前情感语音合成系统中实现细粒度的情感强度控制仍面临两大关键挑战：情感强度的标注高度主观且成本昂贵，现有语料资源普遍缺乏精确的强度标签；主流控制方法如相对属性排序或嵌入空间操作流程繁复，模型结构复杂，泛化能力受限。

传统的相对属性排序（Relative Attribute Ranking, RAR）方法通过构建排序矩阵并利用支持向量机进行优化，尽管能够实现离散级别的强度分类^[94-97]，但其手工构建排序对的方式容易引入偏差，且与主模型分离的训练机制可能导致整体性能不稳定。而基于情感嵌入空间的方法，如情感向量插值^[98]或距离量化^[99]，虽可实现连续控制，但其性能高度依赖于嵌入空间的结构合理性与稳定性，通常需要引入复杂的约束以避免泛化失效。

为此，本章在第3章提出的 ECE-TTS 模型基础上，引入了一种基于任务向量（Task Arithmetic）的情感强度调节方法。该方法具有三大优势：（1）无需额外强度标签，通过预训练模型与特定情感微调模型之间的权重差值构建情感向量，作为强度调节的表示；

（2）通过线性插值在参数空间中实现连续强度调控，避免排序误差与嵌入不稳定性，具有良好的可微性和可控性；（3）整体方法轻量高效，可直接集成于非自回归的 ECE-TTS 框架中，仅需微调即可实现情感强度的平滑生成。

4.2 使用情感算数向量控制情感强度

从图 4-1 中可以看出，不同情感的语音样本表现出不同的分布模式。因此，本研究推断音频样本的效价（V）、唤醒度（A）和支配度（D）值能够有效反映情感强度的变化。每种情感在这三个维度上占据一个特征范围，随着情感强度的变化，相应的 V、A 和 D 值也会相应调整。为了实现精确且灵活的情感强度控制，本研究采用了一种基于情感算术的方法^[43]。该方法的核心思想是通过结合预训练和微调，构建一个能够精确控制情感强度的语音合成系统。

形式上，令 $\theta_{pre} \in \mathbb{R}^d$ 表示预训练模型的权重， $\theta_e \in \mathbb{R}^d$ 表示针对特定情感 e 微调后的模型权重。情感向量 $\phi_e \in \mathbb{R}^d$ 通过逐元素计算得到：

$$\phi_e = \theta_e - \theta_{pre} \quad (4-1)$$

为了调整情感强度，将情感向量 ϕ_e 通过按元素加法融合到基础模型 θ 中，并由缩放因子 α 控制：

$$\theta_{new} = \theta + \alpha \phi_e \quad (4-2)$$

通过调整 α ，模型可以增强或减弱合成语音中的情感强度。具体而言，当 $\alpha = 1$ 时，新模型 θ_{new} 等同于针对情感 e 微调后的模型，生成的语音表现出微调模型对情感 e 的精确情感特征。相反，当 $\alpha < 1$ ，情感表达的强度逐渐减弱；当 $\alpha > 1$ 时，情感属性被放大。




图 4-1 不同情感类别下 V-A-D 情感维度的分布图

Fig.4-1 Distribution of V-A-D emotion dimensions across different emotion categories

为了确保鲁棒的情感强度控制，模型首先在情感语音数据集上进行预训练，获得一组泛化的预训练权重 θ_{pre} 。预训练过程涵盖了多种情感类型，如快乐、悲伤和愤怒，使模型能够捕捉广泛的情感表达语音特征。预训练完成后，针对每种情感分别使用特定情感数据集进行微调。这一步骤生成了优化的模型权重 θ_e ，确保模型能够合成具有准确情感表达的语音。微调模型权重 θ_e 与预训练模型权重 θ_{pre} 之间的差异被定义为情感向量 ϕ_e ，它捕捉了特定情感对语音特征的影响，并为情感表达提供了一个可控参数。

为了实现灵活且精确的控制，使用以下公式生成修改后的模型参数 θ_e^α ：

$$\theta_e^\alpha = \theta_{pre} + \alpha \phi_e \quad (4-3)$$

基于情感算术的方法通过将缩放因子 α 应用于学习到的情感表示，实现了精确且高效的情感强度调节。这种方法使合成语音能够在不同情感强度之间平滑过渡，同时简化了模型设计并确保了鲁棒的情感强度控制。

4.3 实验与结果分析

4.3.1 实验设置

在第三章情感语音合成预训练模型的基础上，本文进一步将完整的情感语音数据集按照情感类别（中性、开心、愤怒、悲伤、厌恶、兴奋、恐惧）划分为若干情感特定子集，并在每个子集上分别进行微调训练。微调阶段沿用预训练阶段的输入设置，即每个批次包含 307,200 个音频帧（约合 0.91 小时音频）。优化器仍选用 AdamW，峰值学习率为 $7.5e-5$ ，且不采用学习率预热策略。为更好地适配不同情感风格，并提升模型在各类情感条件下的表达能力，每个子集均进行了 20k 次更新，从而实现更精准的情感建模与生成控制。

4.3.2 结果与分析

为验证所提出的情感强度控制机制的有效性，本节从主观感知、情感维度变化、基频轨迹以及频谱结构等多个层面开展系统分析。




图 4-2 情感微调强度变化对情感维度取值的影响分析图

Fig.4-2 Analysis of emotion dimension responses to fine-tuning intensity across emotions

图 4-2 展示了缩放因子 α 对情感强度控制的影响，显示了不同情感（快乐、悲伤和愤怒）在 V、A、D 上的系统性变化。结果证实，增加 α 能够以可预测的方式调节情感表达。对于快乐情感，随着 α 从 0.6 增加到 1.4，V、A 和 D 值均有所上升，反映出更强的快乐感知。相比之下，对于悲伤情感，所有三个维度均下降，与悲伤语音的低沉特性一致。对于愤怒情感，V 值下降，而 A 和 D 值上升，表明语音更加激烈和有力。这些趋势与预期的情感特征一致，表明 ECE-TTS 通过调整 α 有效调节情感强度，确保了表达性语音合成的平滑和可控调节。

为进一步验证模型在情感强度控制方面的有效性，在客观评估基础上引入了主观评价方式进行补充分析。以快乐情绪为例，邀请被试对由不同情感强度参数 α 控制生成的四组语音样本进行评分（1=完全不快乐，5=非常快乐）。如图 4-3 所示，不同情感强度参

数下生成语音的主观快乐评分存在显著差异。结果表明，情感强度参数 α 与感知快乐评分之间呈正相关关系。具体而言，未经强度调节的预训练模型 θ_{pre} 获得的快乐评分最低，中位数约为 2.0；当 $\alpha = 0.6$ 时，中位数提升至约 3.0，呈现出中等程度的快乐感知； α 进一步增至 1.0 与 1.4 时，评分持续上升，最高中位数接近 4.0，表明较高的情感强度因子可有效增强语音中的感知快乐水平。




图 4-3 不同情感强度下快乐语音的主观评分结果

Fig.4-3 Subjective happiness ratings under different emotion intensity conditions





图 4-4 不同情感强度下悲伤语音的基频轨迹对比图

Fig.4-4 F0 trajectory comparison of sad speech under different intensity levels


为考察情感强度调控机制在语音声学层面的表达效果，对不同 α 值控制下生成的悲伤语音样本的基频（F0）轨迹进行可视化分析，结果如图 4-4 所示。从图中可以观察到，不同强度等级的悲伤语音在 F0 轨迹上虽然整体走势相似，但在具体频率数值上呈现出清晰的分层特征。随着悲伤情绪强度的增加，F0 值逐渐降低，表现出更低的音高与更平缓的变化趋势。这一现象与悲伤情绪低唤醒度的声学特性高度一致，符合既有的情感语

音学理论预期。上述结果验证了所提出的基于情感向量的强度控制方法在情感表达层次上的有效性。通过调整强度标量参数，模型能够在保持语义一致性的前提下，生成符合不同强度等级的悲伤语音，体现出良好的可控性和表达力。




a) 情感强度为 $\alpha = 0.6$ 时的开心语音对应梅尔频谱图

a) Mel spectrogram corresponding to happy speech at emotion intensity $\alpha = 0.6$



b) 情感强度为 $\alpha = 1$ 时的开心语音对应梅尔频谱图

b) Mel spectrogram corresponding to happy speech at emotion intensity $\alpha = 1$



c) 情感强度为 $\alpha = 1.4$ 时的开心语音对应梅尔频谱图

c) Mel spectrogram corresponding to happy speech at emotion intensity $\alpha = 1.4$

图 4-5 开心情绪类别下不同情感强度语音的梅尔频谱图

Fig.4-5 Mel spectrograms of speech under different emotion intensities in the happy category

在基频轨迹分析的基础上，本研究进一步对不同 α 值控制下的语音频谱结构进行了可视化分析，以更全面地呈现情感强度调控对语音合成的声学影响。图 4-5 展示了在开心情绪类别下，随着情感强度参数（ $\alpha = 0.6$ 、 1.0 、 1.4 ）的变化，合成语音在梅尔频谱

层面所表现出的显著差异。从整体频谱结构来看,随着情感强度的提升,频谱的变化趋势愈加明显。特别是在图中红框标注的部分,可观察到较高强度语音(如情感强度为1.4)在相同语音片段上的频谱变化更为剧烈,表现出更大的频带起伏和能量波动。具体而言,情感强度为0.6的语音,其频谱分布相对平缓,频带轮廓稳定,能量集中在中低频区域,频谱动态性不足,情感表现偏弱;而当强度升高至1.0时,部分区域出现了轻微的能量增强和频带扩展,但仍未表现出显著的波动特征;当情感强度进一步升高至1.4时,红框区域中频带出现大幅波动,谱图纹理更加密集,表现出更强的语音动态性。这些频谱差异表明,随着情感强度的增强,语音合成模型倾向于在声学层面引入更多变化,表现为更加复杂和突出的频谱细节。这种现象在听感上通常也对应为更具表现力和感染力的情感语音。换言之,情感强度越高,频谱波动越显著,情感表达也越突出,用户更容易感知和识别语音中的情绪状态。

以上实验结果证实,基于情感算术向量的强度控制机制能够有效调节V、A和D值的变化,从而实现情感强度的精确调整。通过对模型权重进行简单的算术操作,该方法实现了高效且准确的强度调节,与传统的情绪强度控制方法相比,提供了一种更直接且有效的解决方案。

4.4 情感语音合成系统的设计与实现

在本研究的第三章与第四章中,围绕情感建模与控制,构建并验证了一种基于情感自适应坐标转换与情感算术向量机制的高质量情感语音合成模型(ECE-TTS)。该模型不仅实现了多情感、多强度的精细化控制,还有效克服了传统方法在强度建模中存在的标签依赖性强与结构复杂等问题。主观与客观评估结果验证了该方法在情感可控性与语音自然度方面的有效性,体现出良好的生成质量与实用价值。

在此基础上,文本进一步设计并实现了一个情感语音合成的在线系统,支持从文本输入、参考音频解析到情感语音生成的端到端流程。该系统前端基于Gradio构建,界面简洁明晰,提供包括文本输入、音频上传、情感类别选择及强度调节等多项功能;后端则集成了基于Diffusion Transformer架构的ECE-TTS模型,并支持Whisper语音识别、静音段处理等模块以增强系统稳定性与实用性。系统采用Python开发,基于PyTorch 2.5.1深度学习框架构建,具备良好的跨平台兼容性,支持本地及远程部署。此外,系统提供可视化频谱图展示与语音播放功能,不仅方便用户直观体验情感合成效果,也为研究人员开展可视化分析与调优实验提供便利。整套系统从功能集成、界面交互到模型调度实现了高度模块化与工程化,展现了良好的用户友好性和科研适用性。

可见,本研究的主要贡献不仅在于提出并验证了一种轻量、高效、可控的情感语音合成方法,同时实现了一个实用性强、交互体验良好的在线情感语音合成平台。未来工作将进一步提升模型在复杂语境下的适应能力,扩展系统的多语种与多说话人能力,推动情感语音合成技术向更广泛的实际应用落地。

4.4.1 系统设计

本研究设计并实现了一个面向情感语音合成的在线交互式合成平台，核心目标是提供一种用户友好、响应高效且具备情感可控能力的语音合成服务。为了实现该目标，系统前端采用 Gradio 作为 Web UI 构建框架，后端则集成了基于 Diffusion Transformer 架构的 ECE-TTS 模型。Gradio 凭借其良好的可组合性和对深度学习模型的高度适配性，能够快速将语音生成模型部署为具有实时交互能力的网页应用，极大降低了用户使用与开发的门槛。

在前端模块的实现过程中，本节基于 `gr.Blocks()` 构建了应用的基本容器结构，并通过 `gr.Row()` 和 `gr.Column()` 函数实现了组件的灵活布局。系统交互界面包括多个关键元素：文本输入框（`gr.TextArea`）用于接收用户输入的目标文本；音频上传控件（`gr.Audio`）用于接收参考音频，提取说话人信息及语音风格；情感类别选择控件（`gr.Dropdown`）支持多情感风格选择；滑动条控件（`gr.Slider`）用于控制情感强度；按钮控件（`gr.Button`）触发语音合成操作；合成结果则通过音频播放器模块（`gr.Audio`）实时呈现给用户。




图 4-6 情感语音合成系统的操作流程

Fig.4-6 Operational flow of the emotional speech synthesis system

系统采用事件驱动的交互机制，通过为按钮组件绑定 `click()` 方法，将前端用户输入与后端逻辑函数 `infer()` 联动。该函数完成从文本、参考音频、情感模板向量的预处理，到调用 ECE-TTS 模型完成合成并返回音频与频谱图路径的全过程处理。后端还支持参考音频自动转录（调用 Whisper）与静音段自动删除等扩展功能，以增强系统鲁棒性与灵活性。系统的部署通过 `click` 命令行模块实现，通过 `python webui.py` 启动服务，支持用户设置运行主机（`host`）、端口号（`server_port`）、是否开放共享链接（`share=True`）以及是否提供 API 接口（`api=True`）等参数。默认部署地址为 `http://127.0.0.1:7862`，可通过修改参数适配本地测试或远程访问。为保障数据传输安全性，系统支持两种方式实现 HTTPS 加密访问：（1）配置反向代理服务（如 Nginx）并安装 SSL 证书，实现完整 HTTPS

部署；(2) 利用 Gradio 的 share=True 参数临时生成安全链接，方便模型展示或远程测试。

在本研究提出的情感语音合成系统架构中，整个语音生成流程可划分为前端用户交互流程与后端模型处理流程两部分。为提升系统的可用性与交互友好性，前端界面设计采用 Gradio 框架实现，用户可通过浏览器便捷地完成各项输入操作，系统随后自动完成情感语音的合成与播放。系统的整体操作流程如图 4-6 所示，其具体操作步骤如下：

(1) 启动推理网页。用户在浏览器中访问系统的在线推理平台，加载前端界面并激活模型服务；

(2) 用户输入合成所需信息。在输入界面中，用户需填写三项关键信息：一是参考音频，提供一段代表目标说话人语音风格的录音片段。二是文本内容，输入希望合成的具体文本。三是情感类别，选择希望表达的情感类型（如高兴、悲伤、愤怒等）；

(3) 点击合成按钮。完成以上音频、文本以及情感的输入后，用户点击“Synthesis”按钮，系统开始执行情感语音克隆任务；

(4) 播放合成语音。待语音合成完成后，用户可直接点击播放按钮，收听最终生成的情感语音结果。




图 4-7 情感语音合成系统的后端处理流程图

Fig.4-7 Backend processing pipeline of the emotional speech synthesis system

本系统在架构设计上兼顾操作便捷性与功能完整性，用户可通过简洁的界面完成复杂语音生成过程中的多项条件配置。其高度模块化的设计既提升了交互效率，也为模型的后续拓展与优化提供了良好的兼容性。在完成前端交互输入后，系统将自动转入后端处理流程，整合用户输入的字符文本、参考音频与情感类别信息，提取多模态特征并驱动情感语音合成模型生成结果。该过程的详细处理流程如图 4-7 所示。

在输入采集阶段,用户通过前端界面提交三项核心信息,包括目标文本、参考音频及情感类别。其中,文本输入为英文句子,系统采用字符级建模方式直接将文本转换为字母序列,简化了传统音素分词步骤并提升了处理效率;参考音频用于提取说话人的声学特征和语调信息,以实现跨说话人条件建模。当用户未提供该音频的文本转录时,系统将自动调用 Whisper 语音识别模型生成对应文本,确保语音与文本内容一致。在情感控制方面,系统为用户提供预设的情感选项,用户可直接选择所需的情感类别(如高兴、悲伤、愤怒等),无需上传额外情感音频。后台将根据用户所选情感,调用预处理阶段已提取的情感维度向量,并使用情感自适应坐标变换机制,将 VAD 值转换为连续可调的球面坐标向量。该过程依次包括情感维度提取、中性情感中心计算、情感坐标平移、球面坐标转换及异常值处理五个步骤。最终得到连续可调的球面情感向量,作为模型的情感控制条件输入。

在上述输入信息准备完成后,系统将字符序列、说话人语音特征及情感向量共同送入后端 ECE-TTS 模型中,执行语音生成任务。合成完成后,生成语音被实时返回至前端界面,用户可点击播放按钮直接收听生成结果。

综上所述,本系统的设计目标是为用户提供一个简洁直观、易于操作的交互平台,使非专业用户也能便捷地控制语音的内容、风格与情感表达。通过引入先进的情感建模机制与高保真的语音生成模型,系统在自然度、个性一致性及情感表达准确性方面均达到了较高水平。同时,该系统的底层架构确保了从输入采集到语音合成全过程的高效响应,有效降低了实际部署门槛。

4.4.2 系统展示




图 4-8 情感语音合成系统 Web 端交互界面

Fig.4-8 Web interface of the emotional TTS system implemented via gradio

如图 4-8 所示,本研究所开发的情感语音合成系统采用 Gradio 框架构建前端交互界面,支持通过浏览器访问(默认地址为 <http://127.0.0.1:7862>)。系统界面功能集中、交互

流程清晰，用户可在同一页面内完成全部语音合成相关操作。

在主界面中，用户可在“Reference Audio”区域上传目标说话人的语音样本，系统将自动提取其声学特征用于建模；在“Text to Generate”文本框中输入希望生成的目标文本；通过“Select a emotion”下拉菜单选择情感类别（如 happy、sad 等），用于控制生成语音的情感风格。点击“Synthesize”按钮后，系统自动调用后端模型进行推理合成，并将带有目标音色和情感表达的语音实时返回页面播放。该界面通过将输入配置与语音输出紧密集成，显著提升了用户操作的便捷性与交互性，充分体现了系统在文本驱动情感语音合成任务中的实用性与一体化设计优势。

如图 4-9 所示，系统在合成结果展示区域提供了直观的音频播放器与频谱图可视化界面。用户在点击“Synthesize”按钮完成语音生成后，合成语音将自动加载至“Synthesized Audio”播放器中，用户可直接点击播放按钮试听结果，或根据需要调节播放速度、下载保存音频文件。这一设计满足了用户对生成质量的即时验证需求，也为后续系统集成与实验数据记录提供了便利支持。




图 4-9 情感语音合成系统生成语音的播放与频谱可视化界面

Fig.4-9 Playback and spectrogram visualization of synthesized speech in the emotional TTS system

在音频播放器下方展示的是合成语音对应的频谱图可视化模块。该模块以二维图像形式呈现语音信号在时间和频率轴上的能量分布，能够反映语音的音素结构、语调变化与频率覆盖范围。通过对不同情感类别下的频谱图进行对比，研究人员可进一步分析模型在情感建模方面的有效性，有助于挖掘语音合成过程中的潜在问题与优化空间。

总而言之，本系统不仅通过整洁高效的输入配置界面实现了用户友好的交互体验，还通过音频播放与频谱图可视化模块增强了结果输出的可解释性和直观反馈能力，充分展现了本文提出的情感语音合成平台在功能集成性与科研适用性方面的优势。

4.5 本章小结

本章围绕情感语音合成中的情感强度控制与系统集成实现两个核心问题展开，引入并验证了一种基于情感算术向量的强度调节方法，并构建了一个具备实时交互功能的在线情感语音合成系统。

在情感建模机制上，本文在已有工作基础上，采用情感算术向量机制，通过计算预训练模型与特定情感微调模型之间的权重差构建情感向量，并引入缩放因子以实现情感强度的连续可控调节。该方法在不依赖显式强度标签的前提下，支持在参数空间中实现平滑调控。客观实验表明，该方法可有效控制合成语音在 VAD 三个情感维度上的表现，主观感知实验也验证了强度因子与听感之间的显著正相关关系，频谱图进一步印证了模型对情感强度调节的表达力与一致性。

此外，本章完成了一个面向用户交互的情感语音合成平台的设计与开发。系统采用 Gradio 构建前端交互界面，整合文本输入、音频上传、情感类别选择与强度控制等功能模块；后端集成了 ECE-TTS 模型与 Whisper 模块，支持参考音频转录与静音段自动处理。平台实现了从用户输入到语音输出的端到端流程，具有良好的用户体验和部署适配能力，展示了较强的实用性和扩展性。

综上所述，本章在已有方法的基础上，结合本研究提出的模型架构与系统设计思路，实现了情感语音强度的可控合成与系统化应用，为后续实现更复杂的多情感、多风格语音生成任务提供了技术支撑和平台基础。

结论

本文围绕零样本情感语音合成展开研究，系统分析了当前主流语音合成模型在情感控制方面的优势与不足，并提出了一种基于 F5-TTS 框架改进的情感可控语音合成系统——ECE-TTS。该系统致力于在简化模型结构的同时，实现高质量的语音合成与细粒度的情感控制，在模型架构、控制机制以及数据资源构建等方面进行了多项创新性设计。

在模型设计上，ECE-TTS 融合了 F5-TTS 所采用的条件流匹配与扩散变换器，摒弃了传统 TTS 模型对音素级时长预测器和显式文本对齐模块的依赖，从而显著降低了对精确对齐数据的需求，提升了系统的泛化能力与训练效率。同时，引入 ConvNeXt V2 模块以增强文本编码质量，进一步优化语音节奏和韵律特征的建模表现。针对情感建模任务，本文在风格控制方面引入了情感自适应球面向量机制，基于唤醒度、效价和支配度三维情感空间构建球面坐标系统。该机制通过将 VAD 向量映射为球面上的单位方向向量，使情感风格主要由方向决定，不同方向对应不同的表达风格。相比传统 VAD 表示，EASV 有效增强了情感类别之间的区分度，缓解了风格边界模糊与维度耦合问题，支持在多个情感风格间实现更加自然、可解释的连续过渡与调控；在情感强度调节方面，引入情感算术向量方法，借助权重空间中的向量幅度缩放，实现了对情感表达强度的连续、平滑调控，提升了情感表达的丰富性与自然度，同时避免了对排序标签或复杂嵌入操作的依赖。考虑到情感语音合成对高质量数据的强依赖，本文还构建了一个规模达 200 小时的英文情感语音数据集。该数据集采用自动标注流程，覆盖多个说话人、多种情感类型与表达风格，为模型的高效训练和稳定表现提供了坚实的数据支撑。

在实验评估部分，本文结合主观与客观评价指标，从语音自然度、情感表达准确性、说话人相似度、风格与强度控制精度等维度进行了系统测试。结果表明，ECE-TTS 在 MOS 评分、情感识别相似度以及自动语音识别误差率等方面均优于现有主流模型，验证了其在情感可控性与合成效果方面的显著优势。

尽管 ECE-TTS 在本研究中展现出优异的性能，在语音自然度、情感表达准确性及控制灵活性等方面均取得了显著进展，但系统仍存在进一步优化与拓展的空间。当前模型的训练与评估主要基于英文语料，其跨语言适应能力尚未得到验证。在实际应用中，情感语音合成往往需要覆盖多种语言环境，因此可考虑引入多语种语音数据，结合语言无关的表征机制与迁移学习方法，探索 ECE-TTS 在多语种和跨语言场景下的通用性与稳定性，进一步拓展其应用边界。在情感建模层面，尽管系统实现了对连续情感风格和强度的有效控制，但在处理更复杂的情绪状态方面仍显不足，例如多个情感同时共存、情绪状态随时间渐变等现实中常见的表达模式仍难以准确建模。未来可探索情感轨迹建模、状态转移图谱等机制，提升系统对动态情感演化过程的建模能力，以更贴近真实人类情感表达规律。此外，当前模型主要依赖语音与文本作为输入，尚未引入其他模态的信息辅助。实际交互中，用户情绪常常伴随面部表情、视觉场景、上下文语义等多模态

信号共同呈现。通过引入图像、情境文本、语义图谱等信息构建多模态感知机制，有望增强模型的情绪理解能力，使合成语音更具情感深度与语境适应性。个性化语音合成也是未来研究中不可忽视的重要方向。尽管 ECE-TTS 具备一定的零样本泛化能力，但在实际应用中，用户往往期望系统能够体现其个性特征，包括特定的音色、语速、口音及情感表达习惯。结合小样本建模、元学习、LoRA 等高效自适应方法，构建快速可迁移的个性化语音生成框架，将进一步提升系统在真实场景中的实用性与用户体验。

综上所述，ECE-TTS 为实现结构简洁、控制精细、表达自然的情感语音合成提供了可行路径。在未来工作中，围绕多语种适应、复杂情感建模、多模态融合与个性化生成等方向持续深入，将有助于推动情感 TTS 系统向更高维度的情感理解与表达能力演进，为构建更具情感智能的人机交互系统奠定坚实基础。

参考文献

- [1] Wang Y, Skerry-Ryan R J, Stanton D, et al. Tacotron: Towards end-to-end speech synthesis[J]. arXiv preprint arXiv:1703.10135, 2017.
- [2] Ren Y, Ruan Y, Tan X, et al. FastSpeech: Fast, robust and controllable text to speech[J]. Advances in neural information processing systems, 2019, 32.
- [3] Kim J, Kong J, Son J. Conditional variational autoencoder with adversarial learning for end-to-end text-to-speech[C]//International Conference on Machine Learning. PMLR, 2021: 5530-5540.
- [4] Tan X, Chen J, Liu H, et al. NaturalSpeech: End-to-end text-to-speech synthesis with human-level quality[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(6): 4234-4245.
- [5] 施昊翔,张旭龙,王健宗,等.情感语音合成综述[J].大数据,2024,10(05):56-73.
- [6] 宋宁.论人工智能技术赋能下虚拟主播的功能演进与实践路径[J].中国电视,2024,(12):76-83.
- [7] Schröder M. Expressive speech synthesis: Past, present, and possible futures[M]//Affective information processing. London: Springer London, 2009: 111-126.
- [8] Lawrence W. The synthesis of speech from signal which have a low information rate[J]. Communication theory, 1953: 460-469.
- [9] Black A W, Campbell N. Optimising selection of units from speech databases for concatenative synthesis[J]. 1995.
- [10] Atal B S, Hanauer S L. Speech analysis and synthesis by linear prediction of the speech wave[J]. The journal of the acoustical society of America, 1971, 50(2B): 637-655.
- [11] Wu Y J. Study on the HMM-Based Speech Synthesis Techniques[J]. University of Science and Technology of China: Hefei, China, 2006.
- [12] Zen H, Tokuda K, Black A W. Statistical parametric speech synthesis[J]. speech communication, 2009, 51(11): 1039-1064.
- [13] Lin, Z.H. Research on Speech Synthesis Technology Based on Statistical Acoustic Modeling[J]. University of Science and Technology of China: Hefei, China, 2008.
- [14] Zen H, Senior A, Schuster M. Statistical parametric speech synthesis using deep neural networks[C]//2013 IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2013: 7962-7966.
- [15] Fan Y, Qian Y, Xie F L, et al. TTS synthesis with bidirectional LSTM based recurrent neural networks[C]//Interspeech. 2014: 1964-1968.
- [16] Van Den Oord A, Dieleman S, Zen H, et al. Wavenet: A generative model for raw audio[J]. arXiv preprint arXiv:1609.03499, 2016, 12.
- [17] Kingma D P, Welling M. Auto-encoding variational bayes[EB/OL].(2013-12-20)
- [18] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J]. Communications of the ACM, 2020, 63(11): 139-144.

-
- [19] Wang Y, Zhan H, Liu L, et al. Maskgct: Zero-shot text-to-speech with masked generative codec transformer[J]. arXiv preprint arXiv:2409.00750, 2024.
- [20] Chen Y, Niu Z, Ma Z, et al. F5-tts: A fairytaler that fakes fluent and faithful speech with flow matching[J]. arXiv preprint arXiv:2410.06885, 2024.
- [21] Tong A, Malkin N, Hugué G, et al. Conditional flow matching: Simulation-free dynamic optimal transport[J]. arXiv preprint arXiv:2302.00482, 2023, 2(3).
- [22] Peebles W, Xie S. Scalable diffusion models with transformers[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 4195-4205.
- [23] Choi Y, Choi M, Kim M, et al. Stargan: Unified generative adversarial networks for multi-domain image-to-image translation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 8789-8797.
- [24] Lee Y, Rabiee A, Lee S Y. Emotional end-to-end neural speech synthesizer[J]. arXiv preprint arXiv:1711.05447, 2017.
- [25] Tits N, El Haddad K, Dutoit T. Exploring transfer learning for low resource emotional tts[C]//Intelligent Systems and Applications: Proceedings of the 2019 Intelligent Systems Conference (IntelliSys) Volume 1. Springer International Publishing, 2020: 52-60.
- [26] Tits N, Wang F, Haddad K E, et al. Visualization and interpretation of latent spaces for controlling expressive speech synthesis through audio analysis[J]. arXiv preprint arXiv:1903.11570, 2019.
- [27] Jing Y, Yang Y, Feng Z, et al. Neural style transfer: A review[J]. IEEE transactions on visualization and computer graphics, 2019, 26(11): 3365-3385.
- [28] Shen J, Pang R, Weiss R J, et al. Natural tts synthesis by conditioning wavenet on mel spectrogram predictions[C]//2018 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2018: 4779-4783.
- [29] Skerry-Ryan R J, Battenberg E, Xiao Y, et al. Towards end-to-end prosody transfer for expressive speech synthesis with tacotron[C]//international conference on machine learning. PMLR, 2018: 4693-4702.
- [30] Wang Y, Stanton D, Zhang Y, et al. Style tokens: Unsupervised style modeling, control and transfer in end-to-end speech synthesis[C]//International conference on machine learning. PMLR, 2018: 5180-5189.
- [31] Ju Z, Wang Y, Shen K, et al. Naturalspeech 3: Zero-shot speech synthesis with factorized codec and diffusion models[J]. arXiv preprint arXiv:2403.03100, 2024.
- [32] Wu H, Wang X, Eskimez S E, et al. Laugh Now Cry Later: Controlling Time-Varying Emotional States of Flow-Matching-Based Zero-Shot Text-To-Speech[C]//2024 IEEE Spoken Language Technology Workshop (SLT). IEEE, 2024: 690-697.
- [33] Russell J A. A circumplex model of affect[J]. Journal of personality and social psychology, 1980, 39(6): 1161.
- [34] Wagner J, Triantafyllopoulos A, Wierstorf H, et al. Dawn of the transformer era in speech emotion recognition: closing the valence gap[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(9): 10745-10759.

- [35] Cho D H, Oh H S, Kim S B, et al. EmoSphere++: Emotion-Controllable Zero-Shot Text-to-Speech via Emotion-Adaptive Spherical Vector[J]. arXiv preprint arXiv:2411.02625, 2024.
- [36] Cowen A S, Elfenbein H A, Laukka P, et al. Mapping 24 emotions conveyed by brief human vocalization[J]. American Psychologist, 2019, 74(6): 698.
- [37] Lorenzo-Trueba J, Henter G E, Takaki S, et al. Investigating different representations for modeling and controlling multiple emotions in DNN-based speech synthesis[J]. Speech Communication, 2018, 99: 135-143.
- [38] Choi H, Hahn M. Sequence-to-sequence emotional voice conversion with strength control[J]. IEEE Access, 2021, 9: 42674-42687.
- [39] Schnell B, Garner P N. Improving emotional TTS with an emotion intensity input from unsupervised extraction[C]//Proc. 11th ISCA Speech Synth. Workshop. 2021: 60-65.
- [40] Zhang G, Qin Y, Zhang W, et al. iemotts: Toward robust cross-speaker emotion transfer and control for speech synthesis based on disentanglement between prosody and timbre[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2023, 31: 1693-1705.
- [41] Zhou K, Sisman B, Rana R, et al. Emotion intensity and its control for emotional voice conversion[J]. IEEE Transactions on Affective Computing, 2022, 14(1): 31-48.
- [42] Lei Y, Yang S, Wang X, et al. Msemotts: Multi-scale emotion transfer, prediction, and control for emotional speech synthesis[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2022, 30: 853-864.
- [43] Kalyan P, Rao P, Jyothi P, et al. Emotion arithmetic: Emotional speech synthesis via weight space interpolation[C]//Proc. Interspeech 2024. 2024: 1805-1809.
- [44] 孙继平, 余星辰. 基于声音识别的煤矿重特重大事故报警方法研究[J]. 工矿自动化, 2021, 47(02): 1-5+44. DOI:10.13272/j.issn.1671-251x.17715.
- [45] Sun C, Zhang Q, Wang J, et al. Noise reduction based on robust principal component analysis[J]. Journal of Computational Information Systems, 2014, 10(10): 4403-4410.
- [46] Mavaddaty S, Ahadi S M, Seyedin S. A novel speech enhancement method by learnable sparse and low-rank decomposition and domain adaptation[J]. Speech Communication, 2016, 76: 42-60.
- [47] Min G, Zhang X, Yang J, et al. A perceptually motivated approach via sparse and low-rank model for speech enhancement[C]//2016 IEEE International Conference on Multimedia and Expo (ICME). IEEE, 2016: 1-6.
- [48] 史兆丰, 夏秀渝. 基于语音稀疏性的频域声回波对消算法研究[J]. 四川大学学报(自然科学版), 2013, 50(02): 311-316.
- [49] Kammi S, Mollaei M R K. Noisy speech enhancement with sparsity regularization[J]. Speech Communication, 2017, 87: 58-69.
- [50] 隗雪梅. 基于语音稀疏性的欠定信号盲分离研究[D]. 中国科学技术大学, 2014.
- [51] Purwins H, Li B, Virtanen T, et al. Deep learning for audio signal processing[J]. IEEE

- Journal of Selected Topics in Signal Processing, 2019, 13(2): 206-219.
- [52] LeCun Y, Bengio Y. Convolutional networks for images, speech, and time series[J]. The handbook of brain theory and neural networks, 1995, 3361(10): 1995.
- [53] Mikolov T, Karafiát M, Burget L, et al. Recurrent neural network based language model[C]//Interspeech. 2010, 2(3): 1045-1048.
- [54] Graves A, Graves A. Long short-term memory[J]. Supervised sequence labelling with recurrent neural networks, 2012: 37-45.
- [55] Cho K, Van Merriënboer B, Gulcehre C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[J]. arXiv preprint arXiv:1406.1078, 2014.
- [56] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [57] 杨宜涛. 面向小样本的个性化中文语音合成研究 [D]. 华南理工大学, 2022. DOI:10.27151/d.cnki.ghnlu.2022.004252.
- [58] Ba J L, Kiros J R, Hinton G E. Layer normalization[J]. arXiv preprint arXiv:1607.06450, 2016.
- [59] Li N, Liu S, Liu Y, et al. Neural speech synthesis with transformer network[C]//Proceedings of the AAAI conference on artificial intelligence. 2019, 33(01): 6706-6713.
- [60] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18. Springer international publishing, 2015: 234-241.
- [61] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [62] Zhang H, Sproat R, Ng A H, et al. Neural models of text normalization for speech applications[J]. Computational Linguistics, 2019, 45(2): 293-337.
- [63] Elias I, Zen H, Shen J, et al. Parallel Tacotron 2: A non-autoregressive neural TTS model with differentiable duration modeling[J]. arXiv preprint arXiv:2103.14574, 2021.
- [64] Arik S Ö, Chrzanowski M, Coates A, et al. Deep voice: Real-time neural text-to-speech[C]//International conference on machine learning. PMLR, 2017: 195-204.
- [65] Gibiansky A, Arik S, Damos G, et al. Deep voice 2: Multi-speaker neural text-to-speech[J]. Advances in neural information processing systems, 2017, 30.
- [66] Ping W, Peng K, Gibiansky A, et al. Deep voice 3: Scaling text-to-speech with convolutional sequence learning[J]. arXiv preprint arXiv:1710.07654, 2017.
- [67] Ping W, Peng K, Chen J. Clarinet: Parallel wave generation in end-to-end text-to-speech[J]. arXiv preprint arXiv:1807.07281, 2018.
- [68] Fan D P, Ji G P, Zhou T, et al. Pranet: Parallel reverse attention network for polyp segmentation[C]//International conference on medical image computing and computer-

- assisted intervention. Cham: Springer International Publishing, 2020: 263-273.
- [69] Wu Z, Li Q, Liu S, et al. Dctts: Discrete diffusion model with contrastive learning for text-to-speech generation[C]//ICASSP 2024-2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2024: 11336-11340.
- [70] Valin J M, Skoglund J. LPCNet: Improving neural speech synthesis through linear prediction[C]//ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019: 5891-5895.
- [71] Prenger R, Valle R, Catanzaro B. Waveglow: A flow-based generative network for speech synthesis[C]//ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019: 3617-3621.
- [72] Ping W, Peng K, Zhao K, et al. Waveflow: A compact flow-based model for raw audio[C]//International Conference on Machine Learning. PMLR, 2020: 7706-7716.
- [73] Donahue C, McAuley J, Puckette M. Adversarial audio synthesis[J]. arXiv preprint arXiv:1802.04208, 2018.
- [74] Kumar K, Kumar R, De Boissiere T, et al. Melgan: Generative adversarial networks for conditional waveform synthesis[J]. Advances in neural information processing systems, 2019, 32.
- [75] Kong J, Kim J, Bae J. Hifi-gan: Generative adversarial networks for efficient and high fidelity speech synthesis[J]. Advances in neural information processing systems, 2020, 33: 17022-17033.
- [76] Kong Z, Ping W, Huang J, et al. Diffwave: A versatile diffusion model for audio synthesis[J]. arXiv preprint arXiv:2009.09761, 2020.
- [77] Chen N, Zhang Y, Zen H, et al. Wavegrad: Estimating gradients for waveform generation[J]. arXiv preprint arXiv:2009.00713, 2020.
- [78] Lee S, Kim H, Shin C, et al. Priorgrad: Improving conditional denoising diffusion models with data-dependent adaptive prior[J]. arXiv preprint arXiv:2106.06406, 2021.
- [79] Woo S, Debnath S, Hu R, et al. Convnext v2: Co-designing and scaling convnets with masked autoencoders[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 16133-16142.
- [80] Lipman Y, Chen R T Q, Ben-Hamu H, et al. Flow matching for generative modeling[J]. arXiv preprint arXiv:2210.02747, 2022.
- [81] Chen R T Q, Rubanova Y, Bettencourt J, et al. Neural ordinary differential equations[J]. Advances in neural information processing systems, 2018, 31.
- [82] Dhariwal P, Nichol A. Diffusion models beat gans on image synthesis[J]. Advances in neural information processing systems, 2021, 34: 8780-8794.
- [83] Ho J, Salimans T. Classifier-free diffusion guidance[J]. arXiv preprint arXiv:2207.12598, 2022.
- [84] Liu S, Su D, Yu D. Diffgan-tts: High-fidelity and efficient text-to-speech with denoising diffusion gans[J]. arXiv preprint arXiv:2201.11972, 2022.
- [85] Siuzdak H. Vocos: Closing the gap between time-domain and fourier-based neural

- vocoders for high-quality audio synthesis[J]. arXiv preprint arXiv:2306.00814, 2023.
- [86] Lee S, Ping W, Ginsburg B, et al. Bigvgan: A universal neural vocoder with large-scale training[J]. arXiv preprint arXiv:2206.04658, 2022.
- [87] Todi A, Narula N, Sharma M, et al. ConvNext: A contemporary architecture for convolutional neural networks for image classification[C]//2023 3rd International Conference on Innovative Sustainable Computational Technologies (CISCT). IEEE, 2023: 1-6.
- [88] Ma Z, Zheng Z, Ye J, et al. emotion2vec: Self-supervised pre-training for speech emotion representation[J]. arXiv preprint arXiv:2312.15185, 2023.
- [89] Radford A, Kim J W, Xu T, et al. Robust speech recognition via large-scale weak supervision[C]//International conference on machine learning. PMLR, 2023: 28492-28518.
- [90] Zhou K, Sisman B, Liu R, et al. Emotional voice conversion: Theory, databases and esd[J]. Speech Communication, 2022, 137: 1-18.
- [91] Loshchilov I, Hutter F. Decoupled weight decay regularization[J]. arXiv preprint arXiv:1711.05101, 2017.
- [92] Huang R, Ren Y, Liu J, et al. Generspeech: Towards style transfer for generalizable out-of-domain text-to-speech[J]. Advances in Neural Information Processing Systems, 2022, 35: 10970-10983.
- [93] Zhou K, Sisman B, Rana R, et al. Emotion intensity and its control for emotional voice conversion[J]. IEEE Transactions on Affective Computing, 2022, 14(1): 31-48.
- [94] Parikh D, Grauman K. Relative attributes[C]//2011 International conference on computer vision. IEEE, 2011: 503-510.
- [95] Zhu X, Yang S, Yang G, et al. Controlling emotion strength with relative attribute for end-to-end speech synthesis[C]//2019 IEEE Automatic Speech Recognition and Understanding Workshop (ASRU). IEEE, 2019: 192-199.
- [96] Lei Y, Yang S, Xie L. Fine-grained emotion strength transfer, control and prediction for emotional speech synthesis[C]//2021 IEEE Spoken Language Technology Workshop (SLT). IEEE, 2021: 423-430.
- [97] Schnell B, Garner P N. Improving emotional TTS with an emotion intensity input from unsupervised extraction[C]//Proc. 11th ISCA Speech Synth. Workshop. 2021: 60-65.
- [98] Um S Y, Oh S, Byun K, et al. Emotional speech synthesis with rich and granularized control[C]//ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2020: 7254-7258.
- [99] Im C B, Lee S H, Kim S B, et al. Emoq-tts: Emotion intensity quantization for fine-grained controllable emotional text-to-speech[C]//ICASSP 2022-2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2022: 6317-6321.

DISSERTATION FOR PROFESSIONAL MASTER'S DEGREE

