



分类号: TP391 密 级: 公开
UDC: 学校代码: 10127

内蒙古科技大学

硕士学位论文

论文题目: 基于多模态信息融合的中文隐式情感分
析

英文题目: Implicit Sentiment Analysis for Chinese
texts based on Multimodal Information
Fusion

学 位 类 别: 电子信息硕士
研 究 生 姓 名: 李梦云 学号: 2022022378
学 科 (领 域) 名 称: 计算机技术
指 导 教 师: 张晓琳 职称: 教授
协 助 指 导 教 师: 张焕香 职称: 副教授

2025 年 6 月 5 日

摘 要

情感分析是智能化人机交互的基础，是自然语言处理领域的重要研究方向之一。根据表达层面是否包含显式情感词，情感分析分为显式和隐式情感分析。隐式情感表达因其能够规避敏感内容审查而在社交媒体中愈发常见。这类隐式情感表达通常含蓄隐晦，缺乏显著的情感词，并依赖于复杂的语境来传递情感信息，这使得传统基于词典和语料库的情感分析方法难以有效识别情感，给隐式情感分类研究带来显著挑战。因此，深入分析这类隐式情感表达，对理解用户真实情感、监测舆情变化以及支持商业决策等领域具有重要的学术和应用价值。

随着各类在线社交媒体平台（如新浪微博、Instagram 和抖音等）的蓬勃发展，越来越多的人通过视频内容表达个人观点和情感倾向，这为隐式情感分析研究提供了丰富的数据来源。这些包含视觉与语音信息的多模态特征，能够有效弥补纯文本在情感传递中的不足。针对隐式情感表达晦涩、主观性较强以及现有隐式情感分析方法在捕捉深层语义特征方面的局限性，本文通过结合语音、视觉等多模态方法，从不同维度获取情感信息，深入挖掘其他模态的语境信息，探讨不同模态特征对隐式情感分析的影响，以提高隐式情感分析性能。主要贡献如下：

（1）为解决隐式情感表达中隐含信息难以捕捉的问题，本文提出一种融合语音和视频的多模态特征的隐式情感分析方法。该方法通过提取音调、强度等声学特征，以及捕捉视频中面部表情等视觉特征，辅助理解隐式情感。利用 BiLSTM 提取单模态数据的时序相关特征，并结合多头互注意力机制分别提取与文本相关的语音和视觉特征。通过多次迭代优化，减少非文本模态的低阶冗余信息。同时，构建以文本特征主导的交叉注意融合机制，有效处理多模态数据间的异质性问题，强化隐式文本特征表示。在 CMU-MOSI、CMU-MOSEI、CMSIED 数据集上的实验结果表明，所提出的模型优于其他基线模型。该多模态处理策略充分利用语音和视觉外部知识，更全面、准确地捕捉隐式情感表达，有效提升了隐式情感分析的准确率。

（2）隐喻作为一种丰富而形象的情感表达方式，理解不仅需要依托语境，更涉及多维度认知资源的整合。即使是当前强大的大语言模型（如 GPT）在捕捉隐喻所蕴含的复杂情感意图时仍面临显著挑战。为解决这一问题，本文提出一种基于思维链提示结合生成模型的方法，通过融合图像和语音情感特征来推理隐喻情感。具体

地，思维链提示指导模型逐步生成与文本内容相匹配的相关视觉和语音信息，利用生成的多模态数据丰富情感表达以弥补单一文本的不足。同时考虑到信息生成过程中可能出现的错误信息干扰，设计了一种多模态渐进式融合策略以优化信息整合。在 CCL2018 和 VUA 数据集上的实验结果表明，所提出的图像和语音辅助文本的方法不仅提升了隐喻文本情感分析的性能，还有效捕捉了多模态特征间的隐喻关联。此外，该方法还在一定程度上简化了数据采集流程，为当前大语言模型在处理隐喻文本情感分析时的局限性提供了新的解决思路。

关键词：隐式情感分析；多模态；注意力机制；隐喻识别；数据增强

Abstract

Sentiment analysis serves as the foundation for intelligent human-computer interaction and represents a crucial research direction in the field of natural language processing. Based on whether the expression contains explicit sentiment words, sentiment analysis can be categorized into explicit and implicit sentiment analysis. Implicit sentiment expressions have become increasingly prevalent on social media due to their ability to circumvent sensitive content censorship. Such implicit expressions are typically subtle and indirect, lacking overt sentiment words while relying on complex contextual cues to convey emotional information. This characteristic renders traditional lexicon- and corpus-based sentiment analysis methods ineffective for emotion recognition, posing significant challenges to implicit sentiment classification research. Consequently, in-depth analysis of these implicit expressions holds substantial academic and practical value for understanding genuine user emotions, monitoring public opinion trends, and supporting business decision-making.

With the rapid development of various online social media platforms (e.g., Sina Weibo, Instagram, and TikTok), an increasing number of users express personal opinions and emotional tendencies through video content, providing abundant data sources for implicit sentiment analysis research. These multimodal features incorporating visual and auditory information can effectively compensate for the limitations of pure text in emotion transmission. Addressing the challenges of obscure implicit expressions, strong subjectivity, and the limitations of existing methods in capturing deep semantic features, this study employs a multimodal approach integrating auditory and visual information to extract emotional cues from different dimensions. By thoroughly exploring contextual information across modalities, we investigate the impact of various modal features on implicit sentiment analysis to enhance performance. The main contributions are as follows:

(1) To address the difficulty in capturing implicit information within sentiment expressions, this paper proposes a multimodal implicit sentiment analysis method combining

acoustic and visual features. The approach extracts acoustic characteristics (e.g., pitch and intensity) and visual features (e.g., facial expressions) to facilitate implicit emotion understanding. BiLSTM is employed to capture temporal correlations in unimodal data, while a multi-head mutual attention mechanism separately extracts speech and visual features relevant to the text. Through iterative optimization, low-level redundant information from non-text modalities is reduced. Simultaneously, a text-dominated cross-attention fusion mechanism is constructed to effectively handle heterogeneity among multimodal data and enhance implicit textual feature representation. Experimental results on CMU-MOSI, CMU-MOSEI, and CMSIED datasets demonstrate that the proposed model outperforms other baseline models. This multimodal processing strategy leverages external knowledge from speech and vision to more comprehensively and accurately capture implicit emotional expressions, significantly improving analysis accuracy.

(2) As a rich and figurative form of emotional expression, metaphor comprehension requires not only contextual support but also the integration of multidimensional cognitive resources. Even state-of-the-art large language models (e.g., GPT) face significant challenges in capturing the complex emotional intentions embedded in metaphors. To address this issue, we propose a chain-of-thought prompting approach combined with a generative model, which reasons about metaphorical emotions by integrating image and speech sentiment features. Specifically, chain-of-thought prompting guides the model to progressively generate relevant visual and auditory information matching the textual content, using the generated multimodal data to enrich emotional expression and compensate for textual limitations. Considering potential misinformation during generation, a progressive multimodal fusion strategy is designed to optimize information integration. Experiments on CCL2018 and VUA datasets show that the proposed image- and speech-assisted text method not only improves metaphor sentiment analysis performance but also effectively captures metaphorical relationships among multimodal features. Furthermore, this approach simplifies data collection processes to some extent, offering novel solutions to current

limitations of large language models in metaphorical sentiment analysis.

Key Words: *Implicit Sentiment Analysis; Multimodal; Attention Mechanism; Metaphor Recognition; Data Augmentation*

目 录

1 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	3
1.2.1 显式情感分析.....	3
1.2.2 事实型隐式情感分析.....	4
1.2.3 修辞型隐式情感分析.....	4
1.2.4 隐式数据集.....	6
1.3 本文研究内容.....	7
1.4 论文章节安排.....	8
2 相关理论和技术基础	9
2.1 多模态特征提取.....	9
2.1.1 文本特征提取.....	9
2.1.2 语音特征提取.....	9
2.1.3 视觉特征提取.....	10
2.2 双向长短期记忆融合网络	11
2.3 注意力机制.....	12
2.4 预训练语言模型.....	15
2.4.1 BERT 模型.....	15
2.4.2 Chat GPT.....	16
2.5 扩散模型.....	18
2.5.1 文本-语音扩散模型	19
2.5.2 文本-图像扩散模型	21
2.6 提示学习.....	22
2.7 本章小结.....	24
3 基于语音和视觉特征辅助的中文隐式文本情感分析	25
3.1 引言.....	25
3.2 CMSIED 数据集	25
3.2.1 数据收集.....	26
3.2.2 标注.....	26
3.2.3 数据集的分析与应用.....	27
3.3 TIMISA 模型	27
3.3.1 单模态特征提取.....	28
3.3.2 跨模态特征融合	29
3.3.3 文本交叉注意力协同网络.....	31

3.3.4 情感分类.....	33
3.3.5 损失函数.....	33
3.4 实验结果与分析.....	34
3.4.1 实验数据集.....	34
3.4.2 实验环境与参数设置.....	34
3.4.3 评价指标.....	36
3.4.4 实验结果分析.....	37
3.4.5 消融实验.....	39
3.4.6 案例分析.....	42
3.4.7 可视化分析.....	43
3.5 本章小结.....	44
4 基于思维链提示生成多模态辅助中文隐喻情感分析方法	45
4.1 引言.....	45
4.2 Co T-CMMSA 模型.....	46
4.2.1 隐喻识别与文本增强.....	47
4.2.2 基于隐喻的图像与语音生成.....	49
4.2.3 特征提取及表示.....	51
4.2.4 以文本引导的多模态渐进融合.....	52
4.2.5 情感分类.....	54
4.3 实验结果与分析.....	55
4.3.1 实验数据集.....	56
4.3.2 实验环境和参数配置.....	56
4.3.3 评价指标.....	56
4.3.4 对比实验结果分析.....	57
4.3.5 消融实验.....	58
4.3.6 案例研究.....	62
4.4 本章小结.....	64
5 结论与展望.....	66
5.1 结论.....	66
5.2 工作展望.....	67
参考文献.....	68

1 绪论

1.1 研究背景和意义

21 世纪,信息技术革命的浪潮推动了移动互联网的普及,深刻改变了人们的日常生活,标志着我们进入了信息丰富的数字化时代。微博、TikTok、Facebook、Twitter、知乎等社交网络平台蓬勃发展,从购物、娱乐到学习和工作,用户能够随时获取所需信息并参与讨论。《中国互联网络发展状况统计报告》显示,截至 2025 年 1 月,我国互联网用户总量达 11.08 亿,互联网普及率提升至 78.6%^[1]。随着社交网络数据规模的不断扩大,产生了大量蕴含情感倾向的视频评论信息,并且,为避免社会敏感性,用户评论中的情感表达变得更加多样和隐晦。这些视频数据不仅反映了用户真实的情感状态,还为舆情监测分析提供了重要参考。由于新媒体传播速度快、实时性强,及时掌控网络舆情尤为重要,利用自然语言处理技术对用户评论进行情感分析,计算机可以更好地理解人类的情感倾向,帮助企业 and 政府更好地理解用户需求、优化决策^[2]。

自然语言处理(Natural Language Processing, NLP)是一种使计算机具备理解和分析人类语言能力的技术,广泛应用于人机交互、文本和语音信息处理等多个领域。情感作为人类基本的心理状态,对认知、行为以及身心健康产生深远影响。情感分析作为 NLP 中的一个重要研究分支,其目标是通过挖掘文本中的主观性特征、观点立场、情绪状态及情感极性,来识别和分类情感倾向^[3]。通常,情感分类包括积极、消极和中性三种基本类型。但实际应用中也可以根据具体需求进一步细分,如愤怒、快乐、悲伤等特定情绪类别。根据实际数据的特点,情感分析主要包含显式情感分析和隐式情感分析。其中,显式情感分析主要聚焦于文本中的显式情感词,隐式情感分析则处理不包含明显情感词,但传递主观情感的语言片段,通过分析语音、肢体语言和面部表情等非语言信号来识别情感。中文作为一种高度复杂的自然语言,其情感表达的形式丰富多样,情感信息既可以通过明确的情感词汇传递,也可以借助隐含的语言结构和语境进行表达^[4]。在汉语中,近 15%-20%的句子包含隐式情感表达^[5],以抖音、微博等社交媒体平台为例,受制于敏感词过滤机制,人们更倾向于通过名义隐喻或习语等方式表达抽象的概念与观点。这类文本通常缺乏明确的情感线索,在增强语言生动性的同时也提升了理解难度,往往蕴含着更为强烈的情感内涵。这种特殊的表达方式使得传统显式情感分析模型难以准确捕捉文本的

情感特征，从而影响对隐含情感极性的有效预测。

根据表达特征，隐式情感分为事实描述型与修辞表达型两类。具体示例如表 1.1 所示。事实型隐式情感表达主要通过客观陈述传递情感，文本中不直接出现情感词。如 E1 通过描述公园绿化的独特性，间接传达了欣赏或认可的积极情绪。修辞型隐式情感则借助隐喻、反问、讽刺等修辞手法暗示情感倾向。其中，隐喻是通过概念映射传递情感信息，如 E2 将“生活”比喻为“一场马拉松”，虽未使用显性情感词，但暗示了生活的漫长与疲惫，传递了负面情绪。反讽是通过表面与实际含义的反差来表达情感，通常带有否定意味。E3 通过反讽的语气批评演讲内容糟糕，表达了嘲讽或不满的负面情绪。相比之下，示例 E4 直接使用显式情感词“兴奋”明确表达了积极情绪。

表 1.1 隐式情感句示例

示例	隐式情感类型	情感类别
E1：这座公园的绿化设计独具匠心。	事实型隐式情感句	积极
E2：生活就像一场马拉松。	修辞型隐式情感句	消极
E3：他的演讲真是“精彩”到让人无法忍受。	反讽型隐式情感句	消极
E4：我对这次旅行的体验感到无比兴奋！	显式情感句	积极

作为自然语言处理（NLP）领域的新兴研究方向，隐式情感分析在智能对话系统、政治话语分析和机器翻译等 NLP 任务具有广泛的应用前景。然而，隐式情感分析的复杂性在于情感表达的隐晦性需要更深入的理解语言的语境和背景，现有的文本单模态模型难以全面捕捉隐式情感，分类效果欠佳。人际交流从单一模态的表达逐步向多样模态的协同沟通转变，结合语言和视觉表征的联合模型为隐式情感分析提供了新的研究方向。尽管多模态数据提供了丰富的情感信息，但其融合技术仍面临诸多挑战。当前方法在模态融合过程中未能充分考虑模态间的差异及权重分配问题，简单融合各模态特征难以达到预期效果。此外，不同语言和文化背景下的隐式情感表达方式各不相同，如何在多模态融合和跨语言文化背景下准确分析隐式情感，成为了当前学术界广泛关注的热点问题。

综上所述，目前，结合多模态的隐式情感分析研究仍处于探索阶段，亟需进一步深入研究。在显式情感线索有限的情况下，利用非文本特征（如视觉、语音等）

增强文本语义，有助于模型更准确地识别和提取隐含情感，有效解决隐式情感分析中情感信息不足的问题^[6]。同时，通过挖掘不同模态数据间隐含的互补信息，可以更全面地获取情感特征，为隐式情感分析提供了新的研究思路和方法，具有重要的学术意义和研究价值。

1.2 国内外研究现状

文本情感分析作为自然语言处理领域中的一个重要研究方向之一，具有广泛的应用和商业价值。目前，文本情感分析的国内外研究工作已经取得了大量的研究成果，其中显式情感分析的技术发展相对成熟^[7,8]。而隐式情感分析的研究仍处于初步发展阶段，这主要源于其情感表达缺乏明显的情感特征，分析难度较大。近年来，情感分析方法从传统的机器学习方法转向预训练语言模型架构。然而，在隐式情感分析任务中，由于缺乏足够的标注数据，预训练模型往往难以达到预期效果。为了解决这一问题，部分研究者提出了跨领域知识迁移策略来微调模型^[9]，但该方法对领域外的大规模数据集依赖性较强。随着多模态信息交互技术的发展，研究者们发现仅靠文本数据难以满足更为细致的情感分析，因此提出结合语音、视觉等多模态特征来辅助分析隐式情感，在复杂场景下的隐式情感分析任务上取得优异的性能。本节将从显式情感分析、事实型隐式情感分析、修辞型隐式情感分析和隐式多模态数据集四个方面的国内外研究现状展开介绍。

1.2.1 显式情感分析

显式情感分析的核心在于自动识别并分类文本中所蕴含的情感倾向。早期研究主要采用基于词典的方法、朴素贝叶斯、支持向量机（SVM）和最大熵分类器等技术，将文档或句子划分为积极或消极情绪两大情感类别。Li 等人^[10]提出了一种结合 SO-PMI 算法分析情感词语义相似度的方法，通过扩展情感词典和语义规则进行微博情感分析。Irfan 等人^[11]提出了混合的上下文感知推荐框架 SocialRec，通过整合用户文本评论与协同过滤，利用情绪得分实现个性化推荐。Zhang 等人^[12]开发了一种融合朴素贝叶斯、决策树和支持向量机的政务微博情感分析框架，用于计算政务微博文本的情感倾向和强度。

最近，深度学习方法在文本情感分析和分类中发挥了重要作用，其能够自动从数据中学习具有更高抽象和表现力的特征表示，避免了手动设计特征所带来的限

制。GRU 和循环神经网络（RNN）逐渐成为显式情感分析和分类任务中的主流模型。Xu 等人^[13]采用双向门控递归单元（GRU）模型进行情感分析，通过词云模型解析六类情感标签文本，并通过数据预处理确保数据纯度，实现对文本情感的有效分类。He 等人^[14]提出了一种混合模型 BERT-CNN-BiLSTM-Att，用于分析豆瓣电影评论，解决了文本情感分析过程中的多义词和特征提取问题。Jiang 等人^[15]提出了一种集成了 K-means++、SMOTE、CNN 和 Bi-LSTM 模型的文本情感分析分类模型 KSCB，通过优化情感语料库分布，消除不平衡问题，提高文本情感分类的准确性。

1.2.2 事实型隐式情感分析

基于事实的隐式情感通过陈述客观事实来表达情感，大部分研究通常借助外部知识的方法进行情感分析。早期的研究主要依赖情感词典（如 General Inquirer 和 Opinion Lexicon）来获取文本的情感标签，但人工构建情感词典成本高昂且难以覆盖所有情感词汇。此外，基于规则的方法依靠手工对知识和词典资源进行编码。Nam 等人^[16]通过双重过滤机制对齐隐式特征来优化预测标签，实现方面情感的自动分类。Liao 等人^[5]提出一种基于语义依赖树的 SDT-CNN 融合模型，用于识别事实隐含情感识别及其极性分类。Greene 和 Resnik^[17]通过构建主题与隐式情感的关联，并利用语义计算主题相似性来确定隐式情感。近年来，深度学习开始应用于自然语言处理研究中，研究者们通过借助各种深度神经网络模型分析隐式情感^[18]。Zhou 等人^[19]提出了一种基于层次张量组合的多任务学习框架，利用句子中包含的情感感知事件（包括事件三元组和事件类型）作为特征，实现事件类型分类和情感分类。Zhang 等人^[20]通过将文本序列与关联图像进行语义编码，并融合多模态常识知识，提升了模型在识别和分析反事实类隐式情感方面的能力。以往这些隐式情感处理的工作主要依靠文本特征和外部知识来构建模型，在处理隐式文本时存在一定局限性。相关研究表明，人们认识隐式情感建立在语言理解及感官经验上的，面部表情、语音语调等多模态特征也是分析隐式情感的重要因素^[21]。Shutova 等人^[22]首次提出结合文本与视觉特征的方法，通过用视觉特征丰富文本词嵌入表示实现隐喻识别。Chen 等人^[23]通过将文本转换为词频图，聚合同一情感极性文本中的情感词并提升其权重，从而突出不同隐式情感文本的情绪极性差异，提高中文隐式情感分类性能。

1.2.3 修辞型隐式情感分析

隐喻、讽刺等修辞手法是隐式情感分析中的重要表达方式，其中隐喻情感的识别与分类是当前研究的重点。作为一种语言现象，隐喻通过具象化表达实现对抽象概念的阐释与理解^[24]。隐喻情感分析旨在识别并理解文本中隐喻表达的深层情感含义，通常通过比喻等抽象表达传递情感信息，其背后的情感含义可能不会直接表达，这种非字面意义的转换增加了情感分析的难度，使得传统的情感分析方法在处理隐喻时效果有限。

早期的研究主要关注于文本数据中的隐喻处理。Wilks^[25]最早从语言学和认知学的层面，将隐喻定义为隐喻表达与其语境关系矛盾的表达形式。Rentoumi^[26]通过解析隐喻表达中的词义来判定句子的整体情感。Touahri 等人^[27]采用跨方言词典结合讽刺和攻击性词汇特征，提高了情感分析的准确率。这些早期方法主要依靠手工编写的规则和词典资源，尽管这种方法简单直观，但字典包含的特定于领域的信息很少，在处理间接的隐喻性语言时往往效果有限。随着机器学习和深度学习技术在各种 NLP 任务中的广泛应用，它们也开始用于隐喻情感分析。如 Gao 等人^[28]提出了一个带有语境化词表示的 BiLSTM 模型用于隐喻检测。Liu 等人^[29]使用 BERT 和 XLNet 语言模型来识别给定的单词是否为隐喻。

近年来，一些研究工作采用多任务学习和迁移学习的方法，将隐喻识别和情感分析结合在统一框架中。Yang^[30]等人结合双层注意力机制和图卷积网络实现对隐喻语义和结构信息的精细捕捉。Mao 等人^[31]开发的端到端隐喻处理模型 MetaPro，通过共同学习隐喻识别和词性标注，提升隐喻情感分析分类器的性能。但这种方法无法处理非英语文本、扩展隐喻和隐喻推理。此外，训练数据不足会导致模型学习能力与数据复杂度不匹配，从而影响特征提取和实际应用效果。为解决数据稀缺问题，研究者们通过扩充数据集或增强数据特征来提升模型性能。Ng^[32]采用随机屏蔽和预测被屏蔽的标记来增强文本的多样性。Huang 等人^[33]结合 SimBERT^[34]集成词汇依赖关系和同义词去噪训练，优化特征提取和语义表示。Zheng^[35]提出基于词嵌入相似度选择候选概念填充模板。上述数据增强方法往往在句子层面操作，增强过程中可能会无意中改变句子的隐喻成分。同时，以 GPT、GPT-3^[36]和 BART^[37]为代表的生成语言模型（LLMs）在隐喻识别中展现出强大的能力。Wachowiak 和 Gromann^[38]系统评估了 GPT-3 在无预设域的情况下检测隐喻语言和预测隐喻源域的能力。Amin^[39]等人的研究表明，ChatGPT 模型在处理情感相关任务时优于传统的 NLP 方法，但在识别隐含信息方面仍存在不足。最近，Wei 等人^[40]提出的 CoT 提示

方法通过将复杂问题分解为中间推理步骤，增强语言模型中的推理能力。

这些研究侧重于将情感知识注入预训练语言模型，高度依赖情感词汇的质量，且通过掩码和重建任务训练时易导致信息丢失。即使是像 GPT 这样强大的模型，在处理隐喻文本时也常出现无法解释的错误，无法像处理显式情感那样提取高质量特征。为应对这一挑战，隐喻情感分析转向多模态数据，通过整合文本、声音和图像等信息来实现更全面的情感分析。Sharma^[41]等人通过融合图像和文本的特征，扩展了单一模态情感分析的范畴。Zhang^[42]提出了一个交互式图注意网络 M3GAT，用于多模态情绪和情绪联合识别。He^[43]等人通过图像与文本的双向交互增强视觉特征。Liu 等人^[44]通过评论和数据增强辅助视频语言对齐（CVLA）显著提升了幽默检测的准确率。如何有效处理隐喻的跨模态特征并提高隐喻情感分析的准确率，仍然是该领域未来研究的关键问题。

1.2.4 隐式数据集

NLP 领域发布的隐式数据集通常集中在隐喻文本的研究上。其中，VUA 和 MVSC^[45,46]是目前隐喻识别和语义理解任务中被广泛采用的英文数据集。Kozareva 等人^[47]创建了一个多语言隐喻数据集，涵盖约 600 个西班牙语和波斯语实例，以及 886 个俄语的例子。Nozza 等人^[48]创建了一个多视角情感语料库（MVSC），包含 3000 个与电影领域相关的英语微博帖子，涵盖主客观性、情感倾向性、隐/显性、讽刺和情感标注，是首个对表情符号进行明确标注的英文语料库。Zhang 等人^[49]创建了一个手工标注的中文隐喻语料库，该语料库包含 5,605 个不同实例和 101,616 个汉字，涵盖了快乐、愤怒、悲伤、恐惧、爱、厌恶以及惊讶七个精细的情感类别。SMP-ECISA2019^[50]是目前规模最大且应用最广泛的中文隐式情感分析数据集，其数据来源主要包括微博、马蜂窝、携程、汽车之家以及其他公共论坛，共包括 14774 个隐式情感句。Lu 等人^[51]创建了一个带注释的多语言 Twitter 情感理解语料库，包含 5,422 条推文，旨在更深入地挖掘社交媒体中的情感表达。大多数隐式数据集仅包含文本数据，隐式多模态数据集相对较少。Steen 等人^[52]提出的视觉隐喻数据集 VisMet，仅包含 353 个图像实例，其规模和覆盖范围都相对有限。Zhang 等人^[53]创建的多模态隐喻数据集（MultiMET）由 Twitter、Facebook 和广告等多种来源的 10,437 个文本-图像对组成，将隐喻理解从单一模态扩展至多模态。这些数据集主要以文本和简单图像为主，并未考虑视频中丰富的多模态信息，导致其在隐式情感分

析中的应用潜力未得到全面挖掘。

综上所述，隐式情感分析相较于显式情感分析尚不成熟。尽管该领域已经提出多种方法并取得一定进展，但多模态隐式情感分析仍未受到足够重视。随着多媒体技术的发展，文本与图像、视频的結合愈发普遍，推动了隐式情感研究从单模态向多模态发展。特别是在隐式文本中，情感表达更含蓄，给 NLP 技术提出了更高的要求，通过有效整合多模态特征，能够显著提升隐式情感分析性能。此外，近年来 NLP 发布的许多高质量大规模的隐式情感文本数据集主要集中于英文的单模态特征，中文多模态隐式情感资源较为匮乏，且现有的隐式情感分析领域的多模态模型融合策略过于简单，未能充分考虑不同模态间的交互信息。因此需要更复杂的多模态模型以提升隐式情感分析效果。

1.3 本文研究内容

隐式情感因缺乏明显的情感词汇而表达更为含蓄，导致传统情感分类模型难以提取文本的深层语义特征。现有研究多集中在文本特征分析层面，较少考虑其他模态特征，研究表明，隐式情感倾向与面部表情、语音语调等非语言特征密切相关。引入语音、视觉等多模态特征，能够有效提高模型对隐式文本的理解能力，从而更准确地捕捉潜在的情感线索。本文针对社交网络中中文隐式情感分析存在的情感分类准确率低以及情感特征不足等问题，通过增加多模态特征进行隐式情感分类研究，并取得了较好的效果，具体工作如下：

(1) 针对隐式情感表达中缺乏显式情感词的问题，提出一种融合多模态信息（包括语音和视频）的隐式情感分析方法。该方法通过提取不同模态特征并利用 BiLSTM 提取单模态数据的时序信息。结合多头互注意力机制分别捕捉与文本相关的语音和视觉特征，有效降低非文本模态的冗余数据。另外，设计了一种以文本为中心的交叉注意融合策略，增强隐式文本特征的表征能力，提升隐式情感分析的综合性能。充分利用语音和视觉外部知识理解隐式情感，从而有效提升隐式情感分析的准确率。

(2) 在前一个模型的分析中发现，隐喻作为一种特殊的隐含情感表达方式，其理解需要综合视觉和语音模态的信息。现存研究仅局限于模态间的表层融合，未能深入探索多模态隐喻内在的复杂性及充分地理解视觉、语音隐喻之间的紧密关联。因此，在现有模型的基础上，提出了一种基于思维链提示生成多模态辅助的中文隐

喻情感分析方法。通过结合生成模型从图像与语音中提取情感特征。并引入语音模态减少图像生成过程中可能会出现错误信息对结果的干扰。最后，通过多模态渐进式融合策略优化信息整合。证明了图像和语音辅助文本的方法不仅提升了隐喻文本情感分析的性能，还减少了数据采集过程的复杂度，有效捕捉文本和视觉、语音特征之间的隐喻关联。

1.4 论文章节安排

本节按章节顺序对论文的整体结构进行介绍：

第一章，绪论。介绍中文隐式情感分析的研究背景，阐述中文隐式情感分析研究的重要意义及所面临的挑战，并对国内外研究现状进行了系统的梳理与总结，最后简要说明本文的主要研究内容以及论文的结构安排。

第二章，相关理论和技术基础。详细介绍隐式情感分析研究的相关理论和技术，主要包括多模态特征处理的相关技术、常用的神经网络模型、预训练语言模型、扩散模型和大语言模型等。

第三章，基于多模态信息融合的中文隐式情感分析。首先引出研究所要解决的问题，然后详细介绍本文创建的 CMSIED 数据集及 TIMISA 模型的框架和构建过程。在实验部分对实验所用数据集、实验环境配置及模型评价指标进行简要说明，并通过与基线模型的对比实验和消融实验评估模型性能。最后进行案例分析与可视化分析，深入探讨引入多模态特征在隐式情感分析中的作用和影响。

第四章，基于思维链提示生成多模态辅助中文隐喻情感分析方法。首先分析现有隐喻情感分析方法存在的主要问题，接着详细介绍了 CoT-CMMSA 模型的整体框架以及具体实施步骤。最后通过对比实验、消融实验和案例分析对模型进行了全面评估与深入讨论。

第五章，总结与展望。简要总结了本文所做的研究内容和方法，分析研究过程中存在的问题和不足，并对中文隐式情感分析领域的未来发展方向进行展望。

2 相关理论和技术基础

随着互联网的普及，网络数据的表达形式愈加丰富多样，涵盖了视频、语音和文本等多种形式，极大地丰富了情感数据的来源。融合多模态特征（如视觉、语音）在分析隐式情感中展现出巨大潜力，尤其在捕捉用户隐含情感表达时，能够有效弥补文本单模态数据的不足，提高分析的准确性与全面性。跨模态特征融合要求模型不仅能够精准提取图像或语音信息，还需构建视觉、语音与文本之间的语义关联。本章介绍了本文所涉及的相关理论基础和关键技术，为后续研究提供理论支撑和技术支持。

2.1 多模态特征提取

2.1.1 文本特征提取

文本特征提取是从自然语言中提取关键词、短语、句子结构及上下文关系等信息的过程。常用的文本特征提取方法包括词袋模型（BoW）^[54]、词向量模型^[55]以及基于深度学习的方法。

词袋模型（BoW）通过统计词汇在文档中的出现频率，将非结构化文本转化为固定维度的数值特征向量，通过二进制分数、词频或 TF-IDF 分数（Term Frequency-Inverse Document Frequency）等多种计算方式计算向量中的每个元素的评分。TF-IDF 算法在 BoW 的基础上，通过引入逆文档频率（IDF）提升特定词汇的权重，减小高频词（如“the”、“is”等）的影响，增强特定词汇在文档表征中的区分度。分布式词向量模型则通过将词汇映射至低维连续向量空间，在大规模语料库预训练的基础上，实现了词汇间语义关系与相似性的有效捕捉，从而解决了传统高维稀疏表示所面临的计算效率问题。基于 BERT、Transformer^[56]等预训练语言模型通过自注意力机制捕捉单词之间复杂的上下文依赖关系，进行文本特征提取。本研究采用 BERT 模型提取文本特征，该模型通过预训练和微调，能够处理更长的文本，在多种自然语言处理任务中表现出色。

2.1.2 语音特征提取

语音特征作为一种连续信号，蕴含着丰富的情感、语调、语速等信息，能够有

效反映说话人的情绪状态。在情感计算领域，音高参数、能量分布以及语速变化等声学特征参数构成了情感识别的重要判别依据，特征提取的质量直接影响机器对语音信息的理解程度。早期的语音特征提取主要集中在声学特性分析上，常用的声学特征包括梅尔频率倒谱系数（MFCC）、语谱图（Spectrogram）等。语谱图作为一种时频域分析方法，通过时频联合分布直观呈现语音信号的频谱演变过程；而 MFCC 则是通过模拟人耳听觉特性语音信号提取的倒谱参数。近年来，Wav2Vec 2.0^[57]为代表的自监督学习模型被应用于语音特征提取，该模型通过在大规模无标注语音数据上进行预训练，在有限标注数据场景下仍能展现出良好的性能。

在情感分析领域，常用的声学特征提取工具包括 OpenSMILE^[58]、COVAREP^[59]、LibROSA^[60]等。OpenSMILE 结合语音处理和音乐信息检索领域的特征提取算法，能够提取 CHROMA、响度、MFCC、和感知线性预测倒谱系数（PLP）等特征。COVAREP 能够从每个视频剪辑的音轨中自动提取包括 12 个 mel 频倒谱系数、音高、浊音/浊音分割特征、峰斜率参数等与情感和语调相关的声学特征。

本文使用 LibROSA 对语音特征进行处理。LibROSA 是一个专门针对声音信号处理和音乐数据解析而开发的 Python 库，提供了多种音频特征提取的工具和相应的函数接口。用户只需提供音频信号及相关参数，即可获得规范化的特征矩阵输出，进行特征提取和分析。LibROSA 的 feature 包提供了多种特征提取功能，包括色谱图、Mel 光谱图、MFCC、各种其他光谱和音量特征，显著提升了特征提取的便捷性与可视化程度。

2.1.3 视觉特征提取

视觉特征主要涉及图像或视频内容，通过提取图像中的结构、环境、面部表情等特征分析说话者的情绪。传统的图像特征提取方法通过检测图像中的关键点和边缘信息等低维特征实现图像分类与目标检测任务。与此不同，深度学习模型通过端到端的学习机制自动提取最优特征表示，其中卷积神经网络（CNN）作为图像处理的主流模型，能够从原始图像中提取多层次的特征表示，包括边缘、形状和高级语义信息等高维语义信息。对于视频等动态视觉数据，3D-CNN^[61]能够从时序数据中提取时间维度的特征，捕捉视频中的时空变化。

本研究采用 Faster R-CNN^[62]和 OpenFace^[63]进行视觉特征提取。Faster R-CNN 是

一种结合区域建议网络（RPN）和 CNN 的目标检测工具，该方法通过共享卷积层提取高层次特征并生成特征图。接着，RPN 基于这些特征图生成候选区域，ROI 池化层将其映射为固定大小的特征向量，用于目标分类与边界框回归，实现高效的目标检测。

OpenFace 是由卡内基梅隆大学和剑桥大学联合开发的开源面部行为分析框架，支持面部关键点检测、表情识别、身份验证和头部姿态估计等任务。在特征提取过程中，OpenFace 首先利用 dlib 或 OpenCV 的预训练模型检测人脸区域，并通过仿射变换对人脸进行对齐，以减小姿态和光照的影响，之后，深度神经网络将人脸特征映射为 128 维的向量，捕捉面部的细微差异，便于后续的分类和回归任务。

2.2 双向长短期记忆融合网络

双向长短期记忆网络（Bidirectional Long Short-Term Memory, BiLSTM）^[18]是长短期记忆网络（LSTM）的一种变体，主要用于处理序列数据。传统的单向 LSTM 只能从过去的时间步学习数据特征，而 BiLSTM 能够同时利用输入序列的前向和后向信息进行特征提取和预测，从而更有效地捕捉序列内部的复杂依赖关系。图 2.1 展示了 BiLSTM 神经网络模型的结构。




图 2.1 BiLSTM 网络结构

BiLSTM 由两个相反方向的 LSTM 单元组成，其中一个单元从前向后依次读取序列输入，另一个则从后向前处理。每个 LSTM 单元由三个门（输入门、遗忘门、输出门）和一条保存每个神经元的状态传送带组成，通过门控机制调节信息的流动和更新路径。LSTM 内的单元状态和隐藏状态随着输入序列的处理逐步更新，从而有效捕捉序列中的长期依赖特征，并同时融合当前时刻的前后信息。各 LSTM 单元

的状态计算公式如式 2.1-式 2.6 所示。

$$f_t = \sigma(W_f \cdot [h_{t-1}, w_t] + b_f) \quad (\text{式 2.1})$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, w_t] + b_i) \quad (\text{式 2.2})$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, w_t] + b_o) \quad (\text{式 2.3})$$

$$\tilde{c}_t = \tanh(W_c \cdot [h_{t-1}, w_t] + b_c) \quad (\text{式 2.4})$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad (\text{式 2.5})$$

$$h_t = o_t \odot \tanh(c_t) \quad (\text{式 2.6})$$

其中, f_t 、 i_t 、 o_t 分别表示遗忘门、输入门、输出门; c_t 为内部信息状态; h_t 是时刻 t 的输出; W_f 、 W_i 、 W_o $\in \mathbb{R}^{d_h \times d_k}$ 为权重矩阵; b_f 、 b_i 、 b_o 和 b_c $\in \mathbb{R}^{d_h}$ 为偏差; d_h 为 LSTM 隐藏层的单元数; W_c $\in \mathbb{R}^{d_e}$ 为预训练层的词嵌入; $d_k = d_e + d_h$; σ 为 *sigmoid* 函数; $\cdot$ 和 $\odot$ 分别表示矩阵乘法和元素乘法。

BiLSTM 通过将两个方向的 LSTM 获得的隐藏层输出拼接, 生成最终输出 h_t , 并传递给后续的全连接层, 执行分类或回归等下游任务。在传统的 LSTM 模型中, 每个位置的隐藏状态 h_t 只编码正向的上下文信息。BiLSTM 模型通过连接每个模型的隐藏层输出, 同时利用序列信息的正反序, 从而实现更完整的信息编码, 如式 2.7-式 2.9 所示。

$$\vec{h}_t = LSTM[x_t, \vec{h}_{t-1}] \quad (\text{式 2.7})$$

$$\overleftarrow{h}_t = LSTM[x_t, \overleftarrow{h}_{t-1}] \quad (\text{式 2.8})$$

$$h_t = [\vec{h}_t : \overleftarrow{h}_t] \quad (\text{式 2.9})$$

其中 $\vec{h}_t$ 表示 t 时刻的正向隐藏状态, $\overleftarrow{h}_t$ 表示 t 时刻的反向隐藏状态, x_t 是 t 时刻的输入。通过这种双向处理机制, BiLSTM 能够充分利用前后时序的信息, 捕捉序列中双向的依赖关系, 极大提高了模型的特征表达能力和预测精度。

2.3 注意力机制

注意力机制 (Attention Mechanism) 是深度学习中的重要组件之一, 起源于人类对事物的感知过程。人类在处理大量信息时, 通常会选择性将注意力集中在关键

区域并逐步扩展到整体，以实现全面的理解。类似地，在深度学习中，注意力机制模拟人类大脑在处理信息时的选择性注意过程，通过动态调整输入数据各部分的权重，自动识别并聚焦于与当前任务相关的信息，忽略不重要或冗余的信息，提升模型的效率和准确性，作为一种信息筛选策略，注意力机制已广泛运用于推荐系统、计算机视觉、自然语言处理等领域。

注意力机制常用于解决序列到序列（Seq2Seq）任务，其基本结构如图 2.2 所示。在处理输入序列时，通过引入“注意力权重”，为序列中不同的元素动态分配权重，从而有效捕捉序列中的关键信息。这种特性使其在处理变长序列以及长距离依赖任务时展现出明显优势。




图 2.2 注意力机制结构

注意力机制旨在通过点积、加性或缩放点积等方法计算查询向量（Query）和键（Key）-值（Value）对之间的相似性，生成注意力分数（Attention Scores），相关性越高对应的注意力分数也越高。并使用 Softmax 函数将注意力分数映射到[0,1]区间进行归一化处理，最终构建加权输出矩阵。

常见的注意力机制包括自注意力机制、软/硬注意力、空间注意力机制和算术注意力机制等。本节将重点讨论自注意力机制（Self-Attention）。自注意力通过处理序列内部的依赖关系，能够有效捕捉源与目标之间的依赖特征。该机制又可细分为单头注意力机制和多头注意力机制，前者通过计算注意力权重来提取关键信息；后者则通过多个并行的单头注意力独立计算，这种多头结构类似于人类从不同角度分析问题的方式，多注意力头也会从不同维度来学习序列中的依赖关系，从而更加全

面地理解输入信息的多层次关系。

单头注意力机制通过计算序列中的各元素之间的相关性，并根据相似度为每个元素分配相应的权重，通过加权求和的方式输出结果。其基本结构如图 2.3 所示。该机制采用缩放点积方法来计算相似度，具体计算过程如下：

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_K}}\right)V \quad (\text{式 2.10})$$




图 2.3 单头注意力机制结构

多头注意力机制（Multi-Head Attention）将输入特征空间划分为 h 个独立子空间，每个子空间对应一个注意力头（Attention Head），如图 2.4 所示。在计算过程中，每个注意力头通过独立的线性变换将输入序列映射为特定的查询、键矩阵和值矩阵。对于第 i 个注意力头，通过缩放点积注意力（Scaled Dot-Product Attention）计算查询和键的点积，以获得该头的注意力权重。随后，将得到的注意力权重与对应的值矩阵 V 相乘，生成加权后的输出表示，以确保每个注意力头可以专注于输入序列的不同特征。最后，将 n 个注意力头的输出特征进行拼接（Concatenate）操作，得到最终的多头注意力输出表示。

$$head_i = Attention^i(QW_i^Q, KW_i^K, VW_i^V) \quad (\text{式 2.11})$$

$$MultiHead(Q, K, V) = Concat(head_1, head_2, \dots, head_{n_{head}})W^O \quad (\text{式 2.12})$$

其中, W_i^Q 、 W_i^K 、 W_i^V 为第 i 个头的查询、键、值的权重参数矩阵, W^O 为可训练参数矩阵。




图 2.4 多头注意力机制结构

2.4 预训练语言模型

早期 NLP 研究中, Seq2Seq 模型常用于处理可变长度的输入输出序列, 但该模型在编码和解码过程中存在局限性。与传统依赖手工特征的模型不同, 预训练语言模型 (Pretrained Language Models, PLM) 通过大规模语料库进行无监督学习, 减少了对标注数据的依赖, 在语言规则和上下文语义捕捉方面展现出卓越性能。Transformer 作为预训练模型的核心框架, 主要由自注意力机制和前馈神经网络组成, 能够有效捕捉序列中的全局依赖关系, 缓解传统 RNN 和 LSTM 在处理长序列时面临的梯度消失和梯度爆炸问题。

PLM 主要分为自回归语言模型和掩码语言模型两类。掩码语言模型 (如 BERT) 采用预测被掩码词汇的训练方式, 适语义理解任务; 自回归模型 (如 GPT) 则通过预测下一个词的概率分布来生成文本。两者分别基于 Transformer 架构的编码器与解码器模型架构。本节将重点介绍以 BERT 和 GPT 为代表的模型及其应用。

2.4.1 BERT 模型

BERT (Bidirectional Encoder Representations from Transformers) 是 Google 于 2018 年推出的一种基于 Transformer 结构的自编码预训练模型。该模型通过微调策略, 能够灵活适应各类 NLP 任务, 展现出强大的普适性与泛化能力。BERT 通过堆叠多个双向 Transformer 编码器捕捉上下文信息, 并在每一层都利用自注意力机制为单词分配权重, 使其在理解语义时能够综合考虑单词的前后文信息。通过深度双向上下文学习机制有效解决了多义词的语义识别问题, 提升模型的语义理解能力。

BERT 的框架结构如图 2.5 所示, 图中输入为两个不同文本的句子, 输出为编码后的特征嵌入。BERT 的输入由词嵌入、位置嵌入和句子嵌入三部分组成。词嵌入表示单词本身, 位置嵌入表示单词在句子中的位置, 句子嵌入用于区分不同句子或段落, 以更好地捕捉句子内外的语义关系。BERT 的训练过程分为预训练和微调两个阶段。在预训练阶段, 模型通过并行处理掩码语言模型 (Masked Language Model, MLM) 和下一句预测 (Next Sentence Prediction, NSP) 两个任务的输入序列, 捕捉词汇的深层语义及句子结构关系。MLM 任务通过随机 “MASK” 输入文本中约 15% 的词汇并强制模型仅依赖上下文信息预测被 “MASK” 的词汇, 学习词汇间的依赖关系和语境信息; NSP 任务则用于判断句子间的关联性, 帮助模型理解句子间的语义和逻辑关系。在训练过程中, BERT 使用分隔符 [SEP] 标记分隔句子, [CLS] 标记来表示整个句子的特征, 以进行分类任务的预测。在微调阶段, BERT 在完成大规模语料库的无监督预训练后, 根据具体的下游任务进行参数调整, 以适应并优化在特定任务中的性能。




图 2.5 BERT 模型架构

2.4.2 ChatGPT

自生成式预训练转换器（Chat Generative Pretrained Transformer, ChatGPT）发布以来，受到了国内外研究人员的广泛关注，引发了新一轮的研究和创新，推动了自然语言理解、语义计算及计算机视觉等相关领域的发展^[64]。

ChatGPT 是由 OpenAI 于 2018 年发布的基于神经网络的语言生成模型，其出色的语言处理与生成能力使其在近年来广受欢迎。与 BERT 等编码器模型不同，GPT 采用自回归语言建模（Autoregressive Language Modeling），通过预测上下文中的下一个单词实现文本生成。例如，给定一个句子 $E_1, E_2, \dots, E_n$ ，GPT 在预测单词 E_i 的时候只会利用 $E_1, E_2, \dots, E_{i-1}$ 的信息，而 BERT 会同时利用 $E_1, E_2, \dots, E_{i-1}, E_i, \dots, E_n$ 的信息，因此，GPT 适合处理自然语言生成任务（NLG），BERT 更适用于自然语言理解任务（NLU）。GPT 采用 Transformer 架构的解码器（Decoder）中的掩码多头自注意力机制结构（Mask Multi-Head Attention），通过优化目标函数（式 2.13）并结合前文信息 $E_1, E_2, \dots, E_{i-1}$ 去预测下一个单词 E_i ，如图 2.6 所示。在训练过程在，模型首先进行无监督预训练，然后通过标注数据进行微调，以提升模型在特定任务中的表现。

$$\mathcal{L}^{PT}(E) = \sum_i \log P(E_i | E_{i-k} \dots E_{i-1}; \theta) \quad (\text{式 2.13})$$




图 2.6 GPT 模型架构

ChatGPT 基于互联网提供的庞大文本数据集进行训练，具备较强的连贯性与上下文理解能力，可模拟人类对话模式进行交互，广泛应用于智能客服、教育、医

疗、翻译、虚拟助手、文本撰写和内容创作等场景。然而，由于生成机制的随机性，ChatGPT 可能受到训练数据影响而生成不准确或存在偏见的输出，因此如何有效管理和引导生成内容是当前亟待解决的问题。

2.5 扩散模型

扩散模型（Diffusion Models, DMs）^[65]是一类基于概率生成模型的深度学习方法，作为一种新兴且强大的生成模型，DMs 在图像生成、自然语言处理、推荐系统等多个领域得到了广泛应用，特别是在文本到语音（Text-to-Speech）和文本到图像（Text-to-Image）领域取得了显著成果。如图 2.7 所示，DMs 模型通过正向扩散过程和反向扩散或去噪过程来学习数据的近似分布。首先，前向扩散过程逐步在训练数据中引入高斯噪声，直至转变为完全随机的噪声图像。而后反向扩散过程利用去噪网络逐步去除噪声，恢复原始数据并生成具备高准确性和多样性的新样本。

目前关于扩散模型的研究主要分为三种形式：去噪扩散概率模型(DDPMs)、基于分数的生成模型(SGMs)和随机微分方程(Score SDEs)。其中，DDPM 通过逐步处理噪声来细化样本生成，使其与训练数据的概率分布紧密匹配。



图 2.7 扩散前向逆向过程

采用上述 DMs 过程，如图 2.8 所示，DDPM 的正向过程是一个马尔可夫链，逐步向初始数据 $x_0 \sim p(x_0)$ 中添加高斯噪声 $\varepsilon \sim N(0, I)$ ，并生成有噪声的数据分布或先验分布 $p(x_t | x_{t-1})$ 。

$$P(x_{1:T} | x_0) = \prod_{t=1}^T P(x_t | x_{t-1}) \quad (\text{式 2.14})$$

$$p(x_t | x_{t-1}) = N\left(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I\right) \quad (\text{式 2.15})$$

其中， T 是扩散步骤， I 是单位矩阵， $\{\beta_t \in (0, 1)\}_{t=1}^T$ 是控制添加噪声步长的噪声调度。 x_t 表示时间 t 处的噪声图像， x_t 为线性初始数据 x_0 和随机噪声 ϵ 的组合。根

据方差表 $\{\beta_1, \dots, \beta_T\}$ ，将前一时间步的样本 x_{t-1} 缩放为 $\sqrt{1-\beta_t}$ ，以生成新的样本 x_t 。DDPM 使用重参数化技术 $x_t = \sqrt{\alpha_t}x_0 + \sqrt{1-\alpha_t}\epsilon_t$, $\epsilon_t \sim N(0, I)$ ，可以在任意时间步 t 中基于初始数据 x_0 重建样本 x_t ，当时间步长 t 足够大时， x_t 接近于纯高斯噪声。

如果 β_t 足够小，则反向扩散过程 $q(x_{t-1}|x_t)$ 也是高斯函数，通过参数化模型学习。从初始随机噪声样本 $x_t \sim N(0, I)$ 开始，逐步还原出与真实数据非常相似的样本，即原始分布（后验分布）。

$$P_\theta(x_{t-1}|x_t, 0) = N(x_{t-1}; \mu_\theta(x_t, t), \sum_\theta(x_t, t)) \quad (\text{式 2.16})$$

其中， $\mu_\theta(\cdot)$ 和 $\sum_\theta(\cdot)$ 分别表示均值函数和协方差函数，可以通过 U-Net 或 Transformer 实现。




图 2.8 扩散模型原理

2.5.1 文本-语音扩散模型

随着生成建模^[66]、神经声码器^[67]等技术的快速发展，基于深度神经网络的文本到语音（TTS）合成模型在合成质量和处理速度方面取得了显著提升。现代语音合成系统通常由声学建模与波形生成两部分组成：前者负责将输入文本转换为声学特征，后者用于将声学特征转换为原始波形。本研究重点是生成梅尔谱图（Mel Spectrogram）作为音频特征，而非直接生成原始波形。

TTS 任务旨在将自然语言文本转换为语音输出，通常通过自回归方法生成梅尔谱图，随后通过独立训练的声码器实现高保真音频的合成。整个 TTS 过程包括文本分析、归一化、语音分析和韵律分析几个环节。如图 2.9 所示，本分析模块对输入文本进行语法结构解析和语义理解；接下来，规范化处理模块对非标准词汇进行标准

化转换；然后，语音分析将单词拆解为音素并进行分析；在语音合成阶段，系统基于音素生成相应的语音特征，并结合韵律模式以确保语音的自然流畅；最终，声码器将梅尔谱图转换为实际波形，实现文本到语音的转换。




图 2.9 文本到语音模型




图 2.10 Grad-TTS 体系结构

在此背景下，Popov 等人^[68]提出一种基于梯度下降的端到端的声学特征生成器 Grad-TTS，该模型由编码器、持续时间预测器以及基于扩散过程的解码器组成。Grad-TTS 通过逐步减少噪声的生成过程，能够合成自然且流畅的语音。图 2.10 展示了其推理过程的整体架构。首先，编码器将输入的文本转化为高维的文本特征表示，持续时间预测器（Duration Predictor）根据文本的音素信息预测每个音素的持续时间，确保生成的语音在节奏和时长上与原始文本保持一致。对齐模块（Aligner）使用单调对齐搜索（Monotonic Alignment Search, MAS）技术，将编码器生成的文本特征与持续时间预测结果对齐，确保文本特征与音频特征在时间维度上的同步，避免生成过程中出现不自然的跳跃或错位。最后，U-Net 解码器（Decoder）接收来自编码器文本特征、噪声特征和时间信息，并通过常微分方程（ODE）求解器将这些

特征与高斯噪声结合，通过反向扩散过程，从初始噪声状态 X_T 逐步去噪，最终生成与输入文本匹配的梅尔谱图 X_0 。

Grad-TTS 通过随机微分方程对扩散概率模型进行扩展，能够在不同参数的噪声环境中重构数据，从而生成自然流畅的语音。该模型支持多种语言，具备高度的灵活性和可扩展性，适用于多种语言环境中的语音合成任务。同时，能够通过调整解码器的迭代步数来平衡推理速度与语音质量之间的关系，生成高度质量且易于理解的语音输出。

2.5.2 文本-图像扩散模型

文本生成图像任务是将自然语言描述转化为具有相似语义内容图像的计算方法，这类模型通过文本提示生成图像，采用自回归建模和扩散过程的采样方法，将图像生成问题分解为更易于神经网络学习的小步骤，提升模型生成性能。

在众多生成模型中，Stable Diffusion^[69]通过大量文本-图像对的训练，展现出生成高质量图像的能力。作为一种基于深度学习的图像生成方法，Stable Diffusion 能够根据提示文本生成详细的图像，包括虚构、卡通插图、以及真实感极高的图像等多种风格。该模型采用自回归的训练过程，逐步从噪声生成图像，并集成了内置的 NSFW 过滤器，减少对外部安全机制的依赖。




图 2.11 Stable Diffusion 网络结构图

SD 是 DMs 的变体，称为潜在扩散模型（Latent Diffusion Model, LDM），由 CLIP 文本编码器、U-Net 图像生成器和变分自编码器（VAE）组成。如图 2.11 所示，模型在生成图像时，首先通过 CLIP 文本编码器将输入文本“A giant panda eating bamboo”映射为文本嵌入向量，同时初始化潜在空间的随机高斯噪声矩阵，并与文本嵌入共同输入到 U-Net 去噪模块中，该模块通过引入多头注意力机制，实现文本

信息与图像生成过程的深度耦合，逐步去除噪声生成潜在图像表示。最终，VAE 解码器将去噪后的潜在表示还原为实际图像，输出为 512×512 的高质量图像。这种结构能够确保生成图像与文本描述的高度一致性，同时实现了计算效率与内存使用的最优化。

2.6 提示学习

提示学习（Prompt Learning）是一种无需修改模型架构或参数，通过在输入中添加特定提示，将用户输入与提示信息相结合，指导模型更好地理解任务的上下文并生成更符合预期的输出的方法。图 2.12 展示了基于提示学习的大语言模型的推理过程。提示学习的核心在于设计合适的输入提示，以引导预训练模型（如 GPT 等）生成特定任务的输出。其推理过程包括以下几个步骤：

首先，输入原始文本序列 x 经过预定义的模板函数 $f_{prompt}(\cdot)$ 转换为特定格式的文本序列 x' 。

$$x' = f_{prompt}(x) \quad (\text{式 2.17})$$

在模板中使用占位符来表示输入和输出。假设占位符 $[X]$ 表示输入文本序列 x ， $[Z]$ 表示模型的输出（预测结果）。对于情感分析任务，输入的文本 x ：“He is a Solomon.”，可构建模板为：“ $[X]$. The Solomon is $[Z]$ ”。经模板处理后的输入 x' 为：“He is a Solomon. The Solomon is a $[Z]$ ”。接着，将 x' 输入到预训练模型 M 中，模型根据其在预训练的语义知识和上下文信息，预测并填充 $[Z]$ 位置的内容。

$$\hat{y} = M(x') \quad (\text{式 2.18})$$

在某些特定任务中，生成的输出可能需要进一步的映射或处理，通常会设计一个映射函数 $g(\cdot)$ ，将模型的输出 $\hat{y}$ 转换为任务所需的标签格式 y 。例如，在情感分析任务中，模型生成的输出可能是情感分类的标签（如“positive”、“negative”或“neutral”）。

$$y = g(\hat{y}) \quad (\text{式 2.19})$$

在 NLP 领域，模板设计有多种形式，精心构建的模板能够更有效地指导预训练模型适应特定任务。与传统的微调方法不同，提示学习通过设计提示模板，使下游任务的输入格式更贴近预训练模型的数据分布，从而在无需微调的情况下也能取得理想的效果。这种方法不仅减少了对硬件和数据资源的依赖，还显著提升了模型的推理能力，增强逻辑推理和常识理解等方面的表现。当前常用的提示学习方法包括思维链提示（Chain-of-Thought, CoT）、“思维树”（Tree of Thoughts）和指令微调（Instruction Tuning）等。




图 2.12 基于提示学习的大语言模型的推理过程

思维链（Chain of Thought, CoT）是由 Wei 等人^[40]提出的一种旨在提升 LLM 推理能力的提示学习方法。其核心理念在于通过引导模型逐步推理，将复杂的推理过程分解为一系列连贯的逻辑相关的中间推理步骤。通过这种逐步推理的方式，模型能够依据前一推理步骤的结果以及当前任务的要求，推导出下一步的结论，从而完成整个推理过程。

在实际应用中，思维链提示通常通过提供问题及相关示例来训练模型。示例包括问题本身、思维链推理过程以及输出结果，模型通过学习这些示例，能够掌握如何分步解决类似问题。图 2.13 展示了语言模型如何通过思维链方法解决数学问题的示例。标准提示方法（如图 2.13（a）所示）在处理复杂推理的问题时，模型往往容易出错。与直接给出答案的方式不同，思维链提示（如图 2.13（b）所示）模拟了人类处理复杂问题时的思考过程，要求模型在推理过程中输出每个中间步骤的推导过程，有助于提升其在数学运算、逻辑推理和常识推断等任务中的表现。思维链提示广泛应用于 LLM 的预训练阶段，通过在输入中嵌入特定提示，引导模型生成详细的推理过程，从而提高其对复杂问题的理解与解决能力。




图 2.13 思维链推理过程

2.7 本章小结

本章详细介绍了中文隐式情感分析的理论基础及其相关技术工具, 首先, 详细阐述了单模态特征的提取方法。其次, 介绍了循环神经网络 BiLSTM 及注意力机制的基本结构和关键特征, 并展开介绍了大语言模型的相关理论基础, 包括 BERT 预训练模型和 ChatGPT。接着, 介绍了扩散模型的基本结构, 并详细说明了其在视觉和语音数据处理中的变体, 突出其在处理图像、语音数据中的独特优势。最后叙述了如何利用提示学习进一步优化大语言模型, 为后续的实验研究奠定了坚实的理论基础。

3 基于语音和视觉特征辅助的中文隐式文本情感分析

3.1 引言

在情感分析领域，文本作为情感表达的重要媒介，其蕴含的隐式情感信息相较于显式情感更为细腻且复杂。然而，现存的情感分析技术主要侧重于显式情感，对文本中隐含的丰富情感信息关注较少。隐式情感表达常借助隐喻、暗示等方式间接传达情感倾向，传统的单模态分析方法在面对这类隐式情感时，难以全面捕捉和理解其真实情感特征。因此，如何更有效地分析和理解文本中的隐式情感，成为情感分析领域亟待解决的关键问题。

隐式文本因其自身特性，包含的情感信息相对较少且分布不均衡，使得基于文本特征和词汇资源的方法在处理隐式情感分析时往往不够全面。研究表明，通过整合视觉和语音特征辅助分析隐式情感，可以有效弥补这一不足^[71,72]。在某些特定场景下，文本可能缺乏明显的情感特征，但说话者的语音语调或面部表情却隐含了强烈的情感倾向。例如 Zhou^[70]提出了一种结合隐喻文本特征和图像特征的隐式情感分析方法，提高了情感分类的准确率。然而，现有的多模态融合方法往往停留在问题表面，仅对模态进行简单的映射处理，未能深入探索不同模态间的协同作用及各模态特有的信息特征。

为解决以上问题，本章提出了一种基于视觉和语音特征辅助的隐式情感分析模型 TIMISA (Text-Integrated Multimodal Implicit Sentiment Analysis)。TIMISA 模型通过结合语音和视频数据，为隐式文本提供更丰富的情感上下文信息，弥补单一模态无法全面预测情感的不足。视频中的面部表情、身体姿态和语音语调可以提供额外的情感背景，而这些是纯文本分析无法捕捉到的。模型的核心创新在于设计了一种以隐式文本为主的交叉注意力融合机制，通过关注不同模态之间的贡献度差异，自适应地将语音和视觉特征中的情感信息与隐式文本相结合，解决多模态特征之间的不一致性问题，进一步强化了隐式文本中潜在的情感线索，从而提升隐式情感分析的效果。为验证多模态特征对隐式情感理解的影响，本章构建了一个基于隐式文本的多模态数据集 CMSIED，该数据集包含了隐式文本及其对应的语音和视觉数据，为隐式情感分析研究提供更丰富的训练与验证基准资源。

3.2 CMSIED 数据集

本节将系统阐述数据集 CMSIED 的创建过程，具体包括数据采集、标注规范及约束条件，并对数据集进行分析，为后续公开和复用提供坚实基础。

3.2.1 数据收集

为弥补多模态隐式情感分析领域样本稀缺及标注质量不稳定的问题，本章创建了一个中文隐式多模态数据集 CMSIED，包含文本、视频和音频三种模态，旨在深入挖掘情感表达的隐式特征。与单模态数据集相比，CMSIED 要求视频中说话者的面部表情与语音同步呈现，以便捕捉更丰富的情感细节。数据采集阶段，我们从抖音、快手、小红书、微信公众号及商业广告等多渠道筛选视频片段，确保数据集覆盖多样化且具有代表性的情感表达场景。为突出隐式情感的特点，优先选择能够体现复杂情感或隐含语义的内容。具体而言，通过检索“观点”、“商品评价”、“社会议题”、“职场心得”、“影视点评”、“美容心得”、“育儿经验”等关键词，筛选出具有微妙情感波动或隐晦表达的视频片段。所选视频仅包含一位说话者，且说话者主要面向镜头。采集的视频涵盖多种情绪，同时保留一定程度的噪声，以增强数据集的多样性和真实性。最终，收集了 60 个原始视频。在获得原始视频后，我们对视频进行了严格的筛选和编辑。所有的视频都需要经过视频编辑工具 Adobe Premiere Pro1 逐帧裁剪，以剔除不必要的部分，确保每个视频片段都符合标准。尽管耗时较长，但能够确保数据集的质量。

在整个数据裁剪过程中，严格执行以下规范：

- 语言规范：仅选用普通话，去除口音过重或发音不清晰的视频，避免方言或口音干扰。
- 视频时长：每段视频的时长控制 6 至 17 秒之间，确保情感表达的简洁性。
- 画面人物：每个视频片段中仅允许出现说话者的面孔，不允许出现其他人脸。

最终，裁剪出 3632 个视频片段。在转录文本的过程中，由于部分视频存在环境噪音、背景复杂等问题，自动转录文本的准确率较低，因此我们采用人工校对的方式，确保文本与语音内容高度一致。

3.2.2 标注

数据标注的质量直接影响数据集的可靠性。为确保标注的准确性，我们采用分步标注流程，依次处理文本、语音和视频模态数据，确保标注者在每个阶段仅依据

当前接触的模态信息做出判断，以避免在标注时受到其他模态信息的干扰。具体流程如下：首先，标注人员仅基于纯文本内容独立评定情感倾向，防止不同模态信息影响标注者的判断；随后，标注人员需要在听取语音的同时观看视频，对同一内容进行二次标注，对标注结果进行校验和修正。仅当两次标注结果达成一致时，才视为最终标注结果。

所有视频片段的情感极性均采用三分类标注（消极、中性、积极），最终构建的数据集包含 3632 条语句，每条语句均严格对齐相应的语音和视频数据。

3.2.3 数据集的分析与应用

CMSIED 数据集的优势在于其多模态特性，整合了文本、语音和视频三种模态的数据，为隐式情感分析的研究提供了丰富的数据支持。基于该数据集，本研究验证了多模态隐式情感分析模型的性能，同时也为探索新的隐式情感分析方法提供了可能性，以进一步提升隐式情感分析模型的精度和稳定性。CMSIED 数据集的构建展示了多模态特征在隐式情感智能领域的广阔应用前景，为该领域的研究提供了新的视角和方向。

3.3 TIMISA 模型

TIMISA 模型通过动态调整不同模态间的权重分配策略，优化文本特征的表达，并最大化模态间的互补优势，有效挖掘视觉、语音与文本模态间的协同关联，显著提升了隐式情感分析的准确率。如图 3.1 所示，该模型架构主要由四个模块组成：单模态特征提取、跨模态特征融合、文本交叉注意力协同模块和情感分类模块。

具体的：

（1）单模态特征提取：针对语音、视觉及文本模态，采用特定的预处理技术提取初始特征信息，确保每个数据源的特征能够有效反映其内在属性。

（2）跨模态特征融合：通过多头互注意力机制，动态调整模态间的权重，减少噪声特征的干扰。该模块实现文本特征与语音、视觉特征的双向交互融合，并通过迭代优化权重分配，逐步消除语音和视觉模态中的冗余信息，平衡各模态对情感预测的贡献度。

（3）文本交叉注意力协同模块：采用交叉注意力机制，将文本与经过交互学习优化的声音和图像特征深度融合，以增强文本模态的表达能力。根据源模态（语音

和视觉)对目标模态(文本)的重要性调整模态特征,生成富含情感线索的多模态特征表示。

(4)情感分类:将强化后的综合多模态特征输入全连接层处理,输出情感分类的预测结果。




图 3.1 基于多模态信息融合的隐式情感分析模型

3.3.1 单模态特征提取

在数据预处理阶段,从数据集中选取同一视频片段的单峰原始序列作为模型的输入。各模态的特征提取过程如下:

文本特征:考虑到中文分词不准确对语义的影响以及 BERT 在自然语言处理任务中的优越表现,采用中文 BERT 预训练模型来获得大小为 $d_t = 768$ 词向量表示作为文本特征。由于每个话语段的所对应的句子长度有所差异,为了统一句子长度,我们进行了填充和截断操作。对于较短的文本,在句子矩阵末尾填充字符 padding,对于较长的文本,截取前面的部分作为使用,舍弃后面部分的内容。

语音特征:使用 LibROSA 语音工具包^[60]提取了 $d_a = 33$ 的帧级语音特征,然后使用 P2FA 进行文本和语音的对齐,采用零向量对语音序列进行填充,与文本模态的序列长度保持一致。

视觉特征:视频以 30Hz 的采样率提取连续的图像帧。为降低数据量,我们首先使用 MTCNN 人脸检测算法^[73]检测人脸区域并提取特征点,然后通过 OpenFace2.0^[63]来提取面部表情特征,包含面部标记点,面部动作单元,头部姿势和眼睛注视方向。最后,共提取大小为 $d_v = 709$ 的帧级视觉特征。由于视频是一个时间帧序列数据,同语音特征处理一样,我们在视频帧长度不足的视频表示的末尾填充,对于视频帧长度过长的话语段,我们取其前面部分帧向量,以统一视频帧长度。提取的三

种模态特征序列用式 3.1 表示。

$$I_m \in \mathbb{R}^{L_m \times D_m}, m = \{T, A, V\} \quad (\text{式 3.1})$$

式中, T 表示文本模态, A 表示语音模态, V 表示视觉模态, L 表示不同模态的话语段序列长度, D 表示各模态的特征维度。

我们将提取到的特征输入到 BiLSTM 网络挖掘各模态内部的上下文信息。BiLSTM 通常用于处理自然语言处理中的各种任务, 使用 BiLSTM 可以有效地建模上下文信息, 能够更精确的捕捉序列的上下文关系。通过 BiLSTM 对得到的语音、视觉特征进行编码, 得到语音、视觉模态的上下文表征。对于文本模态, 则直接将采用中文 BERT 预训练模型得到句子的向量表示作为文本特征。三种模态的初始特征信息为 $\hat{I}_m$:

$$\hat{I}_m = \begin{cases} BiLSTM(I_m; \theta_m^{BiLSTM}) \in \mathbb{R}^{L_m \times D_m}, m = T \\ BERT(I_m; \theta_m^{BERT}) \in \mathbb{R}^{L_m \times D_m}, m = \{A, V\} \end{cases} \quad (\text{式 3.2})$$

式中, θ 表示不同模态特征提取的模型参数。由于视觉、语音的特征维度明显小于文本特征, 使用 1D 时间卷积将提取的单模态特征转换成相同的维度。

$$X_m = Conv1D(I_m, k_m) \in \mathbb{R}^{l_m \times d_m}, m \in \{T, A, V\} \quad (\text{式 3.3})$$

其中, k_m 表示不同模态的卷积核大小, l_m 表示为不同模态话语段特征序列对齐之后的长度。 d_m 表示不同模态特征对应的维度大小。

3.3.2 跨模态特征融合

不同的模态反映了不同的情绪倾向, 这些隐式的多模态数据可能具有独立或一致的信息。因此对最终情感预测的贡献也有所不同。隐式文本作为富含高级语义信息的人类语言表达, 与语音和视觉模态这些低级特征相比, 后两者之间存在着大量的冗余信息。此外, 文本和语音、视频所表达的情感往往不完全一致, 直接去除噪声模态可能会丢失模态本身特有的信息。

为解决上述问题，本研究在模态融合过程中，综合考虑了隐式文本和语音、视频模态的双峰融合以及不同模态之间的异质性。通过多头互注意力机制捕捉隐式文本与其他模态之间的交互特征，以隐式文本信息作为核心，与其他非文本模态（语音、视频）特征融合，辅助推理隐式情感。利用非文本模态中的补充特征来提高模态间的相关性，减少模态噪声对情感预测结果的负面影响。

如图 3.2 所示，多头互注意力机制通过一系列线性变换，从不同特征子空间中提取关键信息，以文本为中心自适应地为不同模态分配权重。以文本与视觉模态的融合为例，首先，将每个话语段的文本、视觉特征向量 X_T 、 X_V 进行线性变换，以适应不同模态间的尺寸差异。

$$X'_T = \text{Linear}(X_T) \quad (\text{式 3.4})$$

$$X'_V = \text{Linear}(X_V) \quad (\text{式 3.5})$$

然后通过多头互注意力机制建立文本与视觉特征的动态关联，在这个过程中，文本特征被用作查询来搜索与之相关的视觉特征。具体来说，文本特征向量 X'_T 被映射为多个查询向量 Q ，每个查询向量都对应一个注意力头。同时，视觉特征向量 X'_V 被分解为多个键 K 和值向量 V ，用于与查询向量进行匹配和加权求和。根据 Q 为 V 赋权值，将视觉特征中提取有效信息融入到文本特征中。经过 h 个线性变换投影，模型能够关注并整合不同子空间中的特征信息，这些子空间代表了不同的特征尺度和模态间的关系。

$$X^h = \text{soft max} \left(\frac{X'_T W_T^{(h)} \times (X'_V W_V^{(h)})^T}{\sqrt{d_V}} \right) X'_V \quad (\text{式 3.6})$$

其中， h 表示注意力头数量， $W_q^{(h)}$ 、 $W_k^{(h)}$ 表示第 h 个注意力头的可学习参数矩阵， $\sqrt{d_k}$ 为缩放因子。最后，各注意力头的输出经过拼接和线性变换，生成融合后的跨模态联合特征表示。

$$X_{VT}^* = \text{concat}(X^1, X^2, \dots, X^h) \times W_{VT} \quad (\text{式 3.7})$$

$$X_{VT} = \text{Linear}(X_{VT}^*) \quad (\text{式 3.8})$$

式中， W_{VT} 为权重矩阵。同样，使用上述方法得到语音模态与文本模态的交互特征。

$$X_{AT}^* = \text{concat}(X^1, X^2, \dots, X^h) \times W_{AT} \quad (\text{式 3.9})$$

$$X_{AT} = \text{Linear}(X_{AT}^*) \quad (\text{式 3.10})$$

式中， W_{AT} 为权重矩阵。




图 3.2 多头互注意力

3.3.3 文本交叉注意力协同网络

模态融合特征和单模态特征往往具有大量的重叠信息，明确区分模态间一致的特征和模态特定的特征，能更有效的整合隐式多模态特征。因此，在模态融合阶段，本章提出非对称融合策略，在保留模态特性的同时优化特征整合。

具体来说，我们采用交叉注意力机制，以文本特征为主要信息，利用文本-语音和文本-视觉模态的融合特征作为权重向量来实现文本特征的强化，有效利用了每种模态的特定情感信息，减少模态融合特征对文本特征的负面影响，从而提高了隐式多模态表示效率。

TCACN（Textual Cross-Attention Collaborative Network）的架构如图 3.3 所示。通过学习源模态（文本-语音、文本-视觉）和目标模态（文本）之间的注意力权重，用源模态特征来强化目标模态。以文本和文本-视觉融合特征为例，将目标句

X_T 作为查询向量，将每个融合特征 X_{VT} 视为键，并与查询向量 X_T 进行相似度计算，来检索和匹配文本-视觉融合特征 X_{VT} 中与之相关的特征，获得包含融合特征的文本嵌入表示 $X_{V \rightarrow T}$ 。该过程在保持文本原始语义的同时，强化了其情感表达能力，实现了文本与融合特征的有效融合。

$$\begin{aligned} X_{V \rightarrow T} &= \text{CorAn}(X_{VT}, X_T) \\ &= \text{soft max} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \\ &= \text{soft max} \left(\frac{X_T W_Q \times (X_{VT} W_K)^T}{\sqrt{d_k}} \right) X_{VT} W_V \end{aligned} \quad (\text{式 3.11})$$

其中， X_{VT} 和 X_T 是交叉注意（CrossAttention, CorAn ）的输入， $Q = X_{VT} W_Q$ 、 $K = X_T W_K$ 、 $V = X_V W_V$ 分别表示查询、键和值，分别用于计算注意力权重。接着，将复合文本特征 $X_{V \rightarrow T}$ 作为新的搜索基准，与文本特征进行深度融合，计算权重后获得增强后的文本特征输出 $X_{V \rightarrow T}^*$ 。在每个交叉注意模块中，原始的文本特征被保留并直接输入，确保文本模态特征 X_T 的语义完整性。

$$\begin{aligned} X_{V \rightarrow T}^* &= \text{CorAn}(X_{V \rightarrow T}, X_T) \\ &= \text{soft max} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \\ &= \text{soft max} \left(\frac{X_{V \rightarrow T} W_Q^* \times (X_T W_K^*)^T}{\sqrt{d_k}} \right) X_T W_{V \rightarrow T} \end{aligned} \quad (\text{式 3.12})$$

式中， $W_{V \rightarrow T}$ 为权重。然后，将得到的两个增强特征输出 $X_{V \rightarrow T}$ 与 $X_{V \rightarrow T}^*$ 拼接，并通过线性变换将两种模态的特征表示映射到低维特征表示空间，经过 $\tanh$ 和 soft max 激活函数得到文本-视觉融合信息与文本信息的交互特征，获得最终的注意力得分。

$$X'_{V \rightarrow T} = \text{Linear}(X_{V \rightarrow T}, X_{V \rightarrow T}^*) \quad (\text{式 3.13})$$

$$\tilde{X}_{V \rightarrow T} = \text{soft max}(\tanh(W_i X'_{V \rightarrow T} + b_i)) \quad (\text{式 3.14})$$

同样，使用上述方法获得包含文本-语音融合特征的文本嵌入表示。

$$\tilde{X}_{A \rightarrow T} = \text{softmax}(\tanh(W_i X'_{A \rightarrow T} + b_i)) \quad (\text{式 3.15})$$




图 3.3 文本交叉注意力协同网络

3.3.4 情感分类

最后，将融合结果与文本特征融合，得到最终的多模态特征 Z 并输入到全连接层中输出情感分类结果。

$$Z = \text{Concat}(\tilde{X}_{A \rightarrow T}, \tilde{X}_{V \rightarrow T}, X_T) \quad (\text{式 3.16})$$

$$y = \text{softmax}(W_o Z + b_o) \quad (\text{式 3.17})$$

其中，Concat 函数表示连接（Concatenation）操作， W_o 和 b_o 表示预测层的可训练参数。

3.3.5 损失函数

通过交叉熵损失函数计算隐式情感分析任务中预测结果与真实标签的损失值。

$$L_{\text{sentiment}} = -\frac{1}{n} \sum_{i=0}^{n-1} \hat{y}_i \times \log(y_i) \quad (\text{式 3.18})$$

其中, n 为训练样本数, y 为模型预测值, $\hat{y}$ 为真实情感标签, i 为 $\hat{y}$ 和 y 值的指数。

3.4 实验结果与分析

3.4.1 实验数据集

本章在两个公共的数据集 (CMU-MOSI^[74]和 CMU-MOSEI^[75]) 以及本章所创建的多模态隐式数据集 (CMSIED) 上测试和验证所提出的 TIMISA 模型。数据集的详细统计数据如表 3.1 所示。

表 3.1 数据集统计

数据集	训练集	验证集	测试集	总计
CMU-MOSI	1284	229	686	2199
CMU-MOSEI	13375	3289	3289	19953
CMSIED	2894	1733	1284	3632

CMU-MOSI: CMU-MOSI 数据集包括 2199 个关于来自 YouTube 电影评论的短视频独白。每段视频均通过人工标注了一个情感强度值, 范围为在 $[-3\sim3]$ 之间。 -3 表示强烈消极, 3 表示强烈积极, 0 表示中性, 大多实验都使用处理好的实验数据。其中包含约 380 个具有隐式表达情感的视频。

CMU-MOSEI: CMU-MOSEI 是目前规模最大的多模态情感分析数据集包含了 23,453 条经过标注的视频片段, 涵盖了来自 1,000 个不同的说话者和 250 个主题, 每个视频片段的情绪得分在 -3 (强烈消极) 到 3 (强烈积极) 之间。其中包含约 3000 个具有隐式表达情感的视频。

CMSIED: 实验使用的数据涵盖了抖音、快手、小红书、广告等多个平台的视频内容, 总计包括 3632 个视频样本, 所有视频数据均以隐式情感表达为特征, 按情感极性划分为积极、消极和中性三类。

3.4.2 实验环境与参数设置

本章所述模型使用 PyTorch 1.5.1 作为开发框架, 所有实验均在配备 40G 内存和

GTX-1080Ti 显卡的 Linux 服务器上完成。实验所需的软硬件环境配置参数如表 3.2 所示。

表 3.2 实验环境设置

名 称	配 置
GPU	NVIDIA A100-PCIE
Python 环境	Python3.7
内存	40G
操作系统	Linux
开发工具	PyCharm Professional 2023.1

表 3.3 实验关键参数设置

参 数	CMU-MOSI	CMU-MOSEI	CMSIED
文本模态向量维度	768	768	768
语音模态向量维度	74	74	74
视觉模态向量维度	47	47	35
BiLSTM	hidden_size	256	256
	num_layers	2	2
bert-base-uncased	hidden_size	768	768
	num_layers	12	12
多头注意力头数	8	8	8
学习率	1e-5	1e-5	1e-5
Epoch	70	60	60
Batch Size	64	32	48
Dropout	0.5	0.5	0.5
优化函数	Adam	Adam	Adam

3.4.3 评价指标

实验采用准确率（Acc）和 F1 值（F1-score）作为模型分类性能的评价指标。这些指标能够有效评估隐式情感模型在不同数据集上的表现，尤其是在数据类别不均的情况下，F1 值更能反映模型的真实性能。具体计算公式如式 3.19-式 3.22 所示。

（1）准确率指标衡量模型在测试数据集中正确分类的数据占正确标签的百分比。计算公式如下：

$$Acc = \frac{TP + TN}{TP + TN + FP + FN} \quad (\text{式 3.19})$$

其中，TP（True Positive）表示实际为正类且被正确预测为正类的样本数；TN（True Negative）表示实际为负类且被正确预测为负类的样本数；FP（False Positive）表示实际为负类但被误判为正类的样本数；FN（False Negative）表示模实际为正类但被误判为负类的样本数。

（2）F1 值是精确率（Precision）和召回率（Recall）的调和平均值，取值范围在[0,1]之间，当模型的精确率和召回率较为平衡且都较高时，F1 值更接近 1，反之则接近 0。F1 值的公式如下：

$$F1 = 2 * \frac{P * R}{P + R} = \frac{2TP}{2TP + FP + FN} \quad (\text{式 3.20})$$

其中，精确率通过计算模型正确识别为正类的样本占其预测为正类的总样本的比例计算过程如式（3.21）所示。

$$P = \frac{TP}{TP + FP} \quad (\text{式 3.21})$$

召回率被定义为模型正确识别的正类样本数与实际正类样本总数的比值，该指标能够有效反映模型对真实阳性样本的识别能力。

$$R = \frac{TP}{TP + FN} \quad (\text{式 3.22})$$

3.4.4 实验结果分析

为评估 TIMISA 模型在隐式情感分析任务中的表现，我们与多个基线模型在 CMU-MOSI、CMU-MOSEI 和 CMSIED 数据集上进行了对比实验。

虽然 CMU-MOSI 和 CMU-MOSEI 主要面向显式情感分析，但其包含的隐式情感样本为评估模型在复杂、模糊情境下处理隐式情感特征的能力提出了更高要求，不仅需要模型能够捕捉隐式情感表达，还要够准确提取并理解潜在的情感特征，从而全面检验 TIMISA 模型在面对多样化情感表达时的适应能力。所有基线模型的超参数设置与原论文一致。实验中使用的基线模型主要分为两类：一类是基于多模态信息辅助的模型，另一类是基于文本信息的辅助模型。具体如下：

基于多模态辅助的模型：

(1) sc-LSTM^[76]：上下文 LSTM 的变体，即简单上下文 LSTM，通过捕捉话语间依赖关系提取上下文单模态和多模态特征，提高话语级情感分类的性能。

(2) SWAFN^[77]：利用情感词知识指导多模态特征的联合表示学习，使模型在预测情感时更加关注关键情感词。

(3) CMHFM^[78]：提出了一种跨模态层级融合的多模态情感分析模型，同时处理单模态、双模态和三模态任务，提升情感分析性能。

(4) MCTCF^[79]：利用 2D 卷积捕捉跨模态的局部特征交互，并结合时序 LSTM 建模全局相关性，降低计算复杂度。

(5) UniMSE^[80]：提出一种情绪和情感联合建模模型，通过模态间对比学习，增强模态间的相关性，并放大样本之间融合表征的差异，提高模型预测精度。

基于文本辅助的模型：

(1) MB-CL^[81]：提出一种融合捆绑感知监督对比学习的框架，利用情境化特征提取器和局部感知特征提取器的协同作用，在嵌入空间中对齐显式与隐式情感特征，提高隐式情感分析的准确率。

(2) TTP^[82]：将隐式文本特征转化为情感极性更明显的图片，并以情感极性差异作为情感识别依据，提升中文隐式情感文本分类任务的性能。

表 3.4 展示了各模型在三个数据集上的对比实验结果。TIMISA 模型在三个数据集上的表现均优于或接近最佳基线模型，展现了其在处理多模态隐式情感分析任务时的广泛适用性和有效性。特别是在处理隐式情感数据时，TIMISA 模型的优势更为明显，这主要归功于其精细的隐式情感特征提取方法和跨模态关联建模策略。

在 CMU-MOSI 数据集上, 基于多模态辅助的模型在性能上普遍优于基于文本辅助的模型, 表明多模态数据在情感分析任务中提供了更丰富的情感线索。MB-CL 模型表现最差, 准确率仅为 63.90%, 这是因为该模型仅通过文本特征难以捕获复杂的隐式情感。而 TTP 模型通过将文本特征转换为词频图, 在多模态数据集上的表现优于 MB-CL 模型。相比之下, sc-LSTM 模型通过简单的模态连接利用多模态信息, 准确率提高了近 15%。而 SWAFN 模型通过整合跨模态协同注意力机制与外部知识库, 准确率提高至 80.2%, CMHFM 与 MCTCF 模型则采用更复杂模态特征融合策略, 准确率提高了 4%左右。这表明有效的多模态融合策略能够显著提升模型性能。TIMISA 模型在准确率和 F1 分数上表现超越了大多数基线模型, 准确率和 F1 分数分别为 84.79%, 84.61%, 仅次于 UniMSE 模型。这表明其通过捕捉模态间差异有效处理隐式情感信息, 能较好地适应复杂的多模态数据中的情感变化。

表 3.4 对比实验结果 (“-” 表示该研究未公开结果与实现方式)。

模型	CMU-MOSI		CMU-MOSEI		CMSIED	
	Acc (%)	F1 (%)	Acc (%)	F1 (%)	Acc (%)	F1 (%)
sc-LSTM	78.60	-	-	-	80.40	77.60
SWAFN	80.20	80.10	61.03	59.32	83.02	81.14
CMHFM	84.07	83.65	83.18	81.72	84.20	83.97
MCTCF	83.80	83.70	84.20	84.40	86.07	85.41
UniMSE	85.85	85.79	85.86	85.83	83.06	81.70
MB-CL	63.90	-	64.80	-	81.60	79.30
TTP	76.98	-	73.72	-	86.21	84.86
TIMISA	84.79	84.61	85.87	85.96	89.31	85.63

在 CMU-MOSEI 数据集上, 基于文本的 MB-CL 和 TTP 模型仍然表现较差, 准确率分别为 64.80%和 73.72%, 再次强调了多模态数据在情感分析中的重要性。值得注意的是, SWAFN 因采用七分类任务评估, 准确率低于其他采用三分类任务评估的基线模型。TIMISA 模型的表现高于 UniMSE 模型, 准确率为 85.87%, F1 分数为 85.96%, 这是因为该数据集上包含隐式情感特征的数据数量更多, UniMSE 模型仅

针对显式情感特征设计，在处理隐式数据方面仍有不足。TIMISA 模型在情感分类中具有更高的稳定性和精确度，进一步验证了其在捕捉隐式情感数据方面的优势。所提出的方法同样适用于复杂的多模态情感分析任务。

在 CMSIED 数据集上，所有基于文本辅助的模型的性能相较于 CMU-MOSI 和 CMU-MOSEI 数据集均有所提升，反映了隐式情感数据集对模型敏感度的特殊要求。MB-CL 模型在该数据集上的准确率达到 81.60%，较其他数据集显著提升，表明其通过捆绑感知对比学习，在处理隐含情感信号和细粒度情感分类任务时表现较好。相比下 TTP 模型的准确率提高了 4.686%，可能与该数据集完全由隐式情感数据构成有关，显示了文本特征在特定情境下的有效性。但由于其简单的特征映射方式未能充分考虑模态间的关系，过于简化的处理方式难以取得最佳效果。相对而言，TIMISA 模型通过更精细的模态间交互设计和自适应处理，更好地利用多模态数据，尤其是在隐式情感的捕捉方面表现尤为突出，准确率和 F1 分数分别高达 89.31% 和 85.63%，明显优于其他基线模型。进一步验证了 TIMISA 在复杂的隐式情感数据处理方面的独特优势。UniMSE 的表现稍差，准确率为 83.06%，可能是因其对隐式情感的细微变化没有足够的敏感度。CMSIED 数据集中，文本常以隐喻、暗示等间接的方式表达情感，语音与视觉模态中的微表情、语气停顿等信号则成为情感识别的关键线索。而 TIMISA 模型采用的注意力机制能够基于数据特性，动态聚焦各模态中的关键情感线索。在处理隐晦文本时，模型通过视觉与语音模态的辅助，利用注意力权重增强对隐含情感线索的感知，相比处理显式情感数据时单一模态主导的情况，这种机制更契合隐式情感数据的多模态协同需求。

综上，TIMISA 模型不仅在处理传统显式情感数据时具有一定优势，在隐式情感分析方面的性能表现尤为突出，其多模态融合能力和对情感细节的敏感性使其在不同类型的情感数据处理上都具备较强的竞争力。相比于其他基线模型，TIMISA 能够更好地捕捉隐式情感，并在情感分类的准确性与稳定性上超越大部分基线模型，进一步验证了基于多模态信息的隐式情感分析方法的能够提高模型情感分类能力。

3.4.5 消融实验

（1）多模态特征融合方法对 TIMISA 的影响

为了分析每种模态在 TIMISA 模型中的贡献，我们在 CMU-MOSI 和 CMSIED 数据集上进行了三组消融实验。实验结果如表 3.5 所示。

第一组实验只使用一种模态作为模型输入。结果表明，在四种模态中，文本模态的准确率和 F1 分数均高于语音（A）和视觉（V）模态，语音和视觉模态的表现相对较弱，尤其是在 CMU-MOSI 数据集上，准确率分别仅为 43.16%和 46.33%。这表明了文本模态的决定性作用，非言语模态（A 和 V）中包含了更多的噪声或冗余信息，难以直接提取情感相关的特征。

第二组实验使用两两模态组合作为模型输入。揭示了两种模态之间的相互作用。从结果中可以看出，两种模态组合的性能通常优于单一模态，这表明模型能够从不同模态数据中提取出更多有用的背景信息和互补的情感信息。然而，使用音频特征和视频特征（A+V）作为输入的效果远不如使用文本-语音模态组合（T+A）和文本-视频模态（T+V）组合，进一步证明了文本模态在情感分析中的主导地位，其包含的情感信息比其他模态更为丰富。

第三组使用三种模态组合（T+A+V）作为模型输入。从表中可以看出，与双模态组合相比，三种模态组合的性能进一步提升，在两个数据集上都达到了最佳表现。这也证明了模型通过融合语音和视觉特征，能够获取更多上下文信息，从而提升隐式情感分析的准确性。同时实验结果也表明了多模态组合的有效性，即去除任意一种模态都会导致模型性能下降。

表 3.5 多模态特征融合方法对 TIMISA 的影响

特征	CMU-MOSI		CMSIED	
	Acc (%)	F1 (%)	Acc (%)	F1 (%)
T	50.63	50.17	50.80	49.82
A	43.16	43.21	47.91	46.01
V	46.33	46.31	48.72	49.79
T+A	66.53	62.50	76.13	75.70
A+V	57.14	55.63	72.60	73.15
T+V	70.21	68.33	81.48	78.32
T+A+V	84.79	84.61	89.31	85.63

（2）不同模块结构对 TIMISA 的影响

为了验证 TIMISA 模型中各子模块的作用，基于完整的模型，通过逐步删除不

同模块的方式，在 CMSIED 数据集上进行了消融实验，以验证每个模块的有效性。实验结果如表 3.6 所示。

从表中可以看出，在直接去除多头互注意力模块（TIMISA w/o MHMA）后，导致语音和视觉模态缺乏与文本相关的语义和情感信息，导致模型的准确率下降了 2.23 个百分点。而 MHMA 在处理跨模态信息时更具优势，能够有效地捕捉文本与其他模态之间的语义关联，为后续多模态融合提供更有效的输入。

为验证文本在多模态特征中的主导作用，我们移除了文本语义增强的交叉注意协同模块（TIMISA w/o TCAC），改为将模态特征直接拼接的方式，然后由完全连接层进行分类。实验结果表明，直接拼接的方法准确率较 TIMISA 模型下降了近 6 个百分点。其根本原因在于，该方法平等地对待所有模态，未能学习不同模态之间的相互作用，无法保证最终的融合表示包含足够的情感相关信息。

此外，我们分别测试了以语音模态（AMFISA）和视觉模态（VMFISA）作为目标模态的融合策略。TIMISA 模型在 CMSIED 数据集上的表现最佳，准确率和 F1 分数分别达到 89.31% 和 85.63%，AMFISA 和 VMFISA 的性能均不及 TIMISA 模型。这表明在强化文本模态作用的基础下，来自其他模态的信息可以相互补充，有助于增强说话者情感在视频中的表达，从而提升模型预测情感的准确性。VMFISA 的性能略高于 AMFISA，这可能是因为视觉模态在某些场景下比语音模态能更直观地反映情感状态，但其优势并不显著。这一差异进一步验证了将文本视为主要信息源，同时辅以语音和视觉特征，是一种更为合理且有效的多模态融合策略。

表 3.6 TIMISA 中各模块有效性的消融实验


模型	CMSIED	
	Acc (%)	F1 (%)
TIMISA	89.31	85.63
TIMISA w/o MHMA	87.08	83.95
TIMISA w/o TCAC	83.77	80.30
AMFISA	85.13	82.60
VMFISA	86.42	83.71

3.4.6 案例分析

为了更直观地理解多模态特征融合对模型性能的影响，在 CMSIED 数据集的两个案例中，我们对比了 TIMISA 模型对文本（T）、语音（A）、视觉（V）三个模态的情感预测结果与实际标签之间的差异。实验结果如表 3.7 所示。表中“示例”列表示不同模态的输入。“标签”列为示例的真实标签值，而“TIMISA”列为模型预测值。

在案例 1 中，语境可能带有轻松或调侃意味。由于使用文本或语音单模态，模型因未能捕捉“多”一词的隐含情感。尽管该词语具有正向语义，但因语境的讽刺性，导致模型误判为“Positive”。而视觉模态的面部表情则准确地反映了真实情感。TIMISA 模型通过整合语音和视觉信息，识别视觉模态提供的关键情感信号，正确地将情感预测为“Negative”。这表明多模态融合能够有效降低因词汇误导而产生的预测偏差。案例 2 中，由于单词“杀死”和“懒惰”等词汇的干扰，使模型过度关注文本信息，导致最终预测偏差，识别为“Negative”。然而，TIMISA 模型更多地捕捉到了语音模态中乐观的语气，以及视觉模态提供的自信和决心的面部表情特征，从而正确地识别了整体积极的情感倾向。这表明语音和视觉模态在某些场景下能够有效补充文本模态的不足。

表 3.7 CMSIED 数据集的案例

	示例	T	A	V	TIMISA	标签
案例 1	端午节不就比周末多一天					
	 	积极	积极	消极	消极	消极
案例 2	杀死我心中懒惰的念头					
	 	消极	积极	积极	积极	积极

案例研究表明，基于多模态特征的隐式情感分析任务中，各模态信息之间可能

存在的差异和互补性。而 TIMISA 模型能够综合考虑文本、音频和视频模态的信息，合理处理不同模态之间的情感差异，并在不同模态提供矛盾信息时做出合理的判断，做出准确的预测。这种多模态融合方法有助于减少由单模态信息带来的误判风险，提高隐式情感分析的整体准确性。

此外，我们选取 CMU-MOSI 数据集中的样本，对比了 SKEAFN 和 TIMISA 模型对同一句子的情感预测结果。表 3.8 显示了不同模型对特定句子的预测值、实际标签值以及相关的输入信息（语音和视觉模态特征以文字形式概述）。实验结果表明，两个模型均正确地将该案例的情感倾向判断为“Positive”，证实了多模态特征对分析隐式情感任务的重要作用。从预测值来看，SKEAFN 模型的情感预测值为 0.71，而 TIMISA 模型的预测值更加接近真实标签，误差仅为 0.05。这表明 TIMISA 模型在处理隐式情感差异时具有更高的优势，在预测精度上略胜一筹。

表 3.8 CMU-MOSI 数据集的案例

示例	模型	预测值	真实值	标签
T: Every frame of this film is worth savoring.	SKEAFN	0.71	0.81	积极
A:音调柔和，略带欣赏	TIMISA	0.76	0.81	积极
V:眼神温柔，嘴角微扬，神情专注而沉浸				

3.4.7 可视化分析

为进一步探讨在隐式情感分析中融合多模态特征的作用，本章采用热力图可视化技术对比分析了纯文本特征与多模态融合特征的权重分布差异，如图 3.4 所示。以 CMSIED 数据集中句子“杀死我心中懒惰的念头”为例，3.4（a）和 3.4（b）分别为文本权重矩阵和融合语音和视觉特征后的多模态权重矩阵，其中色度梯度直观地反映了各词汇对情感表达贡献度的差异值。

实验结果显示，在仅使用文本特征时，图 3.4（a）中“我”一词的权重高于“念头”，但其对情感分析并无实际贡献。而在引入语音和视频模态后，图 3.4（b）中“我”的权重有所降低，同时“我”和“心中”之间的权重增加，“杀死”和“我”之间的关联权重下降。这表明，多模态特征的融合使模型能够更准确地地

识别情感意义显著的词汇，并有选择性地加权调整相关词汇的权重，过滤无关噪声，从而提升捕捉关键信息的能力。




图 3.4 权重矩阵的可视化

3.5 本章小结

本研究针对传统隐式情感分析方法在隐含情感线索提取和信息利用不足的问题，提出了一种融合多模态特征的中文隐式情感分析方法。该方法采用多头互注意机制将语音-文本和视频-文本特征进行有效融合，并通过交叉注意力机制优化各模态信息之间的交互特征，减少噪声干扰。为验证所提方法的有效性，本文创建了一个包含多模态特征的中文隐式情感分析数据集 **CMSIED**，其独特的多源数据结构不仅为隐式情感文本分析提供了有价值的多模态训练数据，还为后续研究提供了重要的参考价值。实验结果表明，所提出的多模态信息融合方法在三个数据集上表现明显优于其他方法，证明了引入多模态特征和适当的特征融合策略能够显著增强隐式情感分析性能，为隐式情感分析提供新的思考方向。

在未来的研究中，我们将采用更为严格的标注标准，进一步扩展 **CMSIED** 数据集的规模并提升其质量。此外，我们计划结合知识图谱等外部知识库，以增强模型对特定领域或背景知识的理解与应用能力。

4 基于思维链提示生成多模态辅助中文隐喻情感分析方法

4.1 引言

隐喻情感分析作为隐式情感分析的一个重要分支，旨在识别文本中隐喻表达所隐含的情感极性。作为一种重要的语言认知现象，隐喻的情感往往隐藏于字面含义之下，传递的情感强度往往比字面表达更为强烈。尤其是在微博、Twitter 等社交平台上，人们更倾向于通过隐喻来表达自己的情感^[83]。然而，隐喻情感分析的挑战在于其隐含意义难以直接从文本中提取，传统的文本分析方法难以准确捕捉隐喻背后的情感信息。

目前，大多数方法依赖于词典和规则^[84,85]，在面对复杂的隐喻句子时往往表现出不足。中文情感表达的复杂性与多义性，更易造成字面与隐喻意义的情感极性偏差，进一步加大了隐喻情感分析的难度。相较于单模态隐喻，多模态隐喻融合文本和图像等多种表达方式，因其丰富性和生动性而变得越来越流行。Xu^[86]等人的研究表明，通过研究图像和文本隐喻线索及其相互作用，能够有效提高隐喻情感理解的准确性。为具体阐释视觉特征对隐喻情感解析的辅助作用，图 4.1 展示了原始隐喻文本作为 Stable Diffusion 输入（左）或使用 GPT-3.5 与思维链提示（右）推理增强后生成的图像示例。图 4.1a（1）中，“她的厨房是一个创意的实验室”，字面上表达积极意义，但图像所呈现的凌乱视觉场景反映出一种消极情绪。这种图文模态的情感表征差异验证了图像特征在隐喻情感分析中的重要作用，它能够补充文本未明确表达的情感信息，并有效识别潜在的情感矛盾。

尽管这种方法取得了一定的成功，但多数研究侧重于图像的字面解释，在从语言隐喻生成视觉隐喻的任务中^[87]，生成的图像容易与原意严重偏离，准确揭示语言背后的隐含意义并以图像形式表现出来尤为挑战。引入语音辅助可以帮助模型更好地理解隐喻的深层含义，避免因文字直解引起的误导。例如，图 4.1（b）中句子“他在音乐海洋中遨游”所生成的图像未能准确传达“沉浸于音乐”的抽象概念，添加语音描述可以更好地呈现人物在音乐的世界中自由探索、享受的意图。因此，理解视觉、语音和文本特征之间的交互至关重要，单一模态的信息往往不足以传达完整的意图，还可能因相似性引起混淆或差异性提供的额外线索。

为解决以上问题，本文受 Chakrabarty 等人^[88]通过 ChatGPT 与专门的模型协作来增强视觉语言任务的启发，提出一种基于思维链提示生成的多模态辅助隐喻情感分

析模型（Chain-of-Thought Chinese Multimodal Metaphor Sentiment Analysis, CoT-CMMSA）。该方法在利用 CoT 指导 GPT-3.5^[36]增强隐喻文本描述的基础上，引入语音特征与文本提示融合，解决图像生成不准确问题，提升模型对隐喻深层含义的理解。并利用文本引导的多模态渐进式融合策略，避免在复杂语境中歧义和隐喻引起的误解，有效提升了隐喻情感分析的性能。




图 4.1 引入思维链提示的图像对比示例

4.2 CoT-CMMSA 模型

本文提出的 CoT-CMMSA（Chain-of-Thought Chinese Multimodal Metaphor Sentiment Analysis）模型的总体架构如图 4.2 所示。CoT-CMMSA 主要由四个部分组成：隐喻识别与文本语义增强、基于隐喻的图像与语音生成、特征提取及表示和文本引导的多模态特征渐进融合模块。

隐喻识别与文本语义增强主要借助思维链提示指导下的 GPT-3.5 模型识别隐喻并生成详细的图像描述。基于隐喻的图像与语音生成旨在使用特定的生成模型分别生成图像和语音。特征提取及表示通过文本、视觉和语音编码器将文本及其对应的图像、语音编码为多模态特征，这些特征通过文本引导的多模态特征渐进融合，将增强后的文本、视觉和语音特征进行深度融合，得到的特征表示输入到分类器中进行隐喻情感分析。模型的细节将在下面的部分中详细介绍。




图 4.2 CoT-CMMSA 模型结构

4.2.1 隐喻识别与文本增强

为较好的理解隐含情感，本文采用多任务方式，设计了两个辅助任务隐喻识别和思维链提示进行文本增强。隐喻识别根据句子中上下文来预测哪些词是隐喻词，以减少对情感词典准确性的依赖。文本增强使用 GPT-3.5 语言模型通过扩充句子提升增强文本质量，这比传统模型的计算量要小得多。在本节中，我们介绍了隐喻识别的方法以及如何使用思维链提示进行文本增强。

(1) 隐喻识别

隐喻识别的主要目的是识别文本中的隐喻词及其对情感表达的影响。本文利用 GPT-3.5 模型强大的自然语言处理能力，不依赖外部知识库或复杂模型，将隐喻识别过程转化为序列标注问题，简化了识别过程，有效应对了上下文信息不足带来的挑战 and 繁琐流程。在给定序列 $S = \{w_1, w_2, \dots, w_n\}$ 中，模型的目标是预测每个词 w_i 是否为隐喻词 m_i ：

$$P(M|S) = \prod_{i=1}^n P(m_i | w_i) \quad (\text{式 4.1})$$

其中, $m_i \in \{0,1\}$, 0 表示非隐喻词, 1 表示隐喻词, w_i 表示句子中的第 i 个单词。

(2) 文本语义增强及 CoT 提示构建

考虑到 GPT-3.5 在复杂语境中会忽略语义差异, 导致对视觉信息和文本之间复杂关联性的理解不足, 进而影响文本生成图像任务的表现。本文引入 CoT 提示, 利用隐喻对象、隐含意义和关系等作为中间步骤, 通过 GPT-3.5 逐步推导出文本隐喻并生成扩充信息, 以增强模型的推理和理解能力。同时, 将初次处理时未捕捉到的语义差异与文本一起输入, 加强模型对隐喻情感的理解。

由于提示遵循逐步推理结构, 零样本学习方法并不适用, Chakrabarty 等人^[88]发现精选少量的样本可以显著提高输出质量。基于此, 本研究根据 Li 等人关于中文隐喻类型分类的研究^[89], 为提示选取了五个独特且具代表性的案例对 GPT-3.5 进行微调, 确保所选案例涵盖复杂概念的不同方面以及多个领域。

CoT 提示的构建过程包括多个关键步骤, 并在过程中特别嵌入了视觉描述。具体而言, 模型需识别出句子包含的对象和隐含意义, 明确对象之间的关系并提出三个候选词以丰富描述内容, 最后基于这些属性生成详细的视觉阐述。提示构建完成后, GPT-3.5 根据任务需求对案例数据进行分析处理, 并记录生成结果。

CoT 提示指令构建如下:你的任务是分析隐喻句子中的隐含意义, 明确其对象、属性和关系, 提出三个候选词以丰富描述, 并基于这些候选词构建一个包含隐含意义和对象的细致视觉阐述。表 4.1 展示了通过 CoT 提示对给定隐喻文本进行的增强和阐释的结果。

为评估模型的生成质量, 本研究采用人类主观评分 $H(Q)$ 来对生成的内容进行打分。评分以实际输出 q_i 与预期隐喻语义的匹配度为依据, 计算得分后根据评估结果对提示 P_{in} 或模型参数 W 进行微调和优化, 确保模型生成内容符合预期的质量标准。

$$H(Q) = \frac{1}{n} \sum_{i=1}^n \text{Score}(q_i) \quad (\text{式 4.2})$$

具体地, 基于识别出的隐喻词 w_i 及其对象的属性和关系, 利用 GPT-3.5 生成三

个候选词用于扩充文本对对象和属性的描述。

$$V(w_i) = GPT-3.5(m, a, r) \quad (\text{式 } 4.3)$$

其中, a 和 r 分别表示隐喻对象的属性和关系。接着, 将生成的候选词 $V(w_i)$ 及其上下文作为输入, 通过 GPT-3.5 生成额外扩展的句子, 以获得增强数据。

$$T' = GPT-3.5(V_{(w_i)}, p, context) \quad (\text{式 } 4.4)$$

其中, $T' = \{T'_l | l = 0, \dots, 60\}$, T'_l 表示句子长度, p 为隐喻识别后提取的提示信息, 用于辅助生成上下文相关的扩展文本。

表 4.1 基于 CoT 提示的文本增强示例

1.隐喻文本:快递像蜗牛一样。 对象:快递, 蜗牛 关系:快递服务的速度很慢 隐含意义:慢, 拖延 候选词:缓慢, 迟钝, 拖沓 视觉阐述:一只蜗牛背着象征快递包裹的壳, 在繁忙的城市街道上挪动, 速度慢得让人着急。	3.隐喻文本:法庭上的狐狸。 对象:狐狸 关系:法庭上的人物狡猾且机智, 与权谋和策略相联系 隐含意义:狡猾、狡诈 候选词:诡计、谋略、操控 视觉阐述:一个身着律师服饰的狐狸站立在法庭讲台前, 眼神狡黠暗示着谋略, 尾巴隐于袍内。
2.隐喻文本:她的厨房是一个创意的实验室。 对象:厨房、实验室 关系:把厨房比作实验室, 强调无序和混乱的状况 隐含意义:混乱、没有条理 候选词:杂乱、无序, 繁忙 视觉阐述:厨房一片混乱, 摆满食材和烹饪工具。厨师忙着搅拌一锅冒泡的奇特食材混合物, 四周散落着各种香料。	4.隐喻文本:教室是一个动物园。 对象:教室、动物园 关系:课堂与动物园之间暗示了一种无序和缺乏控制的环境 隐含意义:混乱、喧哗 候选词:嘈杂、婚礼、吵闹 视觉阐述:课堂上, 孩子们像各种动物一样四处乱窜, 嘈杂喧闹, 老师艰难地维持秩序。

4.2.2 基于隐喻的图像与语音生成

(1) 文本生成图像

在文本到图像生成领域，SD 模型因其生成高质量图像的能力广受关注。然而，SD 模型主要依赖于文本提示处理直接、显式的描述，难以准确生成含有隐喻或深层意义的图像，如图 4.2 所示。为解决这一问题，本文采用 SD 模型，将增强后的文本与原始文本提示结合，构建更丰富的描述 $T=(S,T')$ ，并输入到 SD 模型以生成图像。

$$V = SD(T) \quad (\text{式 4.5})$$

通过整合 SD 模型与经过 CoT 提示扩展的文本，实现了从抽象文本到具体图像的高质量转换，使模型能更准确地理解并转化复杂的隐喻描述，提升系统处理复杂语义的能力。

(2) 文本生成语音

CoT 提示策略用于指导 GPT 模型生成细腻的文本描述，以作为 SD 模型生成图像的输入，但生成的文本在捕捉隐喻细节方面仍存在不足，导致部分图像质量不理想。鉴于专家评估视觉描述的复杂性，我们引入语音特征作为补充维度，通过捕捉语音的情绪和语调信息，增强情感表达并提供更多上下文线索，从而缓解图像生成误差对情感分析准确性的负面影响。为此，在生成文本描述后，采用 Grad-TTS 进行文本到语音的转换。具体而言，将增强后的文本序列 T' 作为上下文与原始文本序列 S 拼接，形成文本输入序列 $x_{i:L}$ 。然后，使用 Grad-TTS 模型生成 Mel 频谱图 $y_{i:F}$ ：

$$x_{i:L} = S + T', \quad x_{i:L} \in [1, L] \quad (\text{式 4.6})$$

$$y_{i:F} = \text{Grad-TTS}(x_{i:L}) \quad (\text{式 4.7})$$

其中 F 为声学帧数。接着，编码器将输入文本序列 $x_{i:L}$ 转换为特征序列 $\tilde{\mu}_{i:L}$ ，并使用持续时间预测器生成每个文本输入的持续时间。

$$\tilde{\mu}_{i:L} = \text{Encoder}(x_{i:L}) \quad (\text{式 4.8})$$

将特征序列 $\tilde{\mu}_{i:L}$ 和帧特征序列 $\tilde{\mu}_{i:F}$ 生成之间硬单调对齐的映射 A 。函数 A 是

$[1, F] \cap \mathbb{N}$ 与 $[1, L] \cap \mathbb{N}$ 之间的单调满射映射, 其中, $\mu = \tilde{\mu}_{A(j)}$, $j \in [1, F]$ 将输出序列 $\mu = \mu_{1:F}$ 传递给解码器, 通过参数为 θ 的神经网络 $s_\theta(X_t, \mu, t)$ 定义的常微分方程 (ODE) 来生成最终的音频。

$$A = \frac{1}{2} (\mu - X_t - s_\theta(X_t, \mu, t)) \beta_t dt \quad (\text{式 4.9})$$

其中, 噪声调度 β_t 和时间范围 T 是预定义的超参数。

4.2.3 特征提取及表示

如图 4.2 所示, 在数据预处理阶段使用 BERT、LibROSA 和 Faster R-CNN 分别提取文本、语音以及图像特征, 得到 $d_t = 768$ 词向量表示, $d_a = 33$ 的帧级语音特征以及 $d_v = 1024$ 的图像特征。提取的三种模态的初始嵌入表示为:

$$I_{\{T, A, V\}} \in \mathbb{R}^{L_{\{T, A, V\}} \times D_{\{T, A, V\}}} \quad (\text{式 4.10})$$

式中, T 表示文本模态, A 表示语音模态, V 表示视觉模态, L 表示不同模态的序列长度, D 表示相应模态的特征维度。然后, 使用两个 BiLSTM 网络对输入的多模态特征进行编码, 得到语音、视觉模态的上下文表征:

$$\hat{I}_{\{A, V\}} = BiLSTM(I_{\{A, V\}}; \theta_{\{A, V\}}^{BiLSTM}) \quad (\text{式 4.11})$$

式中, θ 表示不同模态特征提取的模型参数。在处理文本模态时, 使用 BERT 模型获取文本的向量表示, 使用一维时间卷积操作对单模态特征进行转换, 确保不同模态特征具有相同的维度。

$$\hat{I}_T = BERT(I_T; \theta_T^{BERT}) \in \mathbb{R}^{L_T \times D_T} \quad (\text{式 4.12})$$

$$X_m = Conv1D(I_m, k_m) \in \mathbb{R}^{l_m \times d_m}, m \in \{T, A, V\} \quad (\text{式 4.13})$$

其中, k_m 表示卷积核大小, l_m 表示为特征序列对齐之后的长度。 d_m 表示不同模态特征维度。

4.2.4 以文本引导的多模态渐进融合

针对目前大多数多模态隐喻处理方法未能充分考虑不同模态间的独立性和共性，尤其忽视了文本特征在复杂情感分析中的关键线索。本文提出了一个 TPFMF 架构，该架构由两个模块组成，如图 4.2 所示。具体细节将在以下部分进行说明。

(1) 跨模态特浅层征融合

在浅层融合部分，使用多头交互注意力机制，使各模态在保持自身独特性的同时，能够充分利用来自其他模态的信息，学习不同模态之间的相互作用，从而增强单模态特征。如图 4.3 所示，以文本、语音特征增强视觉特征为例，首先，通过线性层调整视觉特征向量 X_V 的维度，使其与其他模态对齐，得到 X'_T 、 X'_V 、 X'_A 。

$$X'_{\{T,V,A\}} = \text{Linear}(X_{\{T,V,A\}}) \quad (\text{式 4.14})$$

接着，使用多头交互注意力机制自适应地为视觉特征分配重要性权重，并选择性的将关键的文本和语音特征地融入视觉特征中。在这个过程中，提取的每个话语的视觉特征通过多头交互注意力模块获取外部信息，不断更新序列以增强特征表现。每个跨模态注意层，源模态（文本和语音特征）的信息被转换成一组不同的键值对，与目标模态（视觉特征）进行交互，然后融合 h 个子空间的特征信息，计算过程如下所示：

$$X^h = \text{soft max} \left(\frac{X'_V W_V^{(h)} \times (X'_T W_T^{(h)})^T}{\sqrt{d_k}} \right) X'_T \quad (\text{式 4.15})$$

其中， h 表示多头注意力机制的头数， $W_q^{(h)}$ 、 $W_k^{(h)}$ 表示第 h 个注意力头部的可训练权重矩阵， $\sqrt{d_k}$ 为缩放因子。每个样本的视觉特征都会关注在与之相关且得分高的文本、语音特征，而其他无关的特征则不会受到关注。最后，经过 h 次解码后，最终得到融合其他两种模态的视觉表示 X_{TV}^* 、 X_{AV}^* 。

$$X_{TV}^* = \text{Linear}(\text{concat}(X^1, X^2, \dots, X^h) \times W_{TV}) \quad (\text{式 4.16})$$

$$X_{AV}^* = \text{Linear}(\text{concat}(X^1, X^2, \dots, X^h) \times W_{AV}) \quad (\text{式 4.17})$$

式中, W_{TA} 为映射矩阵。采用相同的方法得到四种跨模态特征组合, 语音-文本 X_{AT} 、语音-视觉 X_{AV} 、视觉-文本 X_{VT} 和视觉-语音 X_{VA} 特征。每个模态都通过多头互注意力获取其他模态的信息映射。

$$X_V = \text{MultiHead}(Q_{T/A}, K_V, V_V) \quad (\text{式 4.18})$$

最后, 将目标模态的原始特征与其跨模态映射后的特征进行拼接, 得到增强后的单模态特征向量 $X_V = [X_{VT}; X_{VA}]$; $X_A = [X_{AT}; X_{AV}]$ 。




图 4.3 多头互注意力

(2) 文本导向的深层交叉注意力融合网络

在处理隐喻文本时, 其高阶语义信息与语音和视觉模态中的低级特征相比, 后者通常包含大量冗余信息。因此, 在特征融合阶段, 提出一种文本导向的交叉注意力融合方法, 对三种强化后的单模态特征进行深度融合。

具体来说, 通过跨模态交叉注意力机制, 使用语音、视觉特征作为辅助权重向量与文本特征进行多层次融合, 如图 4.4 所示。这种方法能够使文本特征引导模型更多的关注语音、视觉特征的相关区域, 减少低级特征对文本特征的负面影响, 以获得更优的多模态融合表示。以文本和视觉融合特征为例, 首先, 将目标句 X_T 作为查询向量, 匹配与视觉融合特征 X_V 相关的部分, 视觉融合特征作为辅助信息纠正和补充文本语义, 得到跨模态文本嵌入表示 $X_{V \rightarrow T}$ 。

$$\begin{aligned}
 X_{V \rightarrow T} &= \text{CorssAttention}(X_V, X_T) \\
 &= \text{soft max} \left(\frac{X_T W_Q \times (X_V W_K)^T}{\sqrt{d_k}} \right) X_V W_V
 \end{aligned} \quad (\text{式 4.19})$$

其中, $Q = X_V W_Q$ 、 $K = X_T W_K$ 、 $V = X_V W_V$ 分别表示查询、关键字和值。然后, 再将 $X_{V \rightarrow T}$ 作为主要模态, 应用跨模态交叉注意机制来获得从 T 到 V 的交叉模态嵌入表示 $X_{V \rightarrow T}^*$ 。

$$\begin{aligned}
 X_{V \rightarrow T}^* &= \text{CorssAttention}(X_{V \rightarrow T}, X_T) \\
 &= \text{soft max} \left(\frac{X_{V \rightarrow T} W_Q^* \times (X_T W_K^*)^T}{\sqrt{d_k}} \right) X_T W_{V \rightarrow T}
 \end{aligned} \quad (\text{式 4.20})$$

式中, $W_{V \rightarrow T}$ 为权重参数矩阵。接着, 将 $X_{V \rightarrow T}$ 和 $X_{V \rightarrow T}^*$ 拼接, 并通过线性变换获得降维特征。随后, 通过 $\tanh$ 和 soft max 激活函数处理获得交互特征。

$$\tilde{X}_{V \rightarrow T} = \text{soft max}(\tanh(W_i \cdot \text{Linear}(X_{V \rightarrow T}, X_{V \rightarrow T}^*) + b_i)) \quad (\text{式 4.21})$$

$$\tilde{X}_{A \rightarrow T} = \text{soft max}(\tanh(W_i \cdot \text{Linear}(X_{A \rightarrow T}, X_{A \rightarrow T}^*) + b_i)) \quad (\text{式 4.22})$$




图 4.4 文本导向的深层交叉注意力融合网络

4.2.5 情感分类

将交互特征 $\tilde{X}_{V \rightarrow T}$ 和 $\tilde{X}_{V \rightarrow T}$ 拼接得到最终的隐式多模态特征向量 Z 作为预测层的输入，计算情感类别的概率。这一过程不仅整合了多模态信息，还通过更精细的情感分析提升了预测的准确率。

$$Z = \text{Concat}(\tilde{X}_{A \rightarrow T}, \tilde{X}_{V \rightarrow T}) \quad (\text{式 4.23})$$

$$y = \text{soft max}(W_o Z + b_o) \quad (\text{式 4.24})$$

其中， W_o 表示权重矩阵， b_o 表示偏置值。最后，使用交叉熵损失函数计算预测标签与真实标签之间的损失。

$$L_{\text{sentiment}} = -\frac{1}{N} \sum_{i=1}^{N-1} \hat{y}_i \times \log(y_i) \quad (\text{式 4.25})$$

其中， N 是样本数， y 是模型预测输出， $\hat{y}$ 是真实标签值， i 为 $\hat{y}$ 和 y 的索引。

由于文本生成与隐喻识别任务共享相同的语言模型和参数，因此在模型优化过程中，使用最小化语言建模损失提升模型识别隐喻与生成文本的能力。关于辅助任务隐喻识别和文本生成损失 L_{LM} 定义如下：

$$L_{LM} = -\frac{1}{N} \sum_{i=1}^N \sum_{t=1}^{T_i} \log P_{\theta}(x_t^{(i)} | x_{1:t-1}^{(i)}) \quad (\text{式 4.26})$$

其中， N 是样本数量。 T_i 是第 i 个样本的序列长度， $x_t^{(i)}$ 是第 i 个样本在时间步 t 的词汇。 $P_{\theta}(x_t^{(i)} | x_{1:t-1}^{(i)})$ 是在给定上下文 $x_{1:t-1}^{(i)}$ 条件下，模型参数 θ 预测词 $x_t^{(i)}$ 的概率。最终，模型的总损失是情感分析任务 $L_{\text{sentiment}}$ 和辅助任务 L_{LM} 的加权和：

$$L_{\text{joint}} = \alpha \cdot L_{\text{sentiment}} + \beta \cdot L_{LM} \quad (\text{式 4.27})$$

其中， α 、 β 是损失的权重。

4.3 实验结果与分析

4.3.1 实验数据集

该模型在两个公开可用的数据集和 CCL2018^[90]以及 VUA^[91]上进行了评估。具体如下如表 4.2 所示。

CCL2018: 该数据集用于评测中文隐喻检测任务。共包含 4394 个中文句子，其中 4075 条为隐喻句，319 条为非隐喻句。数据来源于新闻报道、文学作品和社交媒体等内容。情感标签分为积极和消极两类。

VUA: VUA 是一个广泛用于隐喻识别和分析的数据集，每个单词都按字面或隐喻方式进行注释。该数据集由 117 个片段组成，包含一万多个句子，这些句子被手动标注为包含隐喻或不包含隐喻。涵盖学术、新闻、对话和小说四种类型。由于缺乏公开可用的隐喻情感分类数据集，我们对 VUA 数据集进行了标注，以验证模型的有效性，其中所有样本被标注为积极、消极或中性三类。

表 4.2 数据集统计

数据集	训练集	验证集	测试集	总计
CCL2018	2157	1691	225	4394
VUA	7529	1550	2694	11838

4.3.2 实验环境和参数配置

所提出模型基于 Pytorch 1.8 和 Python 3.6 构建，训练在 14 vCPU Intel(R) Xeon(R) Gold 6330 CPU @ 2.00GHz 进行。使用 Adam 优化器，学习率为 0.001。批大小初始值为 8。在数据处理模块中，Conv1D 的内核大小设置为 3。多头注意的头数设置为 8。BiLSTM 的隐藏层大小为 256，ChatGPT-3.5 温度设置为 0.7，生成图片大小为 480*480。在句子增强阶段，思维链提示的最大字符数设置为 60。

4.3.3 评价指标

本章实验中，采用准确率 (Acc) 和宏平均 F1 值 (Macro-F1) 作为评价指标，评估模型在 CCL2018 和 VUA 数据集上的性能。其中 Acc 和 F1 值的详细计算过程请参见第三章中 3.4.3 节。

4.3.4 对比实验结果分析

为验证 CoT-CMMSA 模型在情感分类任务中的表现，我们将其与基线模型在 CCL2018 数据集和 VUA 数据集上进行了对比实验。基线模型的超参数沿用与原始论文相同的设置。具体如下：

- (1) MTL^[92]：提出一种隐喻识别和情感预测联合模型进行情感分析。
- (2) RoBERTa^[93]：通过单词相关信息建模进行情感分类。
- (3) TRAT-LSTM^[94]：基于注意力机制检测隐喻语境中的情感。
- (4) DASR^[95]：提出了基于 Seq2Seq 模型识别动词隐喻并分析其情感。
- (5) CDKI^[96]：利用领域特征增强隐喻情感表示并进行情感分析。
- (6) ChatGPT^[64]：使用 ChatGPT 进行隐喻情感分析。
- (7) LSTM+CNN+RF^[97]：提出利用面部表情特征来分析隐喻情感。

表 4.3 显示了模型 CoT-CMMSA 在 CCL2018 和 VUA 数据集上与其他基线模型比较的结果。基线模型的实验结果来源于论文原文或其他论文的复制结果。从表中可以看出，CoT-CMMSA 在两个数据集上的所有评估指标上均优于其他模型，表现出显著优势。

在 CCL2018 数据集上，TRAT-LSTM 模型表现最差，原因是该模型仅依赖文本模态处理目标与上下文的相互作用来检测隐喻语境中的情感，而隐喻情感有时与语境相反或相似，仅靠上下文难以判断句子的情感极性。相反，CDKI 通过结合图像和文本信息准确率提高了 8.52%，强有力地证明了图像辅助文本进行隐喻情感分析的有效性。与 CDKI 模型相比，DASR 通过句子重构进行数据增强，减少噪声信息，准确率提高了 4.33%。进一步证明了增强文本知识为模型提供了更丰富、更有价值的信息，补充生成的伪数据可以在一定程度上提高隐喻情感分类性能。而 LSTM+CNN+RF 尽管融合了视觉特征并提升至 78% 的准确率，但在模态间的交互处理上过于简单，没有考虑模态间的特异性。相比之下，本文采用了渐进式融合策略，充分融合各模态的独特表征，强调文本隐喻信息中的重要性，使模型能够利用更高级别的概念和语义关联，从而有效提高模型的性能。在 CCL2018 数据集上的准确率达到 82.01%。

除 MTL 以外，大多数模型在 CCL2018 上面表现优于在 VUA 数据集上的结果，原因在于 CCL2018 的数据全部为易于分析的明喻。而 VUA 数据集则涵盖了更为复杂的隐喻表达，对模型准确捕获隐喻特征的能力提出了更高的要求。MTL 从隐喻识

别和情感预测联合学习中相互受益，证明了将隐喻模型纳入情感相关任务中是有益的。ChatGPT 模型在两个基准数据集上表现优异，特别是在 CCL2018 数据集上准确率和 F-macro 值分别达到了 80.54%和 79.53%。然而，在 VUA 数据集的复杂场景下，其准确率仅为 74.48%。相比之下，本文模型在更大规模且复杂的 VUA 隐喻任务上展现了敏锐的洞察力和出色的处理能力，准确率和 F1 分数分别提升了 6.69%和 5.68%。

表 4.3 对比实验结果（“-”表示该研究未公开结果与实现方式，每个数据集的最佳结果以粗体显示）。

模型	CCL2018		VUA	
	Acc (%)	F1 (%)	Acc (%)	F1 (%)
MTL	-	72.23	76.30	60.40
RoBERTa	74.31	71.29	70.09	66.93
TRAT-LSTM	67.80	67.70	56.80	66.40
DASR	80.65	-	77.72	-
CDKI	76.32	72.89	70.93	68.37
ChatGPT	80.54	79.53	74.48	73.31
LSTM+CNN+RF	78.00	75.00	73.80	74.00
CoT-CMMSA	82.01	80.68	81.62	78.99

综合实验结果表明，融合视觉和声音等多模态特征的方法通过共享不同模态的特征，在处理复杂隐喻数据时展现出高效性，能够有效提升隐喻文本的情感分类准确率，也为处理此类隐喻情感分析任务提供了新的可能性和方法。

4.3.5 消融实验

在本节中，对 CoT-CMMSA 进行了以下消融实验，以进一步探索本文模型中每个模块的功能。

（1）多模态特征融合模块的影响

通过在 CCL2018 和 VUA 数据集上进行一系列消融实验，深入探讨了多模态特

征融合策略对隐喻情感分析的影响。实验结果如表 4.4 所示。

表 4.4 多模态特征融合方法对 CoT-CMMSA 的影响

特征	CCL2018		VUA	
	Acc (%)	F1 (%)	Acc (%)	F1 (%)
T	62.65	60.12	60.58	59.64
A	48.57	44.17	43.27	42.54
V	54.26	51.71	51.38	49.80
V, A→L	72.77	70.50	70.46	68.13
V, L→A	60.54	59.53	60.12	60.05
A, L→V	64.38	61.74	62.65	60.23
CMMSA (w/o CoT)	79.15	76.36	74.62	72.48
CoT-CMMSA	82.01	80.68	81.62	78.99

首先，使用单模态作为输入时，文本模态表现最好，其次是视觉模态，语音模态的表现相对较弱，这可能是因为语音特征受到背景噪声等因素影响。在非言语层面理解情感时，面部表情与声调等单一信息通常难以提供足够的情感识别依据。从实验数据中可以看到文本信息对情感分析的贡献最大，这得益于丰富的情感词汇使其成为多模态融合过程中的关键因素。

其次，评估了不同模态特征组合的性能。具体来说，主要考虑了三种组合方式：（V,A→L）表示视觉和语音特征映射至文本主模态进行融合；（L,A→V）表示文本和语音特征映射至视觉主模态进行融合；（L,V→A）表示文本和视觉特征映射至语音主模态进行融合。结果表明，（V,A→L）的表现明显优于其他两种组合，引入其他模态特征不仅可以增强单一模态特征，同时通过信息互补能够有效地融入更多差异信息。值得注意的是，以文本模态作为融合的关键，视觉和语音模态的表现也得到了显著提升，在两个数据集上的准确率分别平均提高了 14.41%和 10.47%。这说明文本模态在多模态特征中的主导地位，验证了所提出特征融合方法的有效性。

此外，还验证了模型去除 CoT 指导 GPT-3.5 生成强化文本方法 CMMSA（w/o CoT）的有效性。可以看到在模态数量相同的情况下，CoT-CMMSA 在 CCL2018 数据集上的准确率达到 82.01%，比 CMMSA（w/o CoT）提高了近 3%。这说明删除

文本增强模块会损害模型的性能。

综上所述，包含文本增强模块的 CoT-CMMSA 模型在隐喻情感分析中表现出更高的准确性和有效性。

(2) 隐喻识别模型对隐喻情感分析性能影响的评估

为了评估 ChatGPT-3.5 模型在隐喻识别方面的性能，本文将其与 ChatGPT-2 和 RoBERTa 模型进行了对比，并在 VUA 数据集上测试其性能。主要使用 ACC 和 F1 值作为评估指标。实验结果如表 4.5 所示。

表 4.5 隐喻识别模型对隐喻情感分析性能影响的评估

模型	VUA	
	Acc (%)	F1 (%)
GPT-3.5 (CoT)	82.54	80.14
RoBERTa	84.01	81.27
GPT-2	79.19	76.58

实验结果表明，RoBERTa 模型在隐喻识别任务的整体性能上表现最佳，准确率和 F1 值分别为 84.01%和 81.27%。这主要归功于 RoBERTa 在训练过程中使用了大量外部数据和词性标注等辅助信息，以准确预测隐喻标签。相比之下，GPT-3.5 作为生成式大模型，其优势在于自然语言的生成与语义理解，而非特定任务的优化，虽然 GPT-3.5 在隐喻识别上未达到 RoBERTa 的精度，但其在不依赖外部知识库的情况下，引入 COT 逐步推理技术进行简单微调后，准确率仅比 RoBERTa 低 1.47%，展现出强大的竞争力。这一结果充分证明了 GPT-3.5 具有较强的通用语言理解能力，通过 COT 技术可以有效分解复杂的语言结构，生成更丰富的隐喻解释。相比之下，GPT-2 的表现较差。GPT-3.5 (CoT) 比 GPT-2 有了实质性的改进，准确率提高了 3.35%。

综上所述，虽然 GPT-3.5 在复杂隐喻识别方面表现有所不足，但其高效的处理能力在许多应用场景中表现出色，尤其在简化识别过程和提高扩增句子质量方面表现优异。

(3) Stable Diffusion 与 Grad-TTS 对情感增强的作用评估

为了验证 SD 和 Grad-TTS 在隐喻情感分析中的贡献，我们在 TIE 过程获得 COT

生成的增强文本之后进行了实验，结果如表 4.6 所示。从表中可以明显看出，联合使用 SD 和 Grad-TTS 模型取得了最佳表现。当模型仅依赖 COT 增强文本与原隐喻文本时，准确率仅为 69.91%，表现最差。这表明在隐喻中，情感常通过多层次、多维度的方式传达，单一文本难以充分表达复杂的情感信息。相比之下，当模型加入 Grad-TTS 生成的语音信息时，准确率提升至 76%。尽管文本和语音信息的结合丰富了数据维度，但缺少视觉模态仍然限制了模型对情感的全面理解。在 SD 模型生成图像的辅助下，模型融合 COT 增强文本与原隐喻文本，相较于使用 Grad-TTS 语音特征进行融合时的准确率提高了 2.53%。视觉模态通过提供与文本匹配的视觉线索，有助于模型更深入地理解情感。但与联合使用 SD 与 Grad-TTS 模型相比，语音模态的缺失仍然会导致模型性能下降，特别是在隐喻情感的细微层次表达方面，语音特征（如语调、语速）都会影响模型性能。

实验结果表明，单一文本特征在处理复杂情感时存在局限性。通过联合使用 SD 与 TTS 模型，利用隐含背景知识生成图像和语音信息，能够丰富文本语义特征，提升隐喻情感分析的准确率。

表 4.6 Stable Diffusion 与 Grad-TTS 对情感增强的作用评估

模型	CCL2018	
	Acc (%)	F1 (%)
SD (×) Grad-TTS (×)	69.91	69.80
SD (×) Grad-TTS (✓)	76.00	75.24
SD (✓) Grad-TTS (×)	78.53	76.15
SD (✓) Grad-TTS (✓)	82.01	80.68

（4）生成文本长度对冗余信息量和准确率的影响

在使用 GPT-3.5 增强隐喻文本的过程中，生成文本长度是影响模型性能的关键因素。为了确定最佳生成文本长度，在 CCL2018 数据集上进行了实验。其中生成文本长度范围设定为 0 字至 120 字，通过对比不同文本长度下模型生成文本的冗余信息量及准确率，评估其对模型性能的影响。冗余信息量是指生成文本中出现超出核心情感或意义的多余信息，如重复词汇、无关短语等。准确率则衡量模型在情感分析任务中的性能。

如图 4.5 所示, 当文本输出长度阈值设置为 60 个字符时, 模型的表现最佳。在 45 字到 60 字之间, 准确率趋于平缓上升, 在 60 字时达到峰值, 准确率约为 82%。此时生成的文本在冗余信息和准确率之间达到最佳平衡, 包含的错误信息最少。随着文本长度的增加, 冗余信息量呈线性增长趋势, 模型的准确率明显下降。当文本长度达到 120 字时, 准确率下降到约 43%。生成的文本越长, 包含的不必要或重复信息越多, 潜在的增加了不相关或错误信息的风险。

因此, 文本长度设置为 60 个字符能够生成高质量文本, 避免额外噪声的产生, 同时提高模型准确率并增加情感表达的丰富性。此参数的最优化有助于模型在隐喻情感分析任务中保持高准确率, 减少由于信息冗余引起的误判。然而, 文本的长度可能依赖于具体的数据集和任务类型, 在不同数据集上还需进一步验证。




图 4.5 生成文本长度对冗余信息的影响

4.3.6 案例研究

(1) 使用思维链提示提升 LLMs 与扩散模型图像生成质量的案例研究

为了更直观地理解通过 LLMs 和基于扩散的文本到图像模型的协作如何提升生成图像的质量。本文比较了使用 CoT 提示指导 LLMs 协作的 SD 与直接使用 SD 生成的图像。表 4.7 展示了几个使用原始隐喻文本或其视觉阐述作为 Stable Diffusion 输入生成的图像示例。

例如, 对于“法庭上的狐狸”这一隐喻表达, 其隐含意思是通过狐狸以拟人化的形象将狡猾或智慧的姿态描绘在法庭中的场景。然而, SD 生成的图像仅显示了一只狐狸在法庭的简化画面, 没有传达隐喻的深层含义。使用 CoT 提示可以解决这个

问题，生成更具象征意义的图像。如左图所示。对于案例8“教室是一个动物园”，SD 在转换为视觉图像时，仅直译为“一个教室里坐着斑马和长颈鹿”，未能捕捉到“混乱”这一关键隐喻意义。经过优化文本提示后，我们得到了更符合原意的图像“课堂上，孩子们和各种动物一样四处乱窜，老师感到无奈”。我们发现，输出图片不准确的原因可能是模型无法正确识别和描述隐喻。例如，对于“石油是工业的血脉”这个隐喻，提示应描述为“在一个工业区内，管道密布，管道中流动着红色液体，穿过发电厂等设施，这些设施像人体器官一样依赖管道中的‘血液’维持运转”。暗含石油如同血液一样维持着工业的运转和生命力。然而，SD 模型无法理解“血液”一词，认为其不符合语境，因此在生成过程中直接忽略。这影响了我们对隐喻的正确理解。

实验结果表明，使用 CoT 提示生成隐喻的详细说明，能够显著提升基于扩散的文本到图像模型的生成质量。总体来看，LLM-SD 模型表现最佳，带有 CoT 提示的 GPT-3.5 生成的视觉阐述作为输入，比直接使用原始隐喻文本显著提高了模型性能，验证了我们方法的有效性。

表 4.7 使用 GPT-3.5 与思维链提示(左)或原始的隐喻文本(右)生成的相应图像示例

	SD(CoT)	SD
案例 1: 法庭上的狐狸		
案例 2: 教室是一个动物园		

（2）语音特征对模型性能提升的作用

为了验证引入语音特征对情感分析的有效性，我们通过表 4.8 中的三个案例对比了加入语音特征前后的表现。表中的“标签”列，代表当前文本的真实标签值。

案例 1 中，文本包含“憧憬”“拨云见日”等词语，生成图像中的阳光显示出积极情绪。然而，仅依赖这些文本和视觉特征，模型错误地识别为积极情绪。引入语音特征后，模型正确地识别了消极情绪，说明语音特征有助于捕捉文本和视觉特征之间的潜在不一致性。在案例 2 中，文本中的“淹没”一词提供了误导信息，图像也未能准确识别情绪，导致模型错误地识别为消极情绪。引入语音特征后，模型正确地识别为积极情绪，说明语音特征在文本难以分析、图像情感强度较弱时，能够提供有效的补充信息，流畅的语调更能反映真实的情感。

综上所述，引入语音特征能够显著提高情感分析模型的准确性，特别是在处理复杂隐喻情感时，效果更加显著。

表 4.8 CCL2018 数据集的案例

	标签	T	V	A	T+V	T+V+A
案例 1	消极	她对明日的憧憬似乎 拨云见日，然而总被 新的云层笼罩。			积极	消极
案例 2	积极	他被淹没在音乐海 洋。			消极	积极

4.4 本章小结

本文提出了一种使用思维链提示指导 LLMs 进行中文隐喻情感分析的多模态方法。与所有现有方法不同，该模型基于提示链指导 GPT-3.5 生成新数据，增强隐喻文本语义，并结合生成模型从图像与语音中提取情感特征，进行渐进式多模态融合。该方法充分考虑了不同模态的异质性和同质性，能够更好地理解隐喻情感的复杂性，并有效减少了错误信息的干扰。在 CCL2018 和 VUA 数据集上的实验结果验证了模型的有效性。

然而，隐喻作为一种特殊的比喻语言形式，包含多种类别，在缺乏对隐含意义

详细解释的情况下，生成视觉隐喻仍有很大的改进空间。未来，我们将探索更多句子增强方法，以更全面地分析和处理各种形式的比喻语言。此外，由于英汉两种语言的认知、文化和句法结构上的差异，可能导致相同隐喻词语义的不同。未来工作将从多个角度识别英汉隐喻句差异，提高模型的普适性。

5 结论与展望

5.1 结论

随着自媒体时代和互联网的快速发展,信息传播的方式发生了显著变化。如今,网络上每天涌现出大量的视频、图片和语音信息,文本已不再是用户沟通的主流方式。隐式情感表达作为人类情感表达的重要形式之一,具有隐晦和含蓄等特点,相同的隐式情感表达在不同用户之间可能具有不同的情感倾向,这使得隐式情感分析在心理治疗、网络舆情监测等领域具有广泛的应用价值。因此,隐式情感分析成为一项具有重要意义的研究课题。尽管隐式情感文本分类已经得到越来越多的关注,但由于隐式情感特征与显式情感特征之间存在较大差异,其表达方式往往更加微妙,现有模型难以准确提取有效特征。传统的单模态文本处理方法已难以应对日益复杂的多模态数据分析需求。本文主要研究的是基于多模态数据的隐式文本的情感分类任务,探讨如何通过多模态信息的融合提高隐式情感分析的准确性与鲁棒性。

本文的主要研究工作包括以下几个方面:

(1) 首先,阐述了本论文的研究背景以及本课题的研究意义,并简要分析了国内外隐式情感分析的进展与现有研究成果。然后,系统梳理了隐式文本情感分类任务中使用的相关理论基础和深度学习技术,包括 BiLSTM 模型和 BERT 预训练模型和 GPT 模型等。此外,本文还总结分析了多模态特征融合在隐式情感分析中相较于单模态文本情感分析的优势。

(2) 针对现有隐式情感分析方法存在模态单一性以及未能充分挖掘和融合多模态信息等问题,提出了一种基于多模态融合的隐式情感分析模型,通过从语音、视频中提取与文本相关的语音和视觉特征,辅助理解隐式情感。该模型利用多头互注意力机制,探索模态内部的依赖关系和不同模态间的信息关联性,有效降低非文本模态的低阶冗余信息。此外,不同模态特征对情感预测所做的贡献不同,使用以文本为中心的交叉注意力机制,可以帮助模型缓解模态异质性问题,辅助增强隐式文本特征表示,从而提高模型分类的准确性。最后在 CMU-MOSI、CMU-MOSEI、CMSIED 数据集上的实验结果验证了所提方法在隐式情感分类任务中的有效性。

(3) 隐喻作为一种特殊的隐式情感表达方式,现有的隐喻情感分析方法未能深入探索多模态隐喻内在的复杂性以及充分地理解视觉、语音隐喻之间的紧密关联,

难以准确捕捉隐喻中的复杂情感意图。为此，提出一种基于思维链提示结合生成模型，并融合图像和语音情感特征来推理隐喻情感的方法。首先，通过思维链提示指导模型生成丰富的文本信息，并利用生成模型逐步生成与文本对应的相关视觉和语音信息，从图像与语音中提取情感特征，弥补单一文本在情感表达上的不足。其次，使用多头交互注意力机制，在保持各模态独立性的基础上，有效融合其他模态的相关语义情感信息，从而增强单模态特征的表达能力。最后，利用跨模态交叉注意力机制对三种强化后的单模态特征进行深度融合，减少低级特征对文本特征的干扰，优化多模态融合表示。在 CCL2018 和 VUA 数据集上的实验结果表明，该方法能够有效捕捉多模态特征间的隐喻关联，从而显著提升模型分类的准确率。

5.2 工作展望

本研究虽然在提高隐式情感分类的准确率上有所进展，但模型性能仍存在改进空间，后续还需进一步优化。未来可以从以下方面进行研究：

（1）目前公开的隐式多模态数据集较为匮乏，本文实验基于本研究所创建的多模态隐式情感数据集进行，但由于人工标注情感极性所需的时间和成本较高，该数据集的涵盖范围有限。未来的研究考虑整合搜索引擎、论坛、新闻等多源数据扩展现有数据集。此外，还可在其他相关领域语料库进行训练和测试，以进一步验证和提升模型的泛化能力和性能。

（2）鉴于现实生活中的情感表达不仅限于积极、消极和中性三种基本分类，还包括愤怒、恐惧、沮丧、兴奋等多种细分情感。因此，未来的研究应着重于更细致的情感分类方法，深入分析隐式文本中的复杂情感表达，以提高隐式情感分析的精度和多样性。

（3）目前的研究主要集中在对文本数据的情感分析，对其他类型数据的处理较少。未来研究考虑加入更多模态信息，如动作、手势、面部表情、生理信号等，从多个维度来更全面地捕捉和理解隐式情感，构建更加鲁棒、可靠的情感分析模型。

（4）尽管现有模型在隐式情感分析中取得了一定成效，但不同模态之间的信息融合的深度和精度仍有待提升，未来将探索新的融合策略，增强模型对复杂情感表达的理解和识别能力。尤其是隐喻等特殊隐式情感的分析，可以结合语义理解、情境推理等技术提高模型处理隐式情感时的准确性和实用性，从而更好地解决实际应用场景中的挑战，推动隐式情感分析技术进一步的发展。

参考文献

- [1] 第 55 次《中国互联网络发展状况统计报告》发布[J]. 传媒论坛, 2025, 9(02):1 21.
- [2] 韩坤, 潘宏鹏, 刘忠轶. 融合 BERT 多层次特征的短视频网络舆情情感分析研究[J]. 计算机科学与探索, 2024, 18, (4): 1010-1020.
- [3] Hu R P, Lu L, Zeng P, et al. Text sentiment analysis: A review[C]//4th IEEE International Conference on Computer and Communications, ICCC 2018. 2018:2283-2288.
- [4] Liu B. Sentiment analysis and opinion mining[M]. Springer Nature, 2022.
- [5] Liao J, Wang S, Li D. Identification of fact-implied implicit sentiment based on multi-level semantic fused representation[J]. Knowledge-Based Systems, 2019, 165(FEB.1):197-207.
- [6] Wan Y J, Chen Y Z, Lin J L, et al. A knowledge-augmented heterogeneous graph convolutional network for aspect-level multimodal sentiment analysis[J]. Computer speech & language, 2024, 85(Apr.):101587.1-101587.19.
- [7] He A, Abisado M. Text sentiment analysis of Douban film short comments based on bert-cnn-bilstm-att Model[J]. IEEE Access, 2024, 12, 45229-45237.
- [8] Zhang H C, Ai G J. An image text sentiment analysis method using bimodal attention mechanism[J]. Journal of Circuits Systems and Computers, 2024.
- [9] Xu M H, Wang D L, Feng S, et al. KC-ISA: An implicit sentiment analysis model combining knowledge enhancement and context features[C]//29th International Conference on Computational Linguistics, COLING 2022. 2022:6906-6915.
- [10] 李继东, 王移芝. 基于扩展词典与语义规则的中文微博情感分析[J]. 计算机与现代化, 2018, (2):89-95.
- [11] Irfan R, Khalid O, Khan M U S, et al. SocialRec: A context-aware recommendation framework with explicit sentiment analysis[J]. IEEE Access, 2019.
- [12] 张财, 马自强, 闫博. 基于机器学习的政务微博情感分析模型设计[J]. 计算机工程, 2024, 50, (12): 386-395.
- [13] Xu W, Chen J, Ding Z, et al. Text sentiment analysis and classification based on bidirectional gated recurrent units (grus) model[J]. arXiv preprint arXiv:2404.17123, 2024.

- [14] He A, Abisado M. Text sentiment analysis of Douban film short comments based on BERT-CNN-BiLSTM-Att model[J]. Ieee Access, 2024.
- [15] Jiang W, Zhou K, Xiong C, et al. KSCB: A novel unsupervised method for text sentiment analysis[J]. Applied Intelligence, 2023, 53(1): 301-311.
- [16] Nam K. Korean Aspect-Based sentiment analysis via implicit-feature alignment with corpus filtering. arXiv preprint arXiv:2407.00342.
- [17] Greene S, Resnik P. More than words: syntactic packaging and implicit sentiment[C]//Proceedings of human language technologies: The 2009 annual conference of the north American chapter of the association for computational linguistics. 2009: 503-511.
- [18] Graves A, Jaitly N, Mohamed A. Hybrid speech recognition with deep bidirectional lstm[C]//2013 IEEE workshop on automatic speech recognition and understanding. IEEE, 2013: 273-278.
- [19] Zhou D, Wang J, Zhang L, et al. Implicit sentiment analysis with event-centered text representation[C]//Proceedings of the 2021 conference on empirical methods in natural language processing. 2021: 6884-6893.
- [20] 张益阳. 融合多模态常识知识的反事实类隐式情感分析研究与应用[D]. 山西: 山西大学, 2024.
- [21] Forceville C, Urios-aparisi E. Multimodal metaphor[M]. Walter de Gruyter, 2009.
- [22] Shutova E, Kiela D, Maillard J. Black holes and white rabbits: Metaphor identification with visual features[C]//Proceedings of the 2016 conference of the North American chapter of the association for computational linguistics: Human language technologies. 2016: 160-170.
- [23] Chen M, Ubol K, Xu X, et al. Connecting text classification with image classification: a new preprocessing method for implicit sentiment text classification[J]. Sensors, 2022, 22(5): 1899.
- [24] Lakoff G, Johnson M. Metaphors we live by chicago: university of chicago press 1980[J]. Afterword, 2003.
- [25] Willks Y. A preferential, pattern-seeking, semantics for natural language inference[J]. Artificial intelligence, 1975, 6(1): 53-74.

- [26] Rentoumi V. Sentiment analysis of metaphorical language[D]. University of the Aegean, Greece, 2012.
- [27] Touahri I, Mazroui A. Enhancement of a multi-dialectal sentiment analysis system by the detection of the implied sarcastic features[J]. Knowledge-Based Systems, 2021, 227: 107232.
- [28] Gao G, Choi E, Choi Y, et al. Neural metaphor detection in context[C]//Conference on Empirical Methods in Natural Language Processing (EMNLP). 2018: 607-613.
- [29] Liu J, O'hara N, Rubin A, et al. Metaphor detection using contextual word embeddings from transformers[C]//Proceedings of the Second Workshop on Figurative Language Processing. 2020: 250-255.
- [30] Yang L, Zeng J, Li S, et al. Metaphor recognition and analysis via data augmentation[C]//Natural Language Processing and Chinese Computing: 10th CCF International Conference, NLPCC 2021, Qingdao, China, October 13–17, 2021, Proceedings, Part I 10. Springer International Publishing, 2021: 746-757.
- [31] Mao R, Li X, Ge M, et al. MetaPro: A computational metaphor processing model for text pre-processing[J]. Information Fusion, 2022, 86: 30-43.
- [32] Ng N, Cho K, Ghassemi M. SSMBA: Self-supervised manifold based data augmentation for improving out-of-domain robustness[C]//Conference on Empirical Methods in Natural Language Processing (EMNLP). 2020:1268-1283.
- [33] Huang H, Tang C, Loakman T, et al. Improving Chinese story generation via awareness of syntactic dependencies and semantics[J]. arXiv preprint arXiv:2210.10618, 2022.
- [34] Su J. Simbert: Integrating retrieval and generation into bert[J]. Tech. Rep., 2020.
- [35] Zheng D, Song R, Hu T, et al. “Love is as complex as math”: Metaphor generation system for social chatbot[C]//Chinese Lexical Semantics: 20th Workshop, CLSW 2019, Beijing, China, June 28–30, 2019, Revised Selected Papers 20. Springer International Publishing, 2020: 337-347.
- [36] Wachowiak L, Gromann D. Does GPT-3 grasp metaphors? identifying metaphor mappings with generative language models[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023: 1018-1032.

- [37] Lewis M, Liu Y, Goyal N, et al. Bart: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension[C]//58th Annual Meeting of the Association for Computational Linguistics, ACL 2020.2020:7871-7880.
- [38] Wachowiak L, Gromann D. Does GPT-3 grasp metaphors? identifying metaphor mappings with generative language models[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023: 1018-1032.
- [39] Amin M M, Mao R, Cambria E, et al. A wide evaluation of ChatGPT on affective computing tasks[J]. IEEE Transactions on Affective Computing, 2024.
- [40] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in neural information processing systems, 2022, 35: 24824-24837.
- [41] Sharma C, Bhageria D, Scott W, et al. SemEval-2020 Task 8: Memotion analysis -the visuo-lingual metaphor![C]//14th International Workshops on Semantic Evaluation, SemEval 2020.2020:759-77.
- [42] Zhang Y, Jia A, Wang B, et al. M3GAT: A multi-modal, multi-task interactive graph attention network for conversational sentiment analysis and emotion recognition[J]. ACM Transactions on Information Systems, 2023, 42(1): 1-32.
- [43] He X, Yu L, Tian S, et al. VIEMF: Multimodal metaphor detection via visual information enhancement with multimodal fusion[J]. Information Processing & Management, 2024, 61(3): 103652.
- [44] Liu Y, Shen T, Zhang D, et al. Comment-aided video language alignment via contrastive pre-training for short-form video humor detection[C]//Proceedings of the 2024 International Conference on Multimedia Retrieval. 2024: 442-450.
- [45] Steen G, Dorst A G, Herrmann J B, et al. A method for linguistic metaphor identification[J]. Amsterdam: Benjamins, 2010.
- [46] Nozza D, Fersini E, Messina E. A multi-view sentiment corpus[C]//Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 1, Long Papers. 2017: 273-280.
- [47] Kozareva Z. Multilingual affect polarity and valence prediction in metaphor-rich

- texts[C]//Proceedings of the 51st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2013: 682-691.
- [48] Nozza D, Fersini E, Messina E. A multi-view sentiment corpus[C]//Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 1, Long Papers. 2017: 273-280.
- [49] Zhang D, Lin H, Yang L, et al. Construction of a Chinese corpus for the analysis of the emotionality of metaphorical expressions[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers). 2018: 144-150.
- [50] <https://www.biendata.xyz/competition/smpecisa2019/>.
- [51] Lu Y, Sakamoto K, Shibuki H, et al. Construction of a multilingual annotated corpus for deeper sentiment understanding in social media[J]. Information and Media Technologies, 2017, 12: 111-171.
- [52] Steen, Gerard J, et al. Visual metaphor: Structure and process[M]. John Benjamins Publishing Company, 2018.
- [53] Zhang D, Zhang M, Zhang H, et al. Multimet: A multimodal dataset for metaphor understanding[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). 2021: 3214-3225.
- [54] Mikolov, Tomas, Chen, Kai, Corrado, Greg, et al. Efficient estimation of word representations in vector space[C]//1st International Conference on Learning Representations, ICLR 2013. 2013.
- [55] Malik, Muhammad Shahid Iqbal, Nawaz, Aftab, Jamjoom, Mona Mamdouh, et al. Effectiveness of ELMo embeddings, and semantic models in predicting review helpfulness[J]. intelligent data analysis, 2024, 28, (4):1045-1065.
- [56] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//31st Annual Conference on Neural Information Processing Systems (NIPS). 2017:5999-6009.
- [57] Baeveski A, Zhou H, Mohamed A, et al. wav2vec 2.0: A framework for self-supervised Learning of speech representations[J]. 2020.
- [58] Eyben F, Wöllmer M, Schuller B. Opensmile: the munich versatile and fast open-source

- audio feature extractor[C]//Proceedings of the 18th ACM International Conference on Multimedia, 2010: 1459-1462.
- [59] Degottex G, Kane J, Drugman T, et al. A collaborative voice analysis repository for speech technologies[C]//International Conference on Acoustics, Speech and Signal Processing, IEEE, 2014, 25: 960-964.
- [60] Mcfee B, Raffel C, Liang D, et al. Librosa: audio and music signal analysis in python[C]//Proceedings of the 14th python in science conference. 2015, 8: 18-25.
- [61] Ji S, Xu W, Yang M, et al. 3D convolutional neural networks for human action recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2012, 35(1): 221-231.
- [62] Anderson P, He X, Buehler C, et al. Bottom-up and top-down attention for image captioning and visual question answering [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6077-6086.
- [63] Baltrusaitis T, Zadeh] A, Lim Y C, et al. Open-face 2.0: Facial behavior analysis toolkit[C]//2018 13th IEEE international conference on automatic face & gesture recognition (FG 2018). IEEE, 2018: 59-66.
- [64] 张亚洲, 王梦遥, 戎璐等. ChatGPT 可否充当情感专家?——调查其在情感与隐喻分析的潜力[J]. 北京大学学报(自然科学版), 2024, 60, (1):43-52.
- [65] Rombach R, Blattmann A, Lorenz D, et al. High-resolution image synthesis with latent diffusion models[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10684-10695.
- [66] Rezende D J, Mohamed S. Variational inference with normalizing flows[C]//32nd International Conference on Machine Learning, ICML 2015. 2015:1530-1538.
- [67] Yamamoto R, Song E, Kim J M. Parallel WaveGAN: A fast waveform generation model based on generative adversarial networks with multi-resolution spectrogram[C]//International Conference on Acoustics, Speech, and Signal Processing. IEEE, 2020:6199-6203.
- [68] Popov V, Vovk I, Gogoryan V, et al. Grad-tts: A diffusion probabilistic model for text-to-speech[C]//International Conference on Machine Learning. PMLR, 2021: 8599-8608.
- [69] Rombach R, Blattmann A, Lorenz D, et al. High-resolution image synthesis with latent

- diffusion models[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10684-10695.
- [70] 周欢. 基于隐喻特征的多模态情感分析[D]. 大连理工大学, 2023.
- [71] 冯亚琴, 沈凌洁, 胡婷婷, 等. 利用语音与文本特征融合改善语音情感识别[J]. 数据采集与处理, 2019, 34,(4): 625-631.
- [72] 范习健, 杨绪兵, 张礼, 等. 一种融合视觉和听觉信息的双模态情感识别算法[J]. 南京大学学报 (自然科学版), 2021, 57(2): 309-317.
- [73] Zhang K, Zhang Z, Li Z, et al. Joint face detection and alignment using multitask cascaded convolutional networks[J]. IEEE signal processing letters, 2016, 23(10): 1499-1503.
- [74] Zadeh A, Zellers R, Pincus E, et al. Multimodal sentiment intensity analysis in videos: facial gestures and verbal messages[J]. IEEE Intelligent Systems, 2016, 31(6):82-88.
- [75] Zadeh A A B, Liang P P, Poriao S, et al. Multi-modal language analysis in the wild: Cmu-mosei dataset and interpretable dynamic fusion graph[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2018: 2236-2246.
- [76] Poria S, Cambria E, Hazarika D, et al. Context-dependent sentiment analysis in user-generated videos[C]//Proceedings of the 55th annual meeting of the association for computational linguistics (volume 1: Long papers). 2017: 873-883.
- [77] Chen M, Li X. Swafn: Sentimental words aware fusion network for multimodal sentiment analysis[C]//Proceedings of the 28th international conference on computational linguistics. 2020: 1067-1077.
- [78] Wang L, Peng J, Zheng C, et al. A cross modal hierarchical fusion multimodal sentiment analysis method based on multi-task learning[J]. Information Processing & Management, 2024, 61(3): 103675.
- [79] 孙杰, 车文刚, 高盛祥. 面向多模态情感分析的多通道时序卷积融合[J/OL]. 计算机科学与探索, 2024: 1-11.
- [80] Hu G, Lin T E, Zhao Y, et al. Unimse: Towards unified multimodal sentiment analysis and emotion recognition[J]. arXiv preprint arXiv:2211.11256, 2022.
- [81] Cai S, Yuan J, Li L. A mutual implicit sentiment analysis model with bundle-aware

- contrastive learning[C]//ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
- [82] Chen M, Ubul K, Xu X, et al. Connecting text classification with image classification: a new preprocessing method for implicit sentiment text classification[J]. Sensors, 2022, 22(5): 1899.
- [83] Magana D. Cultural competence and metaphor in mental healthcare interactions: A linguistic perspective[J]. Patient education and counseling, 2019, 102(12): 2192-2198.
- [84] 张声龙, 刘颖, 马艳军. SaGE:基于句法感知图卷积神经网络和 ELECTRA 的中文隐喻识别模型[J]. 中文信息学报, 2024, 38(03):24-32.
- [85] 杨春霞, 韩煜, 桂强等. 融合 RoBERTa-GCN-Attention 的隐喻识别与情感分类模型[J]. 小型微型计算机系统, 2023.
- [86] Xu B, Li T, Zheng J, et al. Met-meme: A multimodal meme dataset rich in metaphors[C]//Proceedings of the 45th international ACM SIGIR conference on research and development in information retrieval. 2022: 2887-2899.
- [87] Zhu D, Chen J, Shen X, et al. Minigpt-4: Enhancing vision-language understanding with advanced large language models[C]//12th International Conference on Learning Representations, ICLR 2024.
- [88] Chakrabarty T, Saakyan A, Winn O, et al. I spy a metaphor: Large language models and diffusion models co-create visual metaphors[C]//61st Annual Meeting of the Association for Computational Linguistics, ACL 2023.2023:7370-7388.
- [89] Li C, Li Y. Research on Automatic Recognition of Metaphorical Sentence Types in Modern Chinese[C]//Proceedings of the 8th International Conference on e-Society, e-Learning and e-Technologies. 2022: 26-29.
- [90] Li Y, Lin C, Geurin F. Nominal metaphor generation with multitask learning[C]//15th International Natural Language Generation Conference, INLG 2022. 2022: 225-235.
- [91] Steen G J, Dorst A G, Herrmann J B, et al. A method for linguistic metaphor identification[M]. Amsterdam: John Benjamins Publishing Company, 2010.
- [92] Dankers V, Rei M, Lewis M, et al. Modelling the interplay of metaphor and emotion through multitask learning[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on

- Natural Language Processing (EMNLP-IJCNLP). 2019: 2218-2229.
- [93] Nandwan P, Verma R. A review on sentiment analysis and emotion detection from text[J]. Social network analysis and mining, 2021, 11(1): 81.
- [94] Peng Y, Su C, Chen Y. Chinese metaphor sentiment analysis based on attention-based LSTM[C]//2018 Tenth International Conference on Advanced Computational Intelligence (ICACI). IEEE, 2018: 478-483.
- [95] Yang L, Zeng J, Li S, et al. Metaphor recognition and analysis via data augmentation[C]//Natural Language Processing and Chinese Computing: 10th CCF International Conference, NLPCC 2021, Qingdao, China, October 13–17, 2021, Proceedings, Part I 10. Springer International Publishing, 2021: 746-757.
- [96] Zhang D, Yu J, Jin S, et al. MultiCMET: A novel Chinese benchmark for understanding multimodal metaphor[C]//Findings of the Association for Computational Linguistics: EMNLP 2023. 2023: 6141-6154.
- [97] Zhang D, Zhang M, Guo T, et al. In your face: Sentiment analysis of metaphor with facial expressive features[C]//2021 International Joint Conference on Neural Networks (IJCNN). IEEE, 2021: 1-8.