

数据与计算发展前沿

Frontiers of Data & Computing

ISSN 2096-742X, CN 10-1649/TP

《数据与计算发展前沿》网络首发论文

题目：零样本语音合成技术研究进展
作者：王丹琳，唐云祁
收稿日期：2025-08-11
网络首发日期：2025-10-11
引用格式：王丹琳，唐云祁. 零样本语音合成技术研究进展[J/OL]. 数据与计算发展前沿.
<https://link.cnki.net/urlid/10.1649.tp.20251011.1124.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

零样本语音合成技术研究进展

王丹琳^{1,2}, 唐云祁^{2*}

1. 北京警察学院, 刑事科学技术系, 北京 102202

2. 中国人民公安大学, 侦查学院, 北京 100038

摘要:【目的】综述零样本语音合成技术研究现状与趋势, 分析该技术在自然度、逼真度和多样性提升中的问题与挑战。【文献范围】基于 2021-2025 年国内外发表的相关学术论文, 检索并分析涵盖不同模型架构、任务和应用场景的研究成果。【方法】介绍了零样本语音合成技术的定义和核心特征, 从深度学习生成模型架构出发, 对现有主流的端到端零样本语音合成模型进行分类, 并对代表性方法进行对比分析。【结果】总结近年代表性方法在语音自然度、说话人相似度、多语言适应性与表达能力方面的进展, 指出生成式人工智能与大语言模型的发展推动了跨语言迁移、上下文学习和多模态生成的新趋势, 同时发现跨说话人迁移、情感与风格控制、多样性等仍存不足。【结论】未来应进一步提升高保真与强表现力的语音生成能力, 加强对情感、语体和风格等属性的建模, 增强跨语言与跨说话人的泛化能力, 同时兼顾轻量化与实时性, 并探索大语言模型驱动的多模态一体化生成框架。

关键词: 语音合成; 零样本; 非自回归模型; 自回归模型; 混合模型; 大语言模型

Advances in Zero-Shot Text-to-Speech Technology

WANG Danlin^{1,2}, TANG Yunqi^{2*}

1. Department of Criminal Science and Technology, Beijing Police College, Beijing 102202, China

2. School of Investigation, People's Public Security University of China, Beijing 100038, China

Abstract:【Purpose】This paper reviews the current research status and development trends of zero-shot Text-to-Speech (Zero-shot TTS), and analyzes the challenges faced by this technology in improving naturalness, fidelity, and diversity.【Scope】The review is based on relevant academic publications from 2021 to 2025, covering studies on different model architectures, tasks, and application scenarios.【Methods】The definition and core characteristics of Zero-shot TTS are introduced, and existing mainstream end-to-end Zero-shot TTS models are classified according to deep learning generative architectures. Representative methods are compared and analyzed. 【Results】Recent advances are summarized in terms of speech naturalness, speaker similarity, multilingual adaptability, and expressive capacity. It is highlighted that the development of generative AI and large language models (LLMs) has promoted new trends in cross-lingual transfer, in-context learning, and multimodal generation. However, limitations remain in cross-speaker transfer stability, fine-grained modeling of emotion and speaking style, and diversity.【Conclusions】Future research should further enhance high-fidelity and

*通信作者: 唐云祁 (E-mail: tangyunqi@ppsuc.edu.cn)

expressive speech generation, strengthen the modeling of emotion, register, and style, improve generalization across languages and speakers, pursue lightweight and real-time deployment, and explore multimodal unified generation frameworks driven by large language models

Keywords: Text-to-Speech; zero-shot; non-autoregressive models; autoregressive models; hybrid models; large language models

引言

语音合成又称为文本到语音 (Text-to-Speech, TTS), 旨在从文本中合成可理解和自然的音频, 长期以来一直是人工智能、自然语言和语音处理的研究课题^[1]。早期的语音合成主要依赖机械式或电子式语音合成器, 其方法简单, 系统庞杂, 难以满足实际应用需求。随着计算机技术、统计建模理论和语音信号分析能力的不断进步, 语音合成经历了从波形拼接、统计参数合成到神经网络驱动的深度学习合成的发展历程。近年来, 深度学习技术的快速演进极大提升了语音合成系统在自然度、流畅性、实时性以及表现力方面的性能, 使得语音合成技术被广泛应用于智能语音助手、车载导航、有声阅读、影视配音、无障碍服务等多个实际场景中。

随着应用场景的不断拓展, 用户对语音合成系统在说话人个性、语音风格、情感表达以及多语言支持等方面提出了更高层次的需求。在此背景下, 传统 TTS 方法对目标说话人语音数据的高度依赖成为限制系统扩展性和泛化能力的关键瓶颈。为此, 研究者提出了零样本语音合成 (Zero-shot Text-to-Speech, Zero-shot TTS), 旨在无需目标说话人训练数据的情况下, 生成具有目标音色、风格甚至情感特征的语音, 突破了传统 TTS 对说话人数据的依赖。这一技术路径显著增强了语音合成系统的灵活性和适应性, 为快速构建多说话人、多语言、强表现力的语音系统提供了可能。

作为近年来 TTS 研究的重要方向, Zero-shot TTS 经历了从基于说话人嵌入的端到端架构, 向融合神经语音编码器与扩散模型的复杂生成框架不断演进。早期方法侧重于音

色迁移与静态说话人建模, 随后逐步引入风格、情感、韵律等多维表达控制机制, 显著提升了语音个性化与自然度。2023 年起, 以 VALL-E、Natural Speech 2/3、MegaTTS 为代表的最新方法融合了离散语音表示与扩散生成过程, 在语音保真度、表达多样性、跨语言迁移能力等方面取得显著进展。同时, 生成式人工智能的快速兴起, 特别是大语言模型 (Large Language Models, LLMs) 的发展, 为 Zero-shot TTS 提供了新的技术范式。LLMs 凭借大规模语音-文本联合建模与上下文学习能力, 使 TTS 系统能够在跨语言迁移、多模态生成及人机交互等场景中展现出更强的适应性及扩展性。这些进展不仅推动了 Zero-shot TTS 在多语言语音合成、语音克隆等实际应用中的落地, 也预示着语音合成正逐步迈向统一的多模态生成框架。

本文围绕 Zero-shot TTS 的发展现状与前沿进展, 系统梳理其定义与核心特征, 重点对主流的端到端 Zero-shot TTS 方法进行分类归纳与性能分析, 并探讨当前研究中面临的挑战与未来发展方向。

1 零样本语音合成概述

本文在 Web of Science 网站上的 Core Collection 核心数据库中以 “Zero-shot TTS” or “voice cloning” 等相关的主题词, 对 2021-2025 年的文献进行检索, 筛选出 118 篇相关文献, 制作了每年发布文献的数量分布图 (图 1)。从整体趋势来看, Zero-shot TTS 相关研究自 2021 年起呈现快速增长态势, 2024 年增长更为显著, 表明该方向是学术界的研究热点。同时用 Citespace 的文献可视化软件制作了文献的关键词聚类图谱 (图 2)。从关键词聚类图谱中可以看出, 近几年, Zero-shot TTS 研究的热点集中在扩散模型、自监督特

征建模和大语言模型等新兴技术的引入,以提升跨说话人、跨语言条件下的语音自然度与表现力,关注在缺乏目标语音数据时实现语音合成的技术研究,实现说话人自适应,还涉及情感语音合成,语言迁移等相关研究。




图 1 2021-2025 年文献分布数量

Fig. 1 The number of literature publications from 2021 to 2025




图 2 相关文献关键词聚类图

Fig. 2 Keyword clustering map of related literature

1.1 零样本语音合成的定义

2023 年以来,基于大规模数据和大语言模型的应用,出现不少具备零样本能力的语音合成模型。Zero-shot TTS 在生成质量以及音色相似度上取得了显著突破,合成语音的自然度达到真人水平,引起了学术界和工业界的广泛关注。目前在主流文献中,对 Zero-shot TTS 并没有给出一个统一、权威的定义,但许多代表性论文和综述在介绍其方法时,都定义了 Zero-shot TTS 的含义。Jia 等人^[2]在其开创性的工作 SV2TTS 中首次提出,系统可以在训练阶段未接触目标说话人的情况下,仅基于几秒钟的参考语音,合成出带有该说话人音色的语音。此后,Casanova 等人^[3]提出的 YourTTS 系统将其表述为模型可在未见目标说话人的前提下,仅通过一条或少量参考语音,生成具有该说话人音色的语音。由此可见,Zero-shot

TTS 的核心是在于对说话人身份的快速捕捉与迁移能力,突破了传统 TTS 系统对大量说话人语料的依赖,具有较强的实用价值和研究意义,成为近年来语音合成技术的重要发展方向之一。

随着研究的深入,Zero-shot TTS 的定义不再局限于说话人身份的迁移,同样适用于其他生成维度,如未见过的说话风格、韵律模式和情感状态。部分工作在模型结构中引入风格编码器、韵律预测模块或情感嵌入,使得系统能够在推理阶段,根据文本提示或参考语音生成此前从未出现过的表达方式。这一趋势预示着 Zero-shot TTS 正从单一的音色克隆任务,向多维度、全方位的个性化语音生成方向发展。例如,Wang 等人^[4]提出的 VALL-E 系统不仅能保持音色一致,还能保留原始语音中的韵律与情感表达。Li 等人^[5]提出 StyleTTS2 模型能够在未见风格的情况下迁移韵律和说话风格。Peng 等人^[6]提出的 VoiceCraft 和 Lam 等人^[7]提出的 Present 模型进一步展示了无需文本一语音配对数据的泛化能力,并支持从真实语境中采集的语音中提取说话人特征用于合成。

1.2 零样本语音合成的核心特征

现有的代表性研究普遍认为,Zero-shot TTS 有以下几个核心特征:

(1) 训练阶段不使用目标语音

Zero-shot TTS 的最核心特征是在模型训练阶段完全不使用目标说话人的语音数据。模型需通过从大量其他说话人学习的通用语音特征表示能力,实现说话人特征的抽象建模与泛化,从而在未见过的说话人上进行迁移。例如,CosyVoice2^[8]在大规模多语言数据集(包含中文、英文、日语、韩语及多种中国方言)上进行训练,通过高质量的语音编码器与说话人嵌入表示机制,实现了跨说话人和跨语言的语音迁移能力,并有效支持零样本条件下的风格转移和多语言合成。

(2) 推理阶段仅需少量样本

在推理阶段,Zero-shot TTS 系统无需任何目标说话人文本一语音配对数据,仅需输入一小段参考语音即可进行音色迁移。参考语音可为目标说话人在任意上下文中的自然语音片段,系统通过说话人编码器提取其个性特征,引导语音生成器完成语音合成。例如,

MegaTTS3^[9]仅需数秒参考音频,即可生成在音色和韵律上高度拟真的目标语音。这种能力大幅度降低了系统构建的成本,为大规模语音合成系统部署与个性化语音克隆提供了可行路径。

(3) 支持音色复现与多维控制

除了实现目标音色的保持,Zero-shot TTS 的另一个关键能力在于其对情感、韵律、风格等多种语音表达维度的迁移与控制能力,这使得语音输出更加自然、个性化,并可适配多样化的应用需求。例如,StyleTTS^[10]和StyleTTS2^[5]都是基于风格的TTS模型,它可以从参考语音话语中用自然韵律合成不同的语音;EmoDiff^[11]无需额外优化,通过软标签权重直接定义情感强度,实现精准控制,生成样本多样性强,相同情感下可产生多样语音;F5-TTS^[12]创新的流匹配非自回归生成方法,结合先进的扩散变换器技术,实现了在无额外监督条件下的零样本学习,其情感控制功能能够根据文本内容灵活调整合成语音的情感表现。这种能力扩展不仅提升了语音合成系统的个性化和多样性,还对人机交互、数字人构建等实际应用场景具有重要意义。

2 零样本语音合成技术的分类

在语音合成技术不断演进的过程中,研究人员提出了多种创新方法,旨在提升合成语音的质量、效率和个性化水平。根据深度学习生成模型的架构特征大致可以将现有主流的端到端Zero-shot TTS方法大致分为基于非自回归模型(Non-Autoregression Models, NAR)、基于自回归模型(Autoregression Models, AR)、基于混合生成模型(Hybrid Models, HM)以及基于大语言模型(Large Language Models, LLMs)四大类。其中,非自回归模型通过并行生成语音特征显著提升了推理效率;自回归模型依靠逐帧生成保持语音的流畅与一致性;混合模型融合多种生成机制以兼顾质量、可控性和泛化能力;而大语言模型方法则利用上下文学习和跨模态建模推动了语音合成范式的转变。同时,本文对当前具有代表性的Zero-shot TTS方法进行了分类与比较(表1),对比维度包括:是否支持跨语言合成、是否支持对话生成,以及是否支持情感、风格与韵律等语音属性的控制。对情感、风格与韵

律等语音属性的控制能力分为显式控制与隐式控制^[13],主要体现在模型对控制信息的使用方式是否明确、是否可人为设定。显示控制是模型在合成过程中明确接收一个人为设定或可解释的控制变量,用户可以直接操控该变量来实现期望的语音输出特征变化。隐式控制是指从参考音频中自动提取某些特征来隐式引导语音合成。用户无法单独调节这些特征的表达方式。通过上述分类与比较,不仅可以全面理解当前端到端Zero-shot TTS模型的发展现状与技术分布,也为后续研究在模型选择与控制机制设计方面提供参考依据。

2.1 基于非自回归模型

2.1.1 基于生成对抗网络

生成对抗网络(Generative Adversarial Networks, GAN)在Zero-shot TTS中主要用于提升语音的自然度与清晰度,其判别器机制能够有效纠正声学特征生成中的模糊与失真问题。相比传统回归式生成方法,GAN在保证音色迁移的同时提升感知质量。例如,Kong等人^[14]提出的HiFi-GAN,是一种高效且高保真的生成对抗网络声码器,通过多尺度生成器与多周期判别器结构,在保持极低延迟的同时显著提升合成语音的自然度。Lee等人^[15]引入抗混叠周期性激活函数和大规模训练,提出了BigVGAN这一通用神经声码器,它在无需微调的情况下,在未见过的说话人、语言、录音环境、歌声、音乐和器乐音频等多种分布外场景中实现了最先进的零样本生成性能。Qiu等人^[16]提出一种基于改进型HiFi-GAN的语音克隆方法,通过优化生成器结构与引入多尺度判别器提升合成语音的清晰度与自然度。这些研究表明,GAN在保证音色迁移的同时,能够显著改善感知质量,为Zero-shot TTS提供了高效的声码器解决方案。

2.1.2 基于变分自编码器

变分自编码器(Variational Autoencoder, VAE)在Zero-shot TTS中的优势在于能够学习连续的、可控的潜在说话人空间,方便实现从少量参考语音中提取稳定的音色嵌入。在推理阶段,这种潜在空间有助于模型在未见说话人上进行平滑泛化,并可自然引入风格、情感

等多维控制。Li 等人^[17]的工作是通过跨话语条件 VAE 提升了对上下文依赖的建模能力，有效增强了合成语音的流畅性和自然度。VAE 方法通常训练稳定、收敛速度快，适合与生成对抗网络，流模型或者自回归模型等其他模型结合形成混合结构，例如，Kim 等人^[18]提出的 VITS 就是一种结合变分推理和对抗生成训练的高表现力语音合成模型。这些研究表明，VAE 方法为零样本条件下的个性化和可控语音生成提供了稳健途径。

2.1.3 基于流模型

流模型（Flow-based models）通过可逆映射直接在语音特征与潜在变量之间进行精确变换，具备精确的似然估计能力，这使得它们在 Zero-shot TTS 中能够生成高保真、无模糊的频谱表示，并保证生成样本的多样性。模型的条件建模能力强，可直接结合说话人嵌入实现音色迁移。Casanova 等人^[19]提出 SC-Glow TTS，一种基于流的零样本多说话人语音合成模型，通过引入说话人条件化机制、多编码器结构和 HiFi-GAN 微调，解决零样本多说话人语音合成中的域迁移问题，实现了高质量、快速的语音生成。随后，Kim 等人^[20]提出 P-Flow，一种基于流匹配的生成模型，在训练中对参考音频片段应用掩码损失，通过对比有或无文本条件的向量场，增强发音清晰度和说话人相似度。Bilinski 等人^[21]提出了一种基于 Flow-TTS 的 Zero-shot TTS 方法，通过可逆变换序列将梅尔频谱映射到潜在空间，并结合说话人嵌入、基频和音素序列实现内容与说话人特征分离，其利用高斯混合模型生成随机说话人嵌入，从而合成训练集中未出现的新声音。这些研究表明，流模型在保证生成样本多样性的同时，能够较好地支持跨说话人泛化与高保真语音生成，成为 Zero-TTS 中的重要技术路线之一。

2.1.4 基于扩散模型

近年来，扩散模型（Diffusion models）在高保真语音生成领域表现突出，其逐步去噪的生成过程可有效恢复细节信息、减少失真。在 Zero-shot TTS 中，扩散模型尤其适合在未见说话人条件下保持韵律和音质的高度一致性，并能通过条件引导机制（如音色嵌入、风格提示）实现多维控制。Le 等人^[22]提出的 Voicebox，采用条件扩散建模机制，首次实现了在统一框

架下支持多任务、跨语言、高质量的文本到语音与任意语音变换任务。该模型突破了传统自回归或 Flow-based 架构在灵活性与可控性方面的限制，基于掩码预测的扩散策略实现对语音特征的逐步去噪生成。Bang 等人^[23]在 Grad-TTS 扩散模型基础上，引入信息扰动和说话人编码器。通过 ECAPA-TDNN 说话人编码器提取参考语音的说话人嵌入，结合扰动技术（如共振峰、音高变换）增强模型对未见说话人的泛化能力。采用两阶段训练优化扩散模型，提升零样本多说话人合成的自然度与说话人相似度。Shen 等人^[24]提出的 NaturalSpeech 2 结合神经音频编解码器与潜在扩散模型，有效提升了语音保真度与跨语言适应性；后续的自然语音 3^[25]借鉴了大语言模型的统一建模思想，在此基础上引入分解式扩散结构并采用更高效的语音表示，从而在自然度、韵律和可懂度等方面均显著优于同期方法。这些研究表明，扩散模型不仅适合于高质量语音生成，还能够通过灵活的条件机制支持情感和韵律的迁移控制。

2.1.5 基于其他非自回归模型

除了 GAN、VAE、Flow 和 Diffusion 外，近年来一些其他非自回归建模框架也在 Zero-shot TTS 中展现出良好性能。例如，Eskimez 等人^[26]提出 E2 TTS，属于非自回归模型框架，且结构非常简洁，不依赖复杂的生成机制，该模型首次在非自回归框架下实现了 Zero-shot TTS 的高效生成，兼具自然度、说话人相似度和推理效率。其核心创新在于摒弃显式时长模型和音素对齐，通过简单字符序列与流匹配训练实现复杂语音建模，为实时语音合成、低资源语言克隆等场景提供了新范式。Goswami 等人^[27]提出 SATTS，引入说话人吸引子机制，旨在通过语音分离任务促进说话人建模能力。该方法构建了一个语音分离模型作为先验网络，提取说话人吸引子向量用于辅助 TTS 模型进行个性化语音生成，从而无需显示说话人标签即可实现零样本语音克隆。刘朝辞^[28]通过表征学习构建隐含韵律建模方法，在 FastSpeech2 框架下引入词级风格变化、帧级自监督表征和多尺度对比学习等机制，有效提升了合成语音的自然度与表现力。这些非自回归方法为 Zero-shot TTS 提供了新的思路，特别是在实时性和低资源场景中展现出应用潜

力。

2.2 基于自回归模型

AR 在 Zero-shot TTS 中的优势在于能够逐帧生成声学特征,从而自然保持语音的时间一致性与流畅性。这类模型在处理长语音、对话式合成以及韵律细节还原方面具有优势,但推理速度相对较慢。Peng 等人^[6]提出了 VoiceCraft,一种基于 transformer 的自回归语言模型,通过结合因果掩码和延迟堆叠技术,实现了对语音编解码器令牌的高效建模。其核心创新在于在自回归框架下引入双向上下文支持,从而在语音编辑和零样本 TTS 任务中达到更高的自然度和鲁棒性。Lam 等人^[7]提出的 Present,属于典型的自回归语音合成框架,在主干网络基础上融合了韵律编码器和文本到韵律预测器,实现了零样本文本到韵律控制能力。岳焕景等人^[29]提出了一种基于音素级韵律建模的自回归 Zero-shot TTS 方法,通过停顿预测、音素时长建模和注意力判别模块提升韵律自然度与对齐稳定性,在多项主客观评估指标上取得优于对比模型的表现。整体来看,自回归方法在语音的细节还原和韵律保持方面表现突出,但推理效率仍是其主要瓶颈,未来的发展需要在保证自然度的同时进一步优化计算效率。

2.3 基于混合生成模型

混合生成模型通过融合多种生成机制的优势,在 Zero-shot TTS 中逐渐成为发展趋势。典型代表包括基于 VITS 框架的改进方法,例如, Pankov 等人^[30]提出了 DINO-VITS,该方法基于 VITS 的混合生成模型架构,结合了 VAE+Flow+GAN。付毅冲等人^[31]提出了一种零样本个性化语音合成系统,结合基于 VITS 的多说话人语音合成模型与基于文本提示的说话人表征生成模型,不仅提升了合成质量和音色匹配度,还显著增强了零样本能力。Li 等人^[32]提出 ZSE-VITS 方法,在 VITS 框架基础上,引入 TitaNe 说话人编码器提取高判别力说话人嵌入,实现零样本跨说话人语音克隆。该方法结合音高、能量和时长预测器进行显式韵律控制,支持局部与全局调节,并通过音高数据增强和情感语料微调提升了情感表现力。此外, Casanova 等人^[33]提出的 XTTS 方法,是在 Tortoise 基础上结合 VAE 与自回归

Transformer,通过两阶段生成压缩与预测实现语音建模。模型引入 ECAPA-TDNN 编码器与语言嵌入,并利用一致性损失提升跨语言泛化,支持 16 种语言的零样本合成。王陈偲等人^[34]基于 XTTS 模型构建了一个支持多语种语音克隆与批量处理的系统平台,并结合 FreeVC 模型实现了文本驱动与无文本条件下的音色迁移,验证了 XTTS 在中文场景下的自然度与个性化表现力。Style TTS^[10]和 Style TTS2^[5]则在风格潜变量建模的基础上结合 GAN 与扩散机制,显著提升了语音的自然度与表达丰富性。MegaTTS2^[35] MegaTTS3^[9]通过引入多粒度声学建模和扩散式解码器,显著增强了合成语音的自然度与多样性。Lei 等人^[36]提出的 Glow-WaveGAN 2 探索了 VAE、Flow 与 GAN 等结构的深度融合,以提升合成语音的保真度与泛化能力。总体来看,这些方法在传统生成框架下不断探索多机制融合路径,在语音质量、跨语言迁移和多维度控制方面均展现出综合优势,但仍面临模型复杂度高、训练和推理成本较大的问题。

2.4 基于大语言模型

近年来,生成式人工智能的发展特别是 LLMs 的兴起,为 Zero-shot TTS 提供了新的技术范式。与传统方法侧重声学特征建模不同,LLMs 驱动的系统通过大规模语音-文本联合建模与上下文学习机制,将语音生成任务转化为语言建模问题,从而在跨语言迁移、上下文保持与多模态协同等方面展现出全新的能力。VALL-E^[4]首次将语音建模与语言建模深度结合,仅依靠数秒参考语音即可实现高保真、具备韵律与情感保持的零样本语音克隆。后续的 VALL-E 2^[37]在人类水平的语音自然度和鲁棒性方面进一步突破。VALL-E R^[38]是基于 VALL-E 改进的鲁棒高效零样本 TTS 系统,解决解码不稳定和推理效率问题。VALL-E X^[39]在 VALL-E 基础上引入语言 ID 嵌入,训练数据包含中英双语共 70 K 小时的数据集 (LibriLight+WenetSpeech),学习跨语言的说话人特征迁移。CosyVoice2^[8]将大语言模型用于流式语音合成,兼顾高保真与实时性,展示了语音大模型在高效生成中的潜力。ByteDance Seed 团队^[40]提出的 Seed-TTS 是一个由多种生成范式构成的统一框架,分别包含

自回归（Seed-S）、非自回归（Seed-SA）、流模型（Seed-F）与扩散模型（Seed-D）四种子结构，融合了生成速度与语音质量的优势。该方法利用参考语音进行隐式风格建模，并通过条件扩散或流机制增强说话人特征保留与表达控制能力，支持多语种零样本语音克隆与高保真语音生成。YE 等人^[41]提出的 LLaSA，将 LLaMA 等大语言模型扩展至语音建模任务，通过统一的文本与语音 token 表示，实现了零样本条件下的语音合成与多模态交互。总

体来看，基于大语言模型的零样本语音生成方法正在把 TTS 从“专门化声学建模”推动到“统一的语言建模与多模态生成”阶段。这一趋势不仅显著提升了语音合成的自然度和泛化能力，也为跨语言人机交互、数字人构建及多模态内容生成提供了新路径。但与此同时，模型规模过大、训练与推理成本高昂、语音与文本/多模态的对齐机制不稳定等问题，仍然是未来需要重点攻克挑战。

表 1 Zero-shot TTS 系统性能比较表

Table 1 Performance Comparison of Zero-shot TTS Systems

合成方法	是否跨语言	是否支持对话	是否支持情感/风格/韵律控制
SC-GlowTTS	否	否	否
P-Flow	否	否	否
Voicebox	是	否	隐式风格控制
Grad-TTS	否	否	隐式风格控制
NaturalSpeech 2	是	否	隐式风格控制、显式韵律控制
NaturalSpeech 3	是	否	显式风格/韵律控制
E2-TTS	否	否	否
SATTs	否	否	否
VoiceCraft	否	否	隐式风格控制
Present	否	否	显式风格/韵律控制
VALL-E	否	否	隐式风格/韵律控制
VALL-EX	是	否	隐式风格/韵律控制
VALL-ER	否	否	显式情感/韵律控制、隐式风格控制
StyleTTS	是	否	隐式风格控制
StyleTTS 2	是	否	隐式情感/风格/韵律控制
SeedTTS	是	否	隐式情感/风格/韵律控制
XTTS	是	否	隐式风格/韵律控制
DINO-VITS	否	否	否
YourTTS	是	否	隐式风格/韵律控制
ZSE-VITS	否	否	显式情感/韵律控制、隐式风格控制
MegaTTS 2	是	否	隐式风格/韵律控制
MegaTTS 3	是	否	显式风格/韵律控制
Glow-WaveGAN 2	否	否	否
CosyVoice2	是	是	隐式情感/风格/韵律控制
LLaSA	是	否	隐式情感/风格/韵律控制

3 未来的挑战和发展方向

3.1 提升语音自然度与个性化表达能力

随着语音合成技术的不断发展，用户对合成语音的自然度、表现力和个性化需求也在持

续提升。实现具备高表现力的语音输出，需要对音色、韵律、情感、风格等多维要素进行精准建模与灵活控制，尤其在区分自发语音与朗读语音等语体风格方面，仍面临较大挑战。个性化语音合成方面，模型往往需在目标说话人

未出现在训练集的情况下，仅凭极少量参考语音进行合成。然而，由于不同说话人发音习惯、语速语调存在显著差异，模型如何在缺乏充足音素覆盖的前提下合成出自然流畅、个性鲜明的语音，仍是一个难点。此外，当前语音合成系统主要聚焦于句子级别的语音生成，对多说话人参与的对话语音建模尚不充分。如何实现上下文一致、角色分明、语调自然的多说话人对话合成，也是未来需要重点突破的方向。

3.2 增强跨语言与跨说话人泛化能力

在全球多语种、多方言交流日益频繁的背景下，语音合成系统的跨语言迁移能力成为衡量其实用性的重要指标。不同语言在语音系统、音系规则、音节结构等方面存在显著差异，如何使模型在未见语种或未见方言条件下实现自然、准确的语音合成，是一个急需解决的挑战。同时，Zero-shot TTS 的核心目标是实现未见说话人的语音克隆，但不同模型对说话人特征的泛化能力差异明显。部分系统仅能处理与训练语料中相似的说话人，而难以适配性别、年龄、口音等属性差异较大的个体。因此，提升模型在跨语言与跨说话人场景下的泛化能力，是推动 Zero-shot TTS 走向通用化和实用化的关键所在。

3.3 推进数据与资源的可持续建设

尽管现有研究主要集中于模型架构与生成能力的优化，但高质量语音合成系统的构建在根本上仍依赖于丰富、全面的数据资源。Zero-shot TTS 在多语言、多风格、情感表达等维度上的发展，对语音数据的覆盖度、标注精度和可获取性提出了更高要求。目前，主流数据集往往集中于少数语言、标准发音或特定语体，缺乏对多样化口音、情感风格、自发语音、非主流语言等维度的覆盖，严重限制了模型的泛化能力和应用范围。未来亟须构建包含多语言、多说话人、多风格特征的大规模开源语音语料，提升模型训练的丰富性和代表性，从而推动 Zero-shot TTS 向更广泛的应用场景发展。

3.4 实现面向交互的高效语音合成

在智能语音助手、人机对话、语音翻译等实时交互场景中，语音合成的响应速度和系统延迟直接影响用户体验。当前部分高质量语音合成模型在推理阶段计算复杂、速度缓慢，难

以满足低延迟要求。与此同时，现有模型普遍参数规模庞大，难以适配边缘设备、移动终端等资源受限环境。未来需要从两个方面改进：一方面，通过优化模型结构与推理流程、提升并行计算效率、引入流式合成框架来增强系统的响应能力和交互自然性；另一方面，通过神经架构搜索、模型剪枝、蒸馏、量化等方式研发轻量化、高效率的语音合成模型，实现低功耗、高性能的跨平台部署，从而满足多场景、多设备的应用需求。

3.5 融合多模态生成

随着生成式人工智能的不断发展，语音合成正逐渐融入多模态生成体系。未来的 TTS 系统不仅要在声音层面实现高保真与强表现力，还需要与文本、图像、视频等模态协同建模，从而在语义一致性、风格统一性和交互自然性上达到新的水平。在这一趋势下，Zero-shot TTS 将成为多模态交互和数字人构建的重要基础。然而，目前语音与其他模态在数据规模、特征表示和对齐机制上仍存在显著差异，限制了跨模态生成的稳定性与可控性。此外，多模态模型参数规模庞大，推理与训练成本过高，也影响了其实用化进程。因此，如何在统一框架下实现高效的跨模态对齐与协同表达，是未来 Zero-shot TTS 需要重点攻克的方向。

利益冲突声明

所有作者声明不存在利益冲突关系。

参考文献

- [1] TAN X, QIN T, SOONG F, et al. A survey on neural speech synthesis[J]. arXiv, 2021, 2106.15561.
- [2] JIA Y, ZHANG Y, WEISS R, et al. Transfer learning from speaker verification to multispeaker text-to-speech synthesis[C]//Advances in Neural Information Processing Systems (NeurIPS). 2018, 31.
- [3] CASANOVA E, WEBER J, SHULBY C D, et al. YourTTS: Towards zero-shot multi-speaker TTS and zero-shot voice

conversion for everyone[C]//International Conference on Machine Learning (ICML). PMLR, 2022: 2709-2720.

[4] WANG C, CHEN S, WU Y, et al. Neural codec language models are zero-shot Text-to-Speech synthesizers[J]. arXiv, 2023, 2301.02111.

[5] LI Y A, HAN C, RAGHAVAN V, et al. StyleTTS 2: Towards human-level text-to-speech through style diffusion and adversarial training with large speech language models[J]. Advances in Neural Information Processing Systems, 2023,36: 19594-19621.

[6] PENG P, HUANG P Y, LI S W, et al. VoiceCraft: zero-shot speech editing and Text-to-Speech in the wild[J]. arXiv, 2024, 2403.16973.

[7] LAM P, ZHANG H, CHEN N F, et al. PRESENT: zero-shot text-to-prosody control[J]. IEEE Signal Processing Letters, 2025.

[8] DU Z, WANG Y, CHEN Q, et al. CosyVoice 2: Scalable streaming speech synthesis with large language models[J]. arXiv, 2024, 2412.10117.

[9] JIANG Z, REN Y, LI R, et al. MegaTTS 3: Sparse alignment enhanced latent diffusion transformer for zero-shot speech synthesis[J]. arXiv, 2025, 2502.18924.

[10] LI Y A, HAN C, MESGARANI N. StyleTTS: A style-based generative model for natural and diverse text-to-speech synthesis[J]. IEEE Journal of Selected Topics in Signal Processing, 2025.

[11] GUO Y, DU C, CHEN X, et al. EmoDiff: Intensity-controllable emotional text-to-speech with soft-label guidance[C]//ICASSP 2023—IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2023: 1-5.

[12] CHEN Y, NIU Z, MA Z, et al. F5-TTS: A fairytaler that fakes fluent and faithful speech with flow matching[J]. arXiv, 2024, 2410.06885.

[13] 唐浩彬, 张旭龙, 王健宗, 等. 表现性语音合成综述[J]. 大数据, 2023,9(6): 53-71.

[14] KONG J, KIM J, BAE J. HiFi-GAN: Generative adversarial networks for efficient and high fidelity speech synthesis[J]. Advances in Neural Information Processing Systems, 2020,33: 17022-17033.

[15] LEE S, PING W, GINSBURG B, et al. BigVGAN: A universal neural vocoder with large-scale training[J]. arXiv, 2022, 2206.04658.

[16] QIU Z, TANG J, ZHANG Y, et al. A voice cloning method based on the improved HiFi-GAN model[J]. Computational Intelligence and Neuroscience, 2022,2022: 6707304.

[17] LI Y, YU C, SUN G, et al. Cross-Utterance conditioned VAE for speech generation[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2024,32: 4263-4276.

[18] KIM J, KONG J, SON J. Conditional variational autoencoder with adversarial learning for end-to-end text-to-speech[C]//International Conference on Machine Learning (ICML). PMLR, 2021: 5530-5540.

[19] CASANOVA E, SHULBY C, GÖLGE E, et al. SC-GlowTTS: An efficient zero-shot multi-speaker text-to-speech model[J]. arXiv, 2021, 2104.05557.

[20] KIM S, SHIH K, SANTOS J F, et al. P-Flow: A fast and data-efficient Zero-shot TTS through speech prompting[J]. Advances in Neural Information Processing Systems, 2023,36: 74213-74228.

[21] BILINSKI P, MERRITT T, EZZERG A, et al. Creating new voices using normalizing flows[C]//Interspeech 2022. 2022: 2958-2962.

[22] LE M, VYAS A, SHI B, et al. Voicebox: Text-guided multilingual universal speech generation at scale[J]. Advances in Neural Information Processing Systems, 2023,36: 14005-14034.

[23] BANG C W, CHUN C. Effective

zero-shot multi-speaker text-to-speech technique using information perturbation and a speaker encoder[J]. Sensors, 2023,23(23): 9591.

[24] SHEN K, JU Z, TAN X, et al. NaturalSpeech 2: Latent diffusion models are natural and zero-shot speech and singing synthesizers[J]. arXiv, 2023, 2304.09116.

[25] JU Z, WANG Y, SHEN K, et al. NaturalSpeech 3: zero-shot speech synthesis with factorized codec and diffusion models[J]. arXiv, 2024, 2403.03100.

[26] ESKIMEZ S E, WANG X, THAKKER M, et al. E2 TTS: Embarrassingly easy fully non-autoregressive Zero-shot TTS[C]//IEEE Spoken Language Technology Workshop (SLT). IEEE, 2024: 682-689.

[27] GOSWAMI N, HARADA T. SA-TTS: Speaker attractor text-to-speech, learning to speak by learning to separate[J]. arXiv, 2022, 2207.06011.

[28]刘朝辞. 基于隐含表征的语音合成韵律建模方法研究[D]. 合肥: 中国科学技术大学, 2025.

[29]岳焕景, 王嘉玮, 杨敬钰. 基于音素级韵律建模的自回归零样本语音合成[J]. 湖南大学学报(自然科学版), 2025, 52(4): 114-123.

[30] PANKOV V, PRONINA V, KUZMIN A, et al. DINO-VITS: Data-efficient Zero-shot TTS with self-supervised speaker verification loss for noise robustness[J]. arXiv, 2023, 2311.09770.

[31]付毅冲. 零样本个性化语音合成的研究[D]. 北京: 北京邮电大学, 2024.

[32]LI J, ZHANG L. ZSE-VITS: A zero-shot expressive voice cloning method based on VITS[J]. Electronics, 2023,12(4): 820.

[33]CASANOVA E, DAVIS K, GÖLGE E, et al. XTTS: A massively multilingual zero-shot Text-to-Speech model[J]. arXiv, 2024, 2406.04904.

[34]王陈偲,杨思燕,苗启广.基于 XTTS 模型的声音克隆系统研究[J/OL]. 计算机科学,1-10[2025-09-12].<https://link.cnki.net/urlid>

/50.1075.tp.20250815.0949.022.

[35]JIANG Z, LIU J, REN Y, et al. Mega-TTS 2: Boosting prompting mechanisms for zero-shot speech synthesis[J]. arXiv, 2023, 2307.07218.

[36]LEI Y, YANG S, CONG J, et al. Glow-WaveGAN 2: High-quality zero-shot Text-to-Speech synthesis and any-to-any voice conversion[J]. arXiv, 2022, 2207.01832.

[37]CHEN S, LIU S, ZHOU L, et al. VALL-E 2: Neural codec language models are human-parity zero-shot Text-to-Speech synthesizers[J]. arXiv, 2024, 2406.05370.

[38]韩冰,钱彦旻.VALL-E R:利用单调对齐策略的鲁棒且高效零样本语音合成[J/OL]. 信号处理,1-13 [2025-09-12].<https://link.cnki.net/urlid/11.2406.tn.20250728.1918.006>.

[39]ZHANG Z, ZHOU L, WANG C, et al. Speak foreign languages with your own voice: Cross-lingual neural codec language modeling[J]. arXiv, 2023, 2303.03926.

[40] ANASTASSIOU P, CHEN J, CHEN J, et al. Seed-TTS: A family of high-quality versatile speech generation models[J]. arXiv, 2024, 2406.02430.

[41] YE Z, ZHU X, CHAN C M, et al. LLaSA: Scaling train-time and inference-time compute for LLaMA-based speech synthesis[J]. arXiv, 2025, 2502.04128.

收稿日期: 2025 年 8 月 11 日

作者简介



王丹琳, 北京警察学院刑事科学技术系, 讲师, 主要研究方向为视听检验技术、智能图像识别与理解。本文承担工作: 负责系统性文献调研、

论文的撰写。

WANG Danlin, Department of Criminal Science and Technology, Beijing Police College, Lecturer, Research interests: forensic audio-visual examination technology, intelligent image recognition and interpretation.

Contribution to this paper: responsible for systematic literature review and manuscript writing.

E-mail: wangdl.1101@163.com



唐云祁, 中国人民公安大学侦查学院, 教授, 博士生导师, 主要研究方向为电子数据检验、智能图像识别与理解等。本文承担工作为: 负责论文框架设计, 论文修改与审定。

TANG Yunqi, School of Criminal Investigation, People's Public Security University of China, Professor and Doctoral Supervisor. Research interests: electronic data examination and forensics, intelligent image recognition and interpretation Contribution to this paper: responsible for paper framework design, revision, and final approval. E-mail: tangyunqi@ppsuc.edu.cn